Hydro-UAI Course

Redes neurais artificiais
Fundamentos básicos

Prof. André Rodrigues

Prof. Bruno Brentan

Prof. Rodrigo Perdigão



Objetivos e percurso da aula

01	**Representação**	Como o neurônio combina as entradas.
02	**Não linearidade**	Como as ativações ampliam o modelo.
03	**Treinamento**	Como o erro orienta o ajuste dos pesos.
04	**Generalização**	Como avaliar a previsão em dados futuros.

Relembrando a Aula Passada

01 Como identificar relações entre as entradas e a saída?

02 A chuva de agora explica a vazão de agora?

03 Quanto histórico de chuva e vazão devemos considerar?

04 Mais variáveis de entrada significam um modelo melhor?

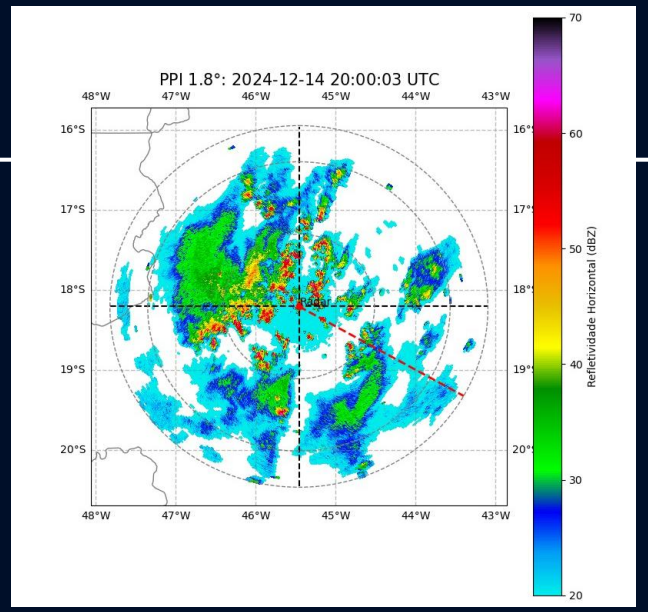
05 O que muda ao prever 1, 3 ou 6 horas à frente? E 24 horas?

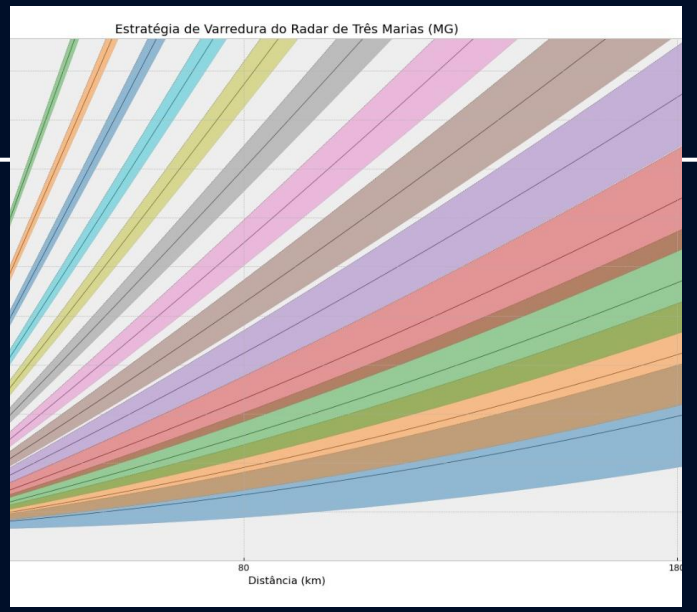
Estimativa de Chuva Futura

Radar meteorológico

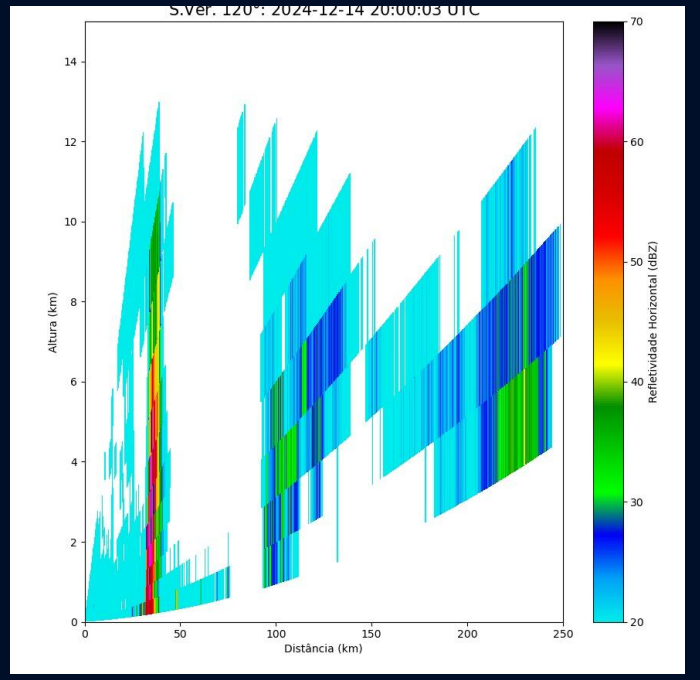
Estima a intensidade e acompanha o deslocamento da precipitação, apoiando o monitoramento de tempestades e os alertas de cheias.

- **Resolução Temporal: atualizações na ordem de minutos**
- **Espacial: detalhamento na ordem de 100-200 metros, conforme o equipamento, o produto e a distância ao radar**
- **Cobertura no Brasil: A rede própria do Cemaden possui nove radares e deixa extensas áreas sem cobertura**





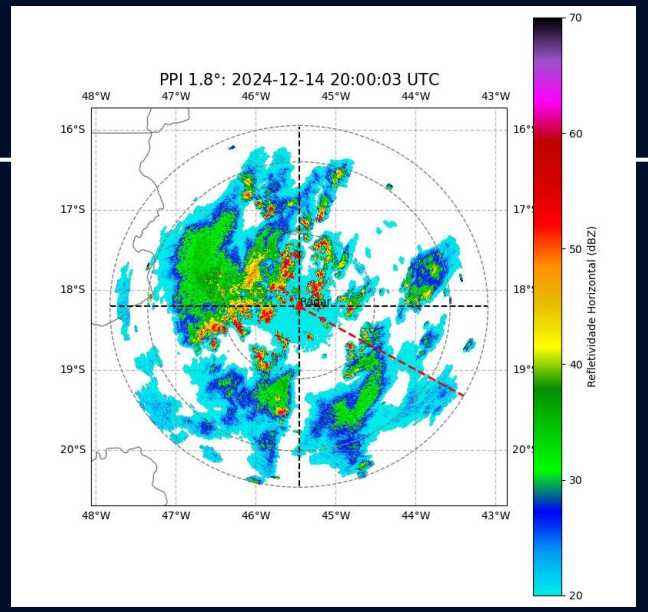


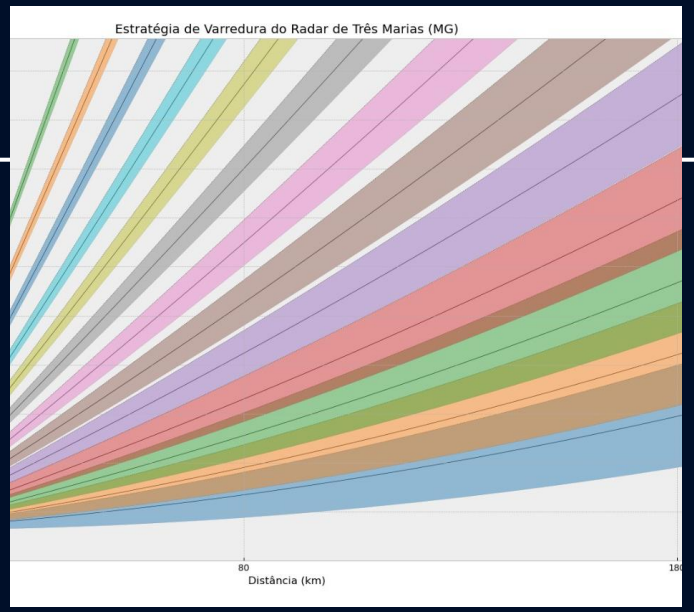


Estimativa de Chuva Futura

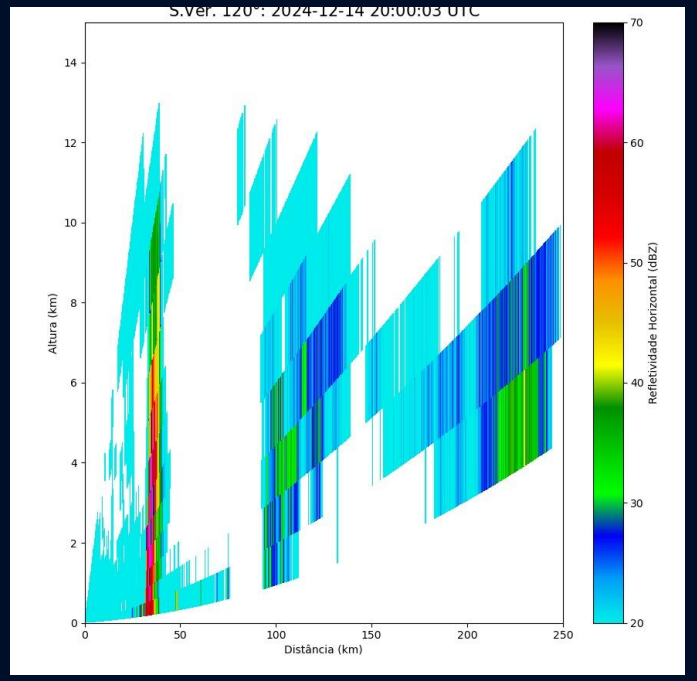
Radar meteorológico

- **Outras redes públicas e privadas complementam o monitoramento, incluindo radares de mineradoras, como a Vale**
- **O Rio Grande do Sul investe na ampliação da cobertura, com a iminência de instalação de três novos equipamentos no RS**





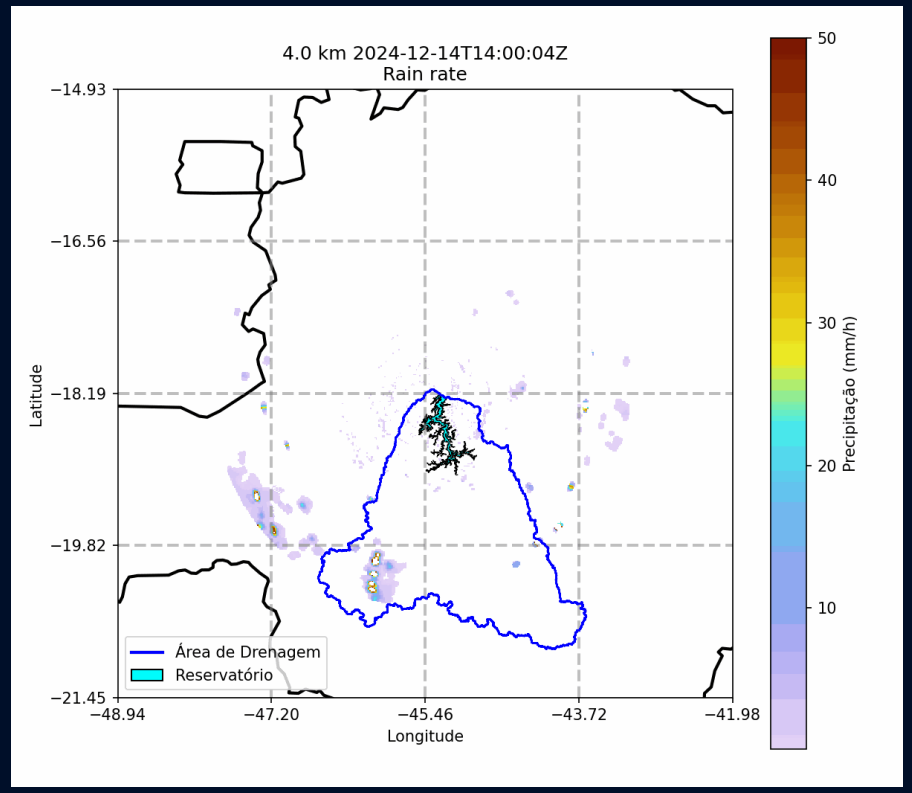


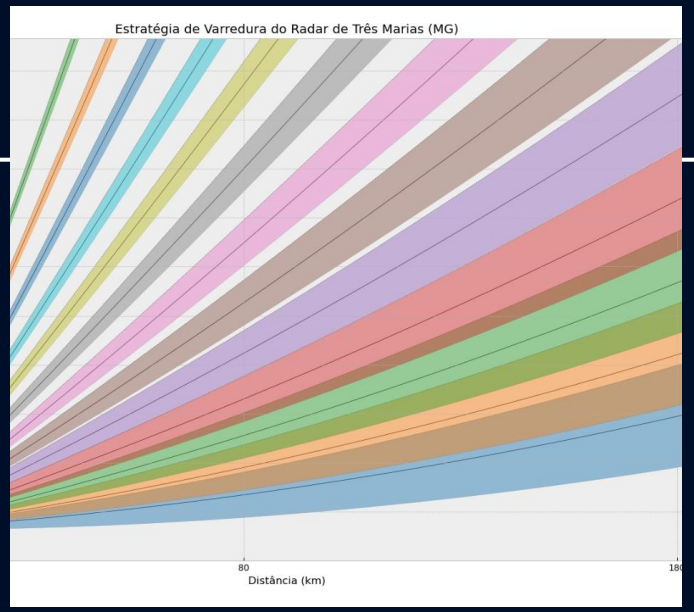


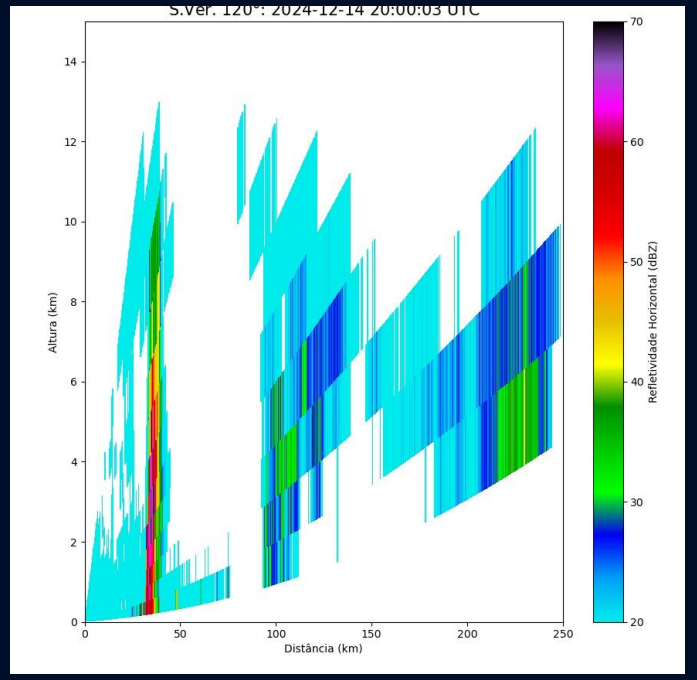
Estimativa de Chuva Futura

Radar meteorológico

- **Outras redes públicas e privadas complementam o monitoramento, incluindo radares de mineradoras, como a Vale**
- **O Rio Grande do Sul investe na ampliação da cobertura, com a iminência de instalação de três novos equipamentos no RS**







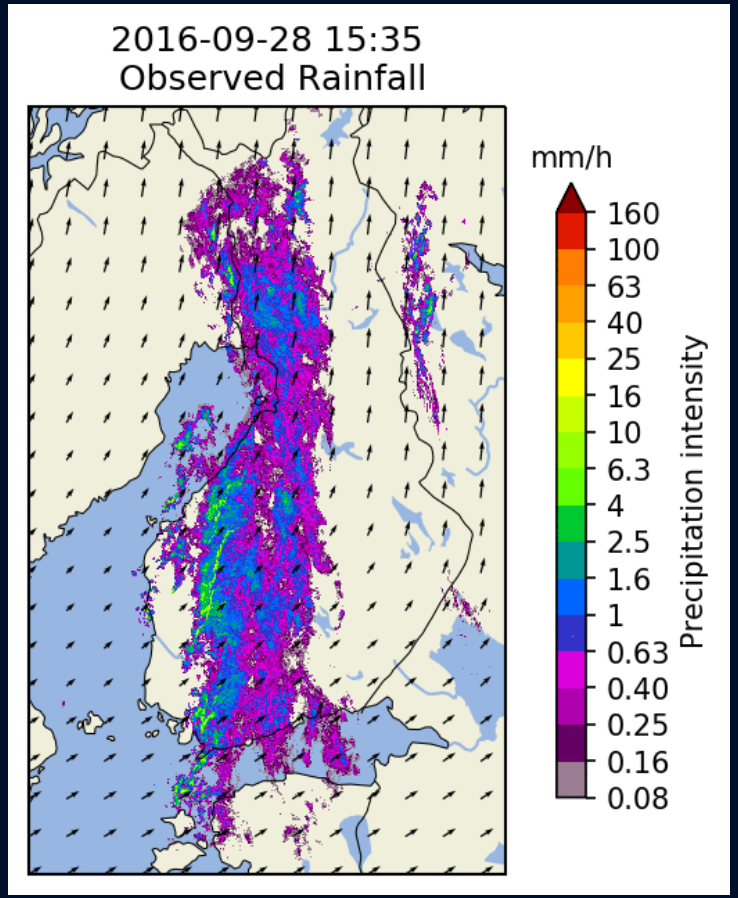
Estimativa de Chuva Futura

Previsão de curtíssimo prazo com radar (Nowcasting)

Imagens sucessivas de radar permitem estimar a direção e a velocidade de deslocamento dos sistemas de chuva

Métodos de previsão

- **Extrapolação e modelos estatísticos: estimam o movimento da chuva e projetam sua posição futura, podendo gerar cenários probabilísticos.**
- **Exemplo: pysteps.**
- **Métodos baseados em dados: aprendem padrões de evolução da chuva em séries históricas de radar. Exemplos: redes neurais e modelos generativos.**



Estimativa de Chuva Futura

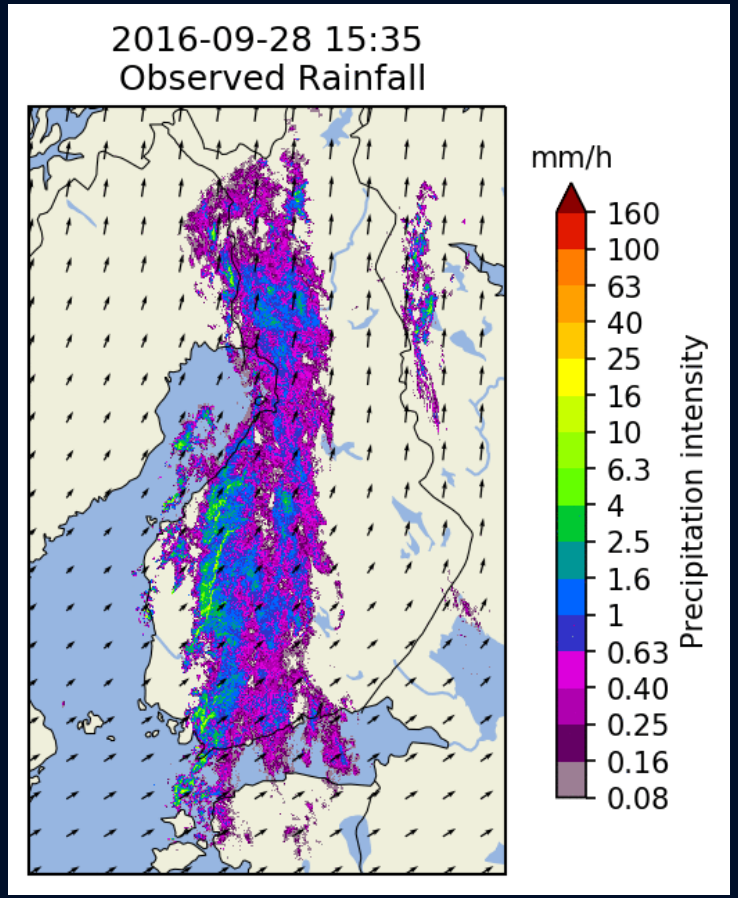
Previsão de curtíssimo prazo com radar (Nowcasting)

Horizonte de previsão

- **Maior habilidade nas primeiras 1–2 horas•**
- **Possível extensão até 3–5 horas, conforme o método e o evento•**
- **Perda acentuada de habilidade com o aumento da antecedência**

Principal limitação:

Prever a formação, a intensificação e a dissipação das tempestades, além de seu deslocamento.



Estimativa de Chuva Futura

Previsão numérica do tempo — NWP

Modelos numéricos representam a evolução da atmosfera por meio de equações físicas, a partir de observações de satélites, estações e outros instrumentos.

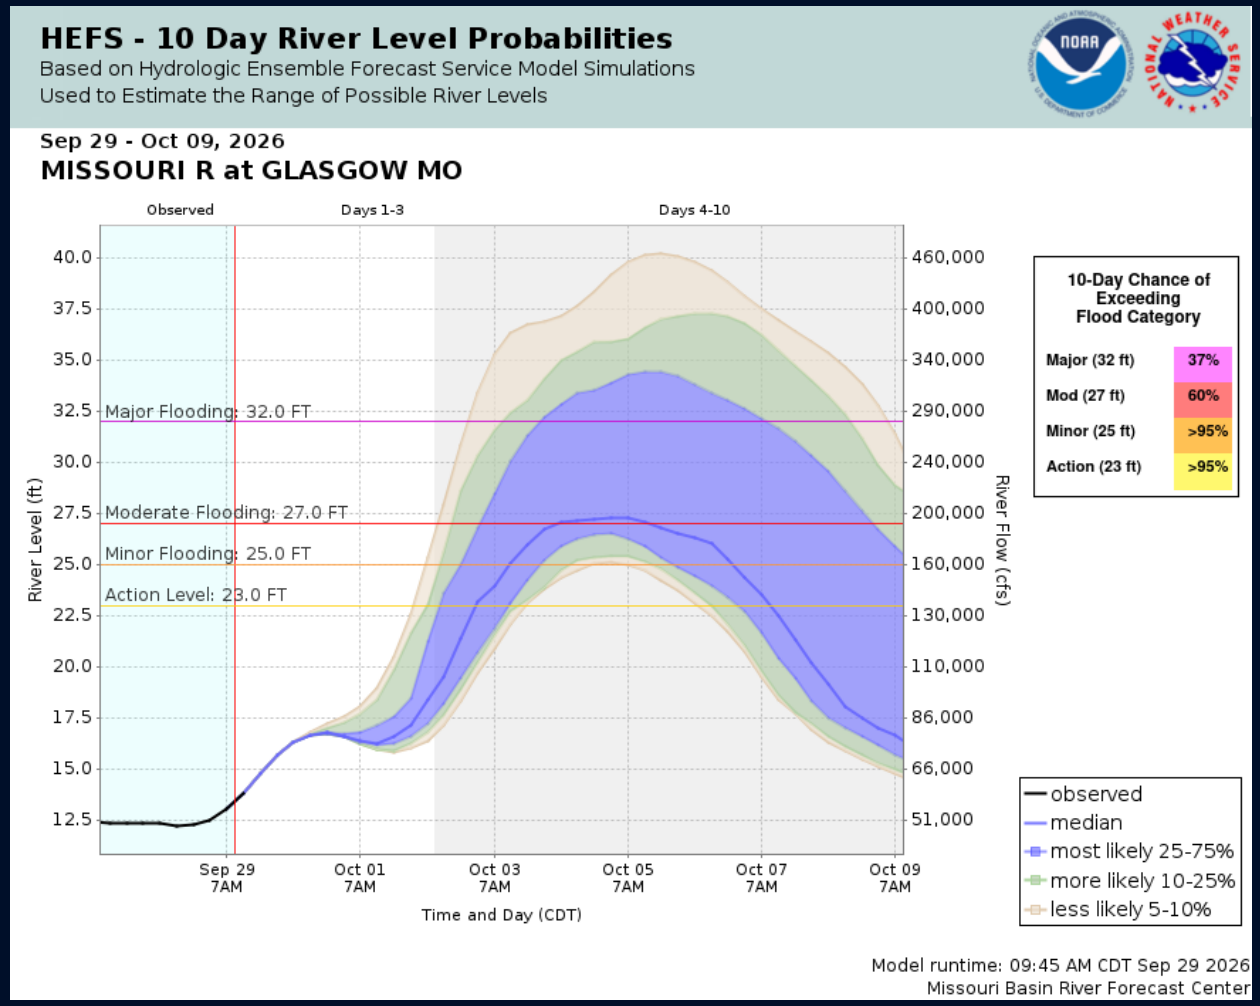
- **GEFS: sistema de previsão por conjuntos da NOAA/NCEP**
- **IFS/ENS: modelo e sistema de previsão por conjuntos do ECMWF**

Vantagens

- **Cobertura global, incluindo regiões sem radares**
- **Representação da evolução dos sistemas meteorológicos**
- **Previsões de precipitação, temperatura, vento e outras variáveis**

Faixa de aplicação no curso: 6–72 horas

Antecedência para preparar alertas e alimentar modelos hidrológicos.



Estimativa de Chuva Futura

Previsões por conjuntos

GEFS e ECMWF ENS produzem múltiplos cenários, variando as condições iniciais e aspectos da representação da atmosfera.

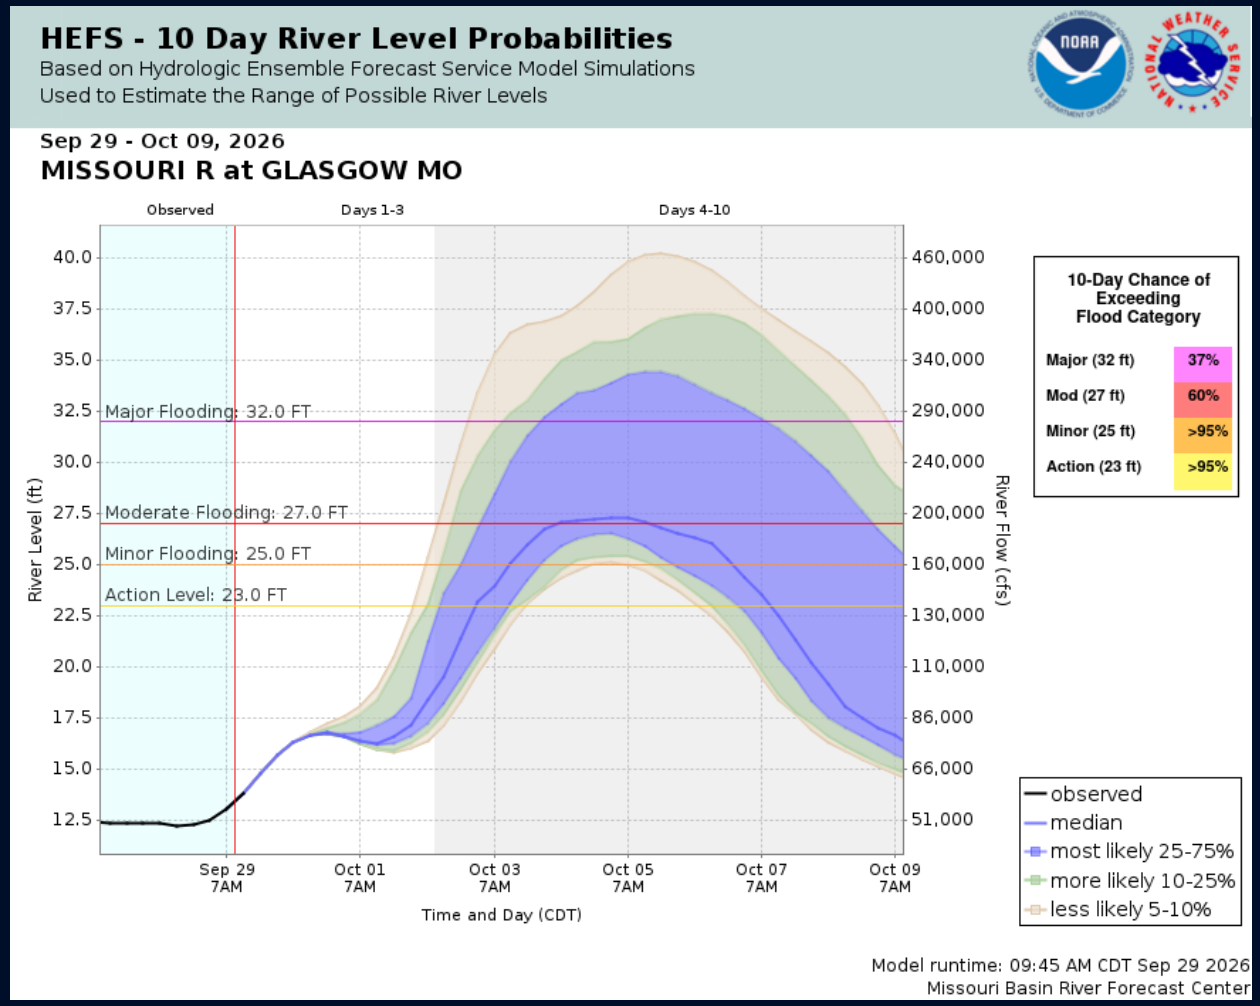
- **Probabilidade de a chuva superar um limiar**
- **Faixas de precipitação acumulada**
- **Incerteza sobre intensidade, localização e horário da chuva**

Aplicação em hidrologia

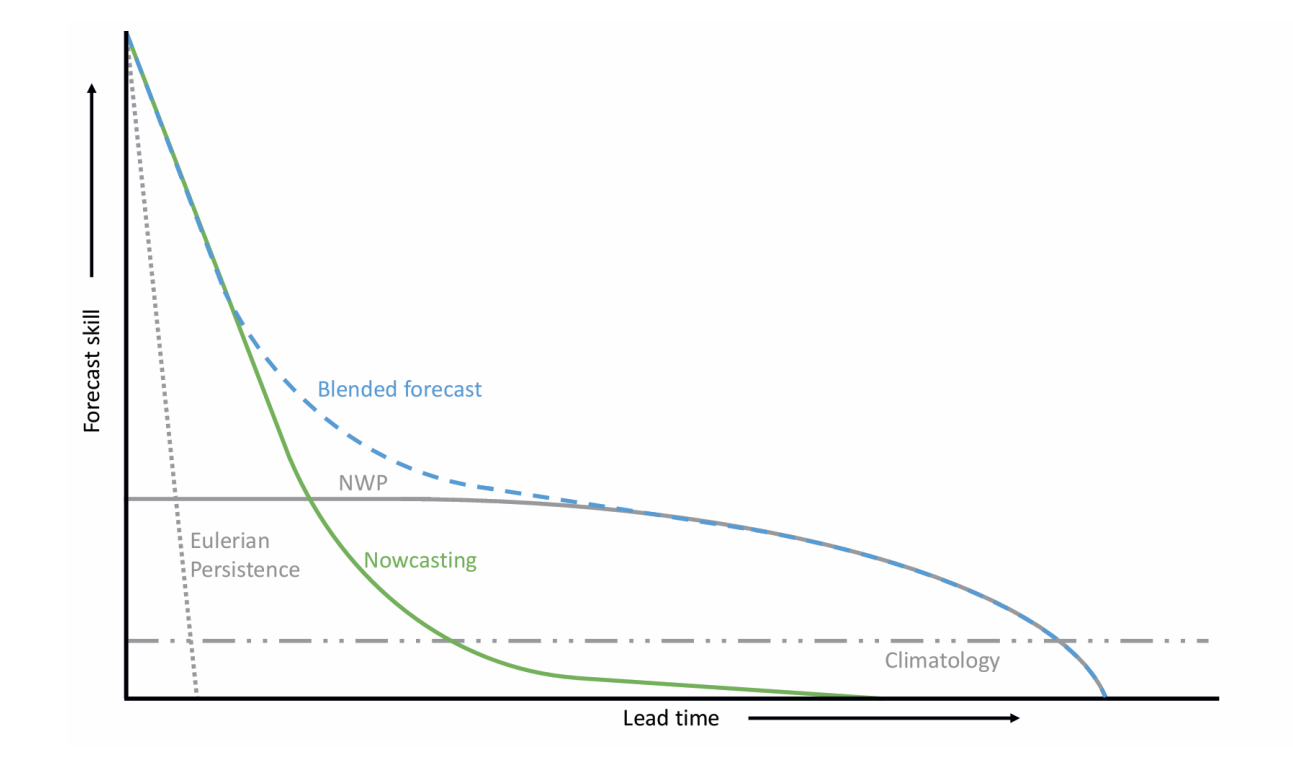
Cada cenário de chuva pode alimentar um modelo hidrológico, gerando diferentes cenários de vazão e risco de cheia.

Horizonte de interesse: 6–72 horas

As probabilidades precisam de avaliação e calibração com dados observados.



Estimativa de Chuva Futura



Received: 12 August 2022 | Revised: 4 March 2023 | Accepted: 7 March 2023 | Published on: 24 April 2023
DOI: 10.1002/qj.4461
Quarterly Journal of the Royal Meteorological Society RMetS
RESEARCH ARTICLE

Scale-dependent blending of ensemble rainfall nowcasts and numerical weather prediction in the open-source pysteps library

Ruben O. Imhoff[1,2] | Lesley De Cruz[3,4] | Wout Dewettinck[5] | Claudia C. Brauer[2] | Remko Uijlenhoet[6] | Klaas-Jan van Heeringen[1] | Carlos Velasco-Forero[7] | Daniele Nerini[8] | Michiel Van Ginderachter[3] | Albrecht H. Weerts[1,2]

Redes neurais na hidrologia



Previsão de vazão

Estimar Q(t + 1) com informações disponíveis até t.

Detecção de anomalias

Analisar diferenças entre medidas e estimativas.

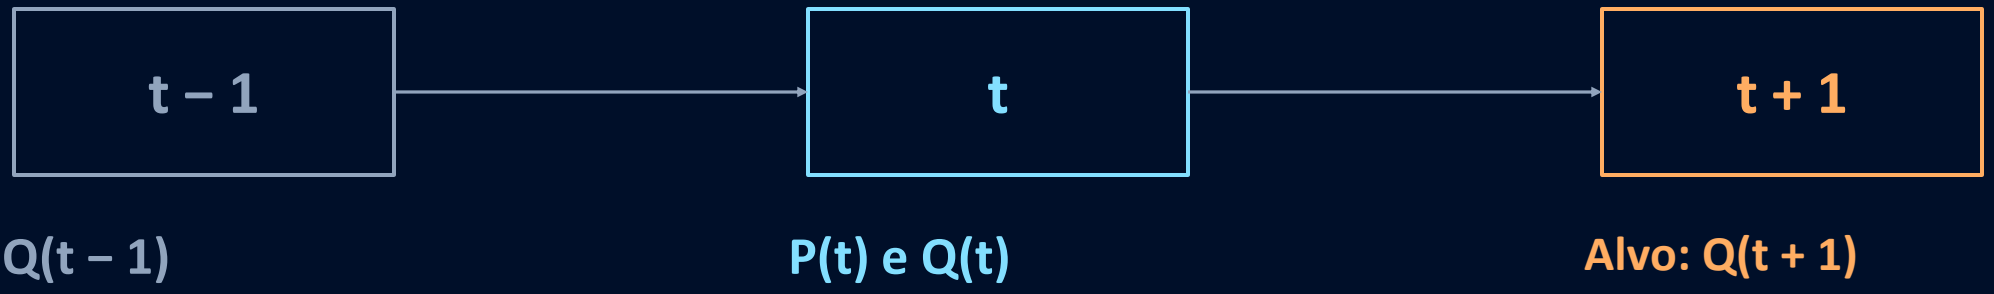
Reservatórios e balanços

Estimar variáveis de apoio à operação e ao balanço hídrico.

A interpretação física e a qualidade dos dados continuam necessárias.

Previsão e disponibilidade dos dados

Objetivo: prever a vazão do próximo dia.



$x_t = [P(t), Q(t), Q(t - 1)]$

$y_t = Q(t + 1)$

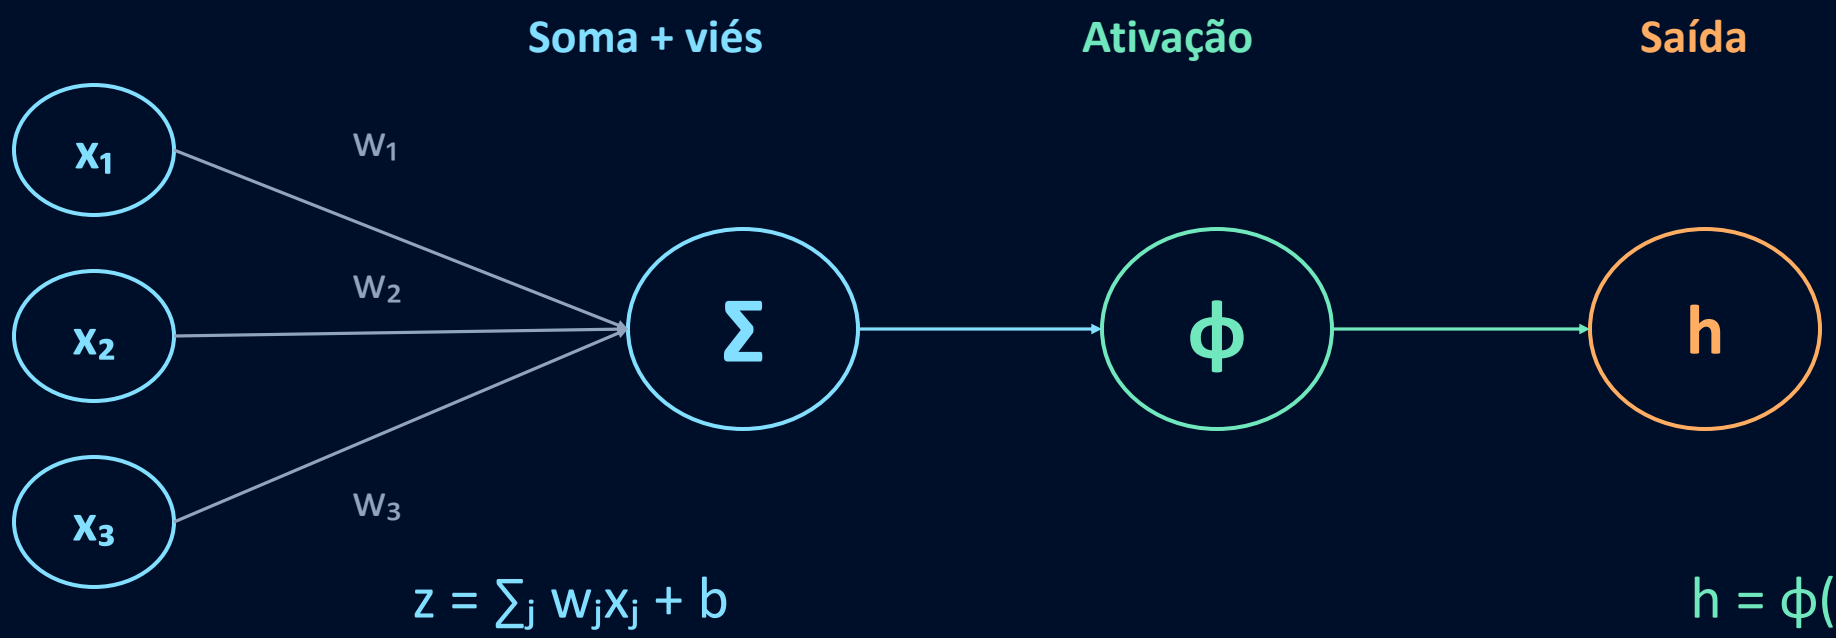
Aprendizado supervisionado

Cada linha associa um vetor de entradas x_t à saída observada y_t.

t	P(t) mm	Q(t) m³/s	Q(t − 1) m³/s	y_t = Q(t + 1) m³/s
1	12	50	47	46
2	0	46	50	49
3	8	49	46	65
4	20	65	49	61

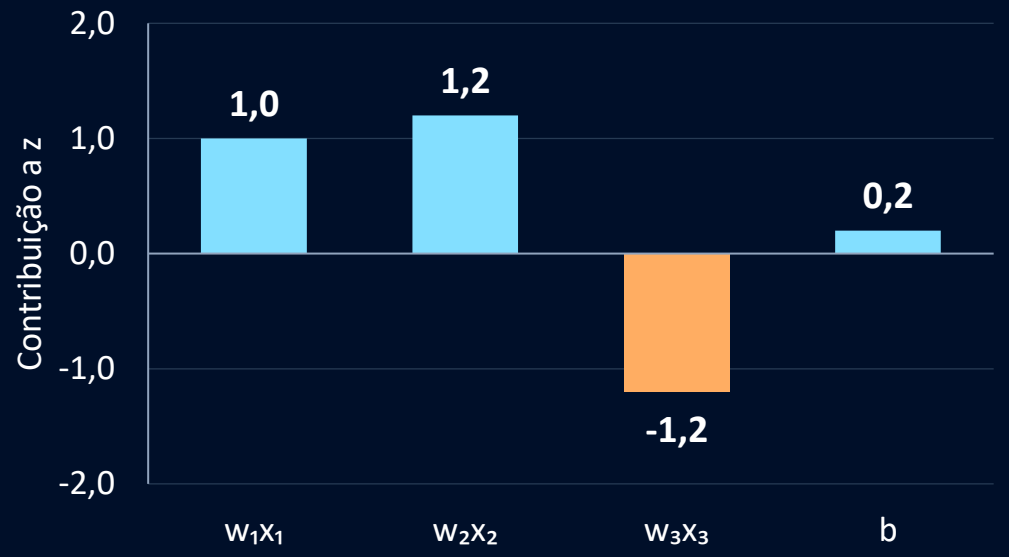
Dados hipotéticos para explicar a organização do dataset.

O neurônio artificial



Pesos e viés: um exemplo numérico

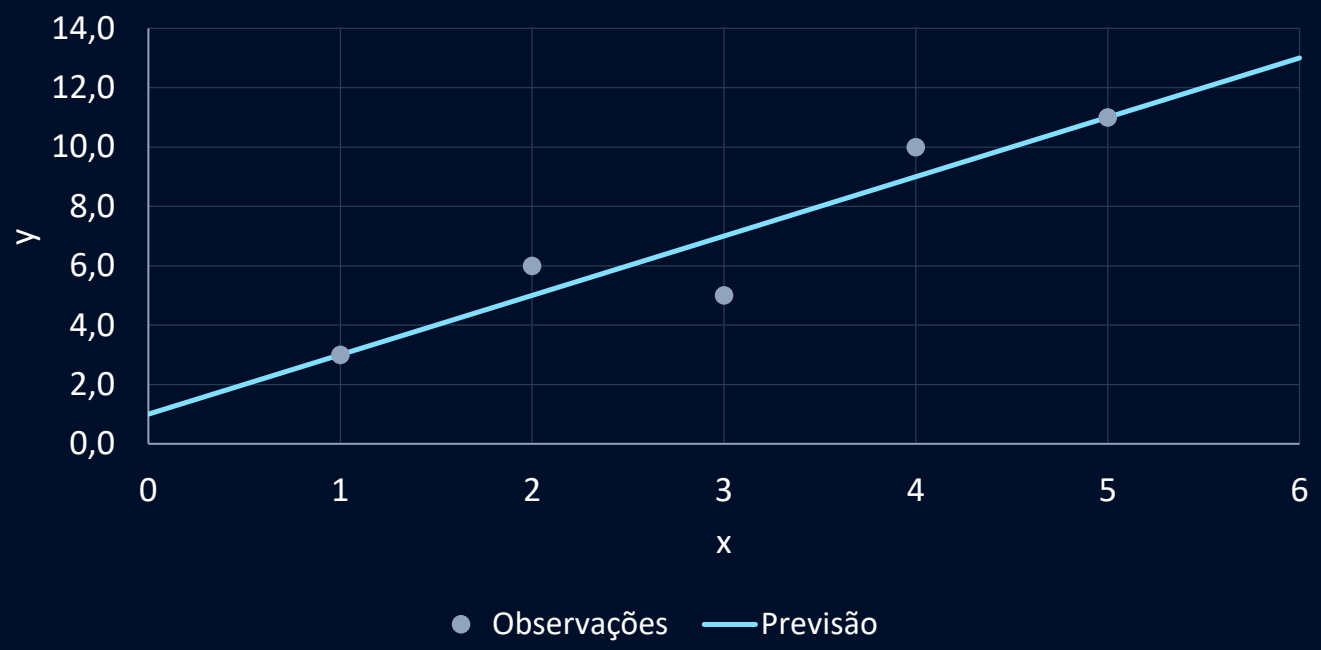
Entrada	x_j	w_j	$w_j x_j$
x_1	2	0,5	1,0
x_2	1	1,2	1,2
x_3	3	−0,4	−1,2



b = 0,2

z = 1 + 1,2 − 1,2 + 0,2 = 1,2

Neurônio linear e regressão



Ativação identidade

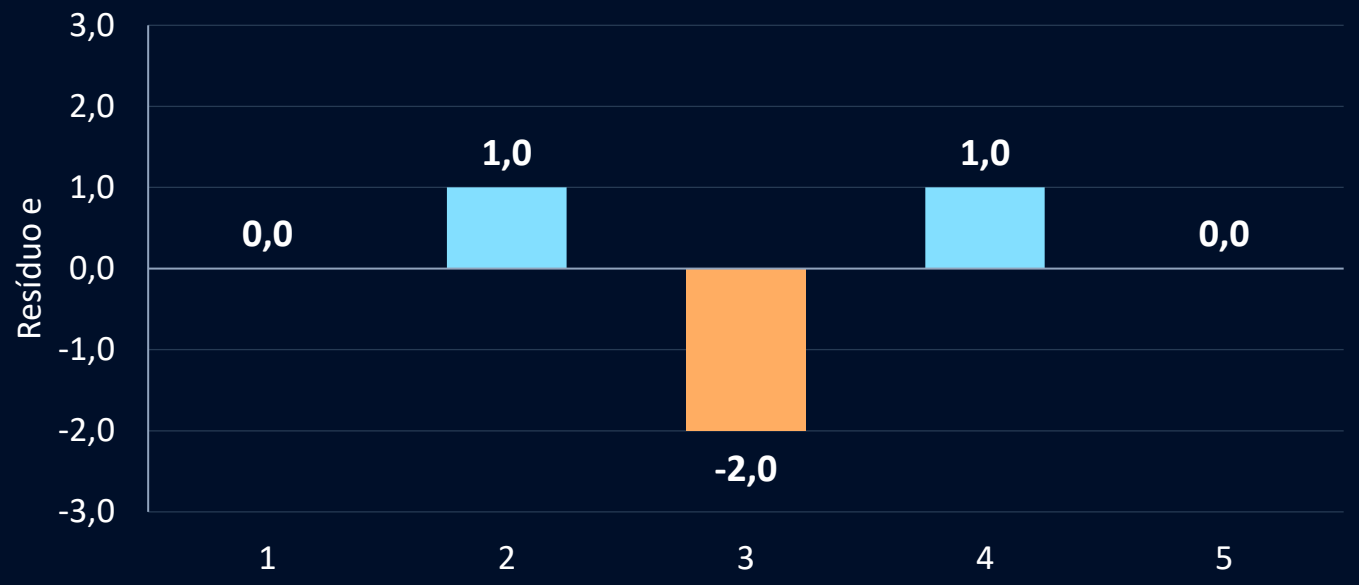
$\phi(z) = z$

$\hat{y} = wx + b$

Neste exemplo:
w = 2 e b = 1

Dados didáticos adimensionais. Cinza: y. Ciano: ŷ.

Resíduo: direção e magnitude



$e_i = y_i - \hat{y}_i$

e > 0

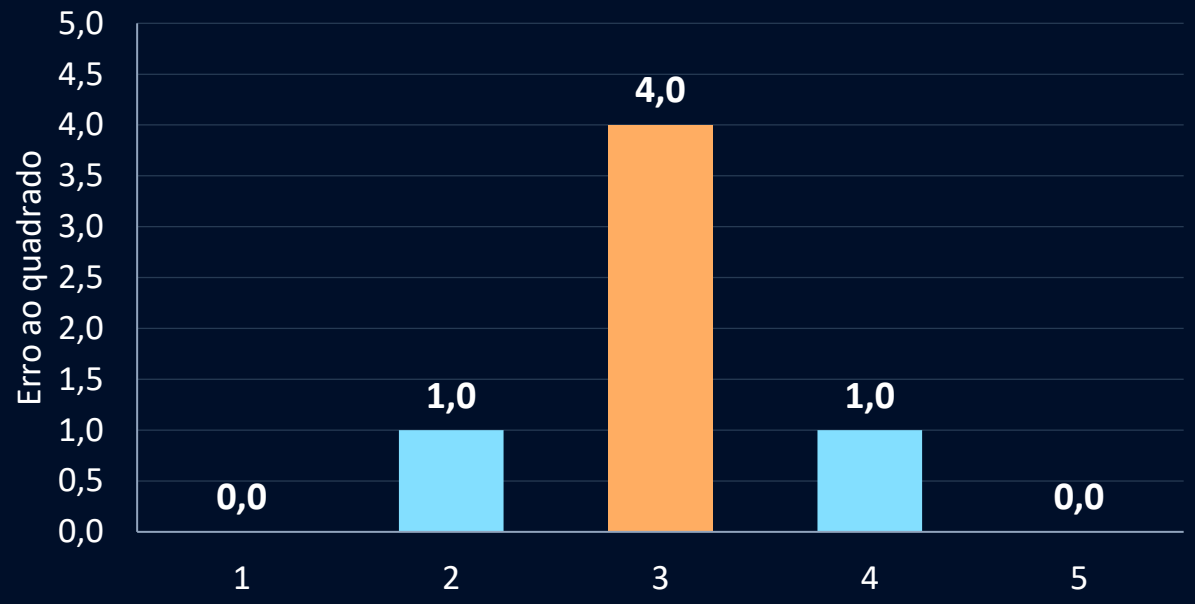
A previsão fica abaixo do valor observado.

e < 0

A previsão fica acima do valor observado.

Mesmo exemplo do slide anterior. O sinal do resíduo segue e = y − ŷ.

MSE e influência dos erros



$$MSE = (1/N) \sum_i e_i^2$$

$$(0 + 1 + 4 + 1 + 0)/5$$

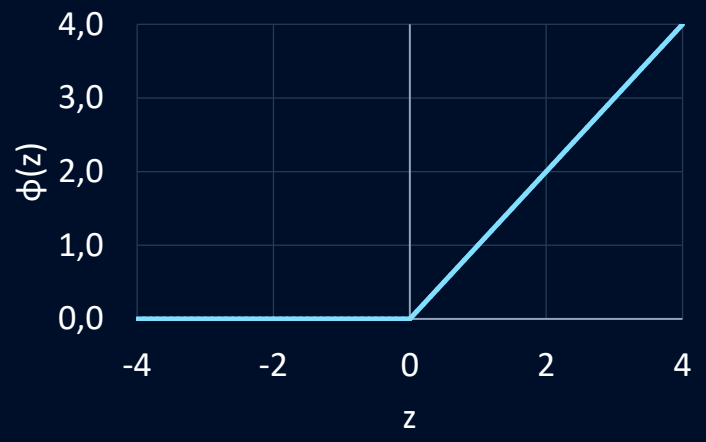
$$MSE = 1,2$$

Um erro duas vezes maior contribui quatro vezes mais.

Exemplo adimensional. Para Q em m^3/s, o MSE tem unidade $(m^3/s)^2$.

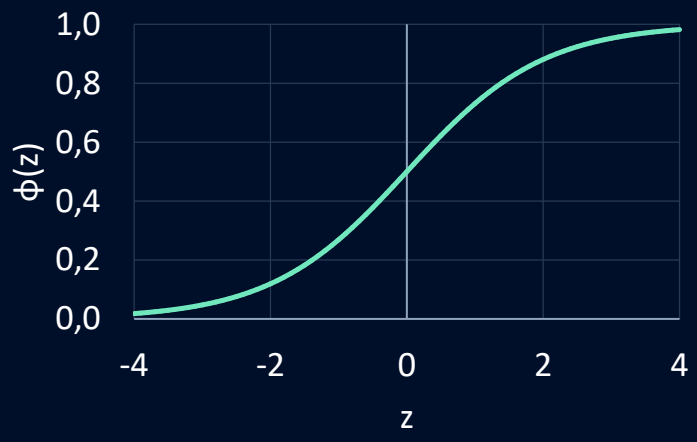
Funções de ativação

ReLU



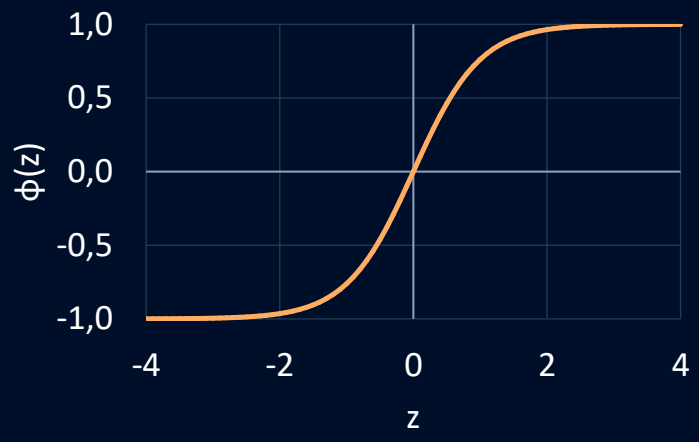
$\max(0, z)$

Sigmoide



$1/(1 + \exp(-z))$

tanh



$\tanh(z)$

Sigmoide e tanh saturam. A ReLU tem derivada zero para $z < 0$.

Camadas lineares e não linearidade

Sem ativação não linear:

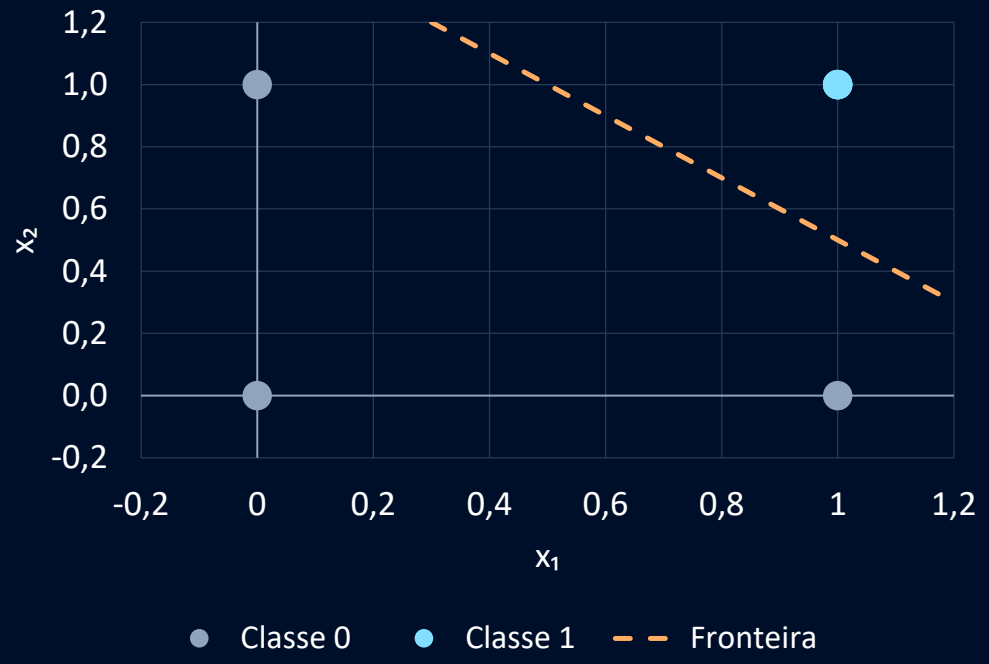
$$\hat{y} = W_2(W_1x + b_1) + b_2 = W_ex + b_e$$

A composição de camadas afins continua sendo uma função afim.

Com uma ativação não linear:

$$h = \phi(W_1x + b_1) \qquad \hat{y} = W_2h + b_2$$

Perceptron e separação linear



Exemplo AND

$z = x_1 + x_2 - 1{,}5$

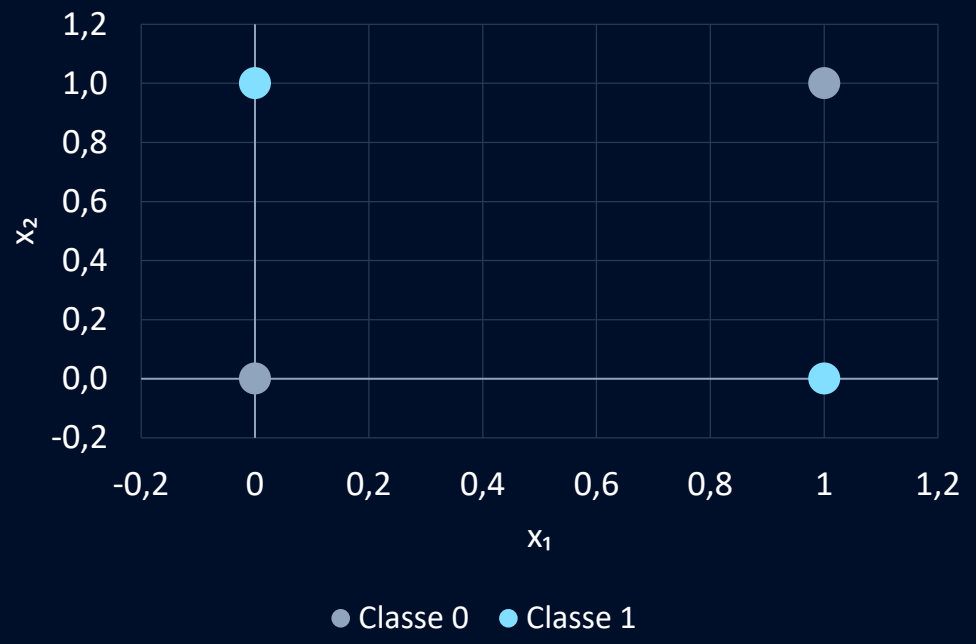
$\hat{y} = 1$ se $z \geq 0$

$\hat{y} = 0$ se $z < 0$

x_1	x_2	AND
0	0	0
0	1	0
1	0	0
1	1	1

A fronteira z = 0 separa as quatro combinações.

O problema XOR

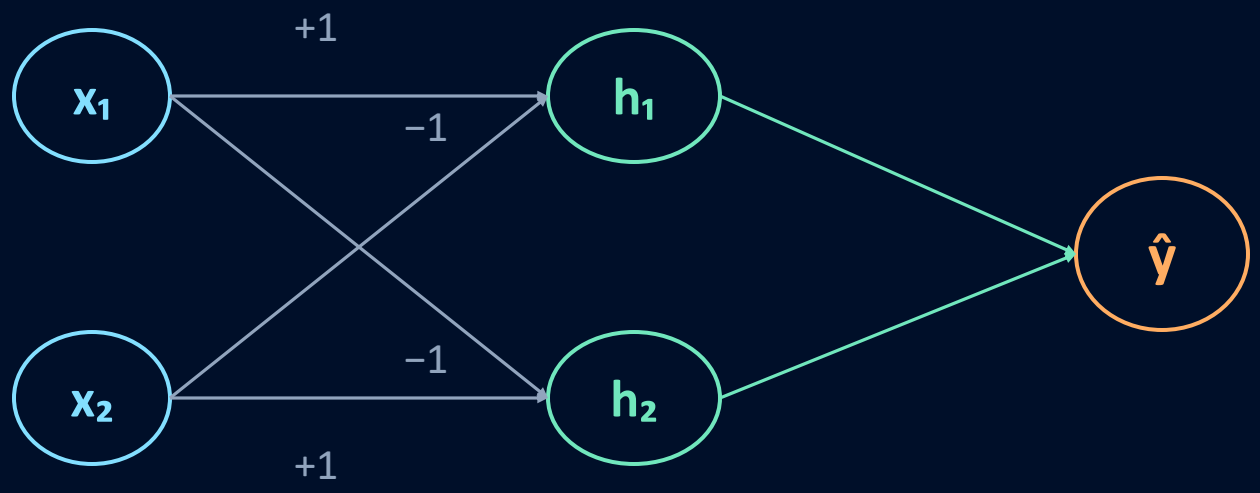


x_1	x_2	XOR
0	0	0
0	1	1
1	0	1
1	1	0

Uma única reta não separa essas classes.

XOR com uma camada oculta

$h_1 = \text{ReLU}(x_1 - x_2)$
$h_2 = \text{ReLU}(x_2 - x_1)$

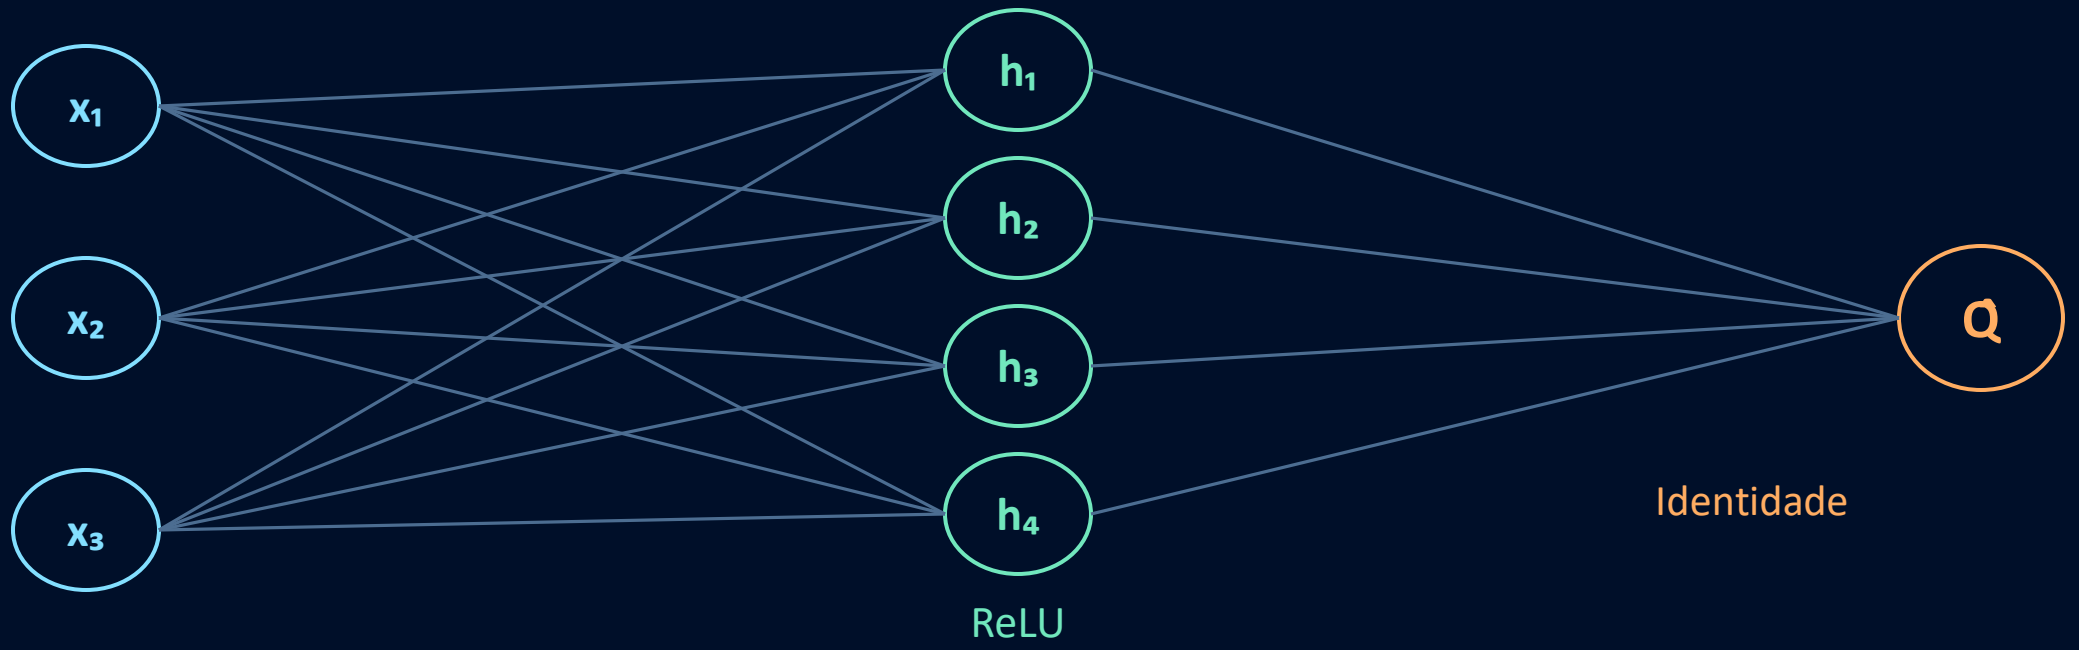


$\hat{y} = h_1 + h_2$

x_1x_2	h_1	h_2	$\hat{y}$
00	0	0	0
01	0	1	1
10	1	0	1
11	0	0	0

Arquitetura de uma MLP

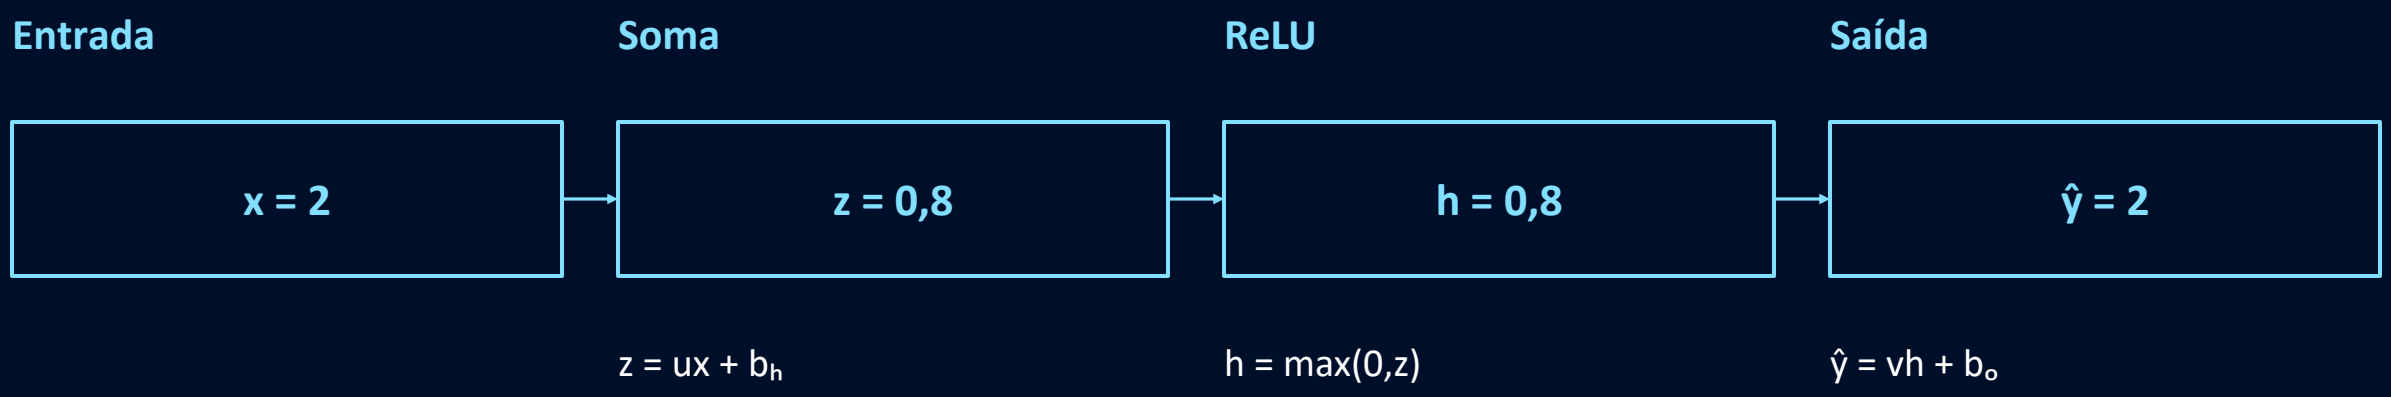
3 entradas **4 neurônios ocultos** **1 saída**



Parâmetros: 3×4 pesos + 4 vieses + 4×1 pesos + 1 viés = 21.

Propagação direta: cálculo da previsão

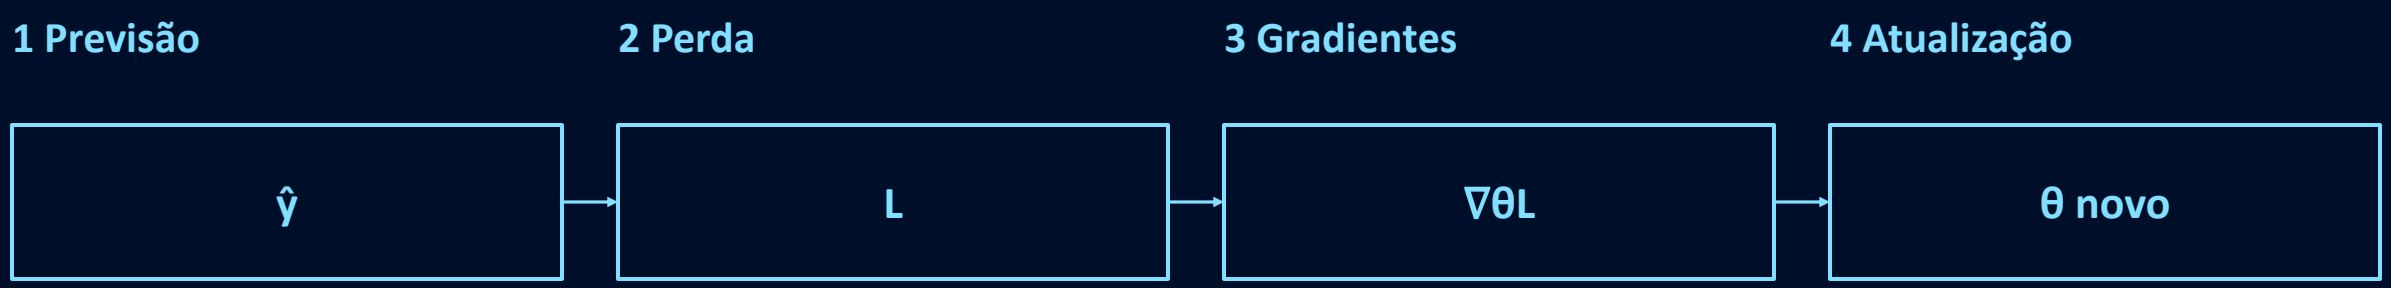
$x = 2 \quad u = 0{,}5 \quad b_h = -0{,}2 \quad v = 2 \quad b_o = 0{,}4$



Observação: $y = 3$

$e = 1 \quad L = e^2 = 1$

O ciclo de treinamento



Propagação direta com os pesos atuais.

Comparação entre a previsão e y.

Retropropagação pela regra da cadeia.

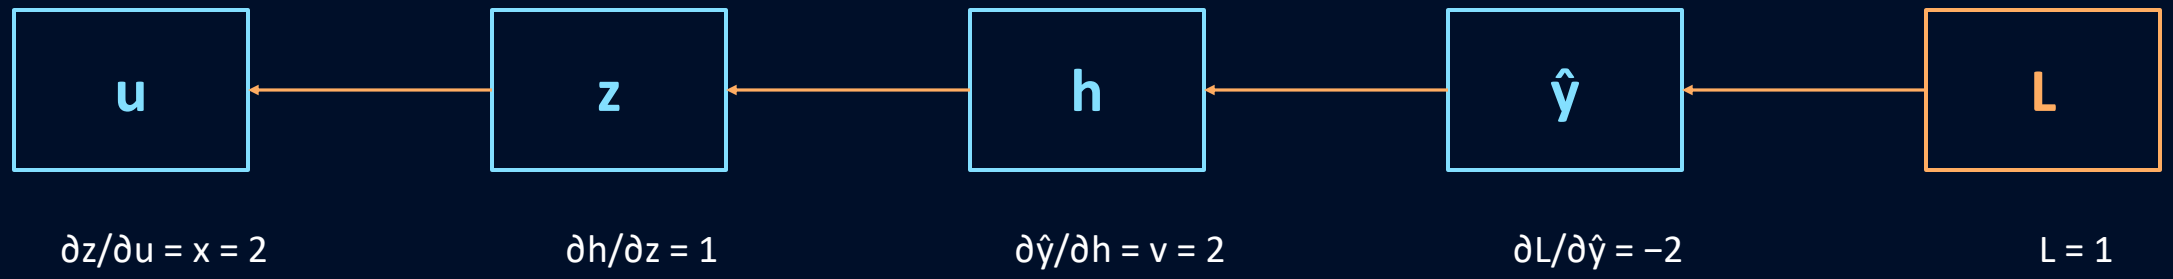
Otimizador ajusta pesos e vieses.

O ciclo se repete ao longo dos lotes e das épocas.

- Lotes/Batch: conjunto de amostras utilizado em uma atualização.
- Época/Epochs: uma passagem completa pelo conjunto de treinamento.

Retropropagação e regra da cadeia

$e = y - \hat{y}$ $\partial L/\partial \hat{y} = 2(\hat{y} - y) = -2e$



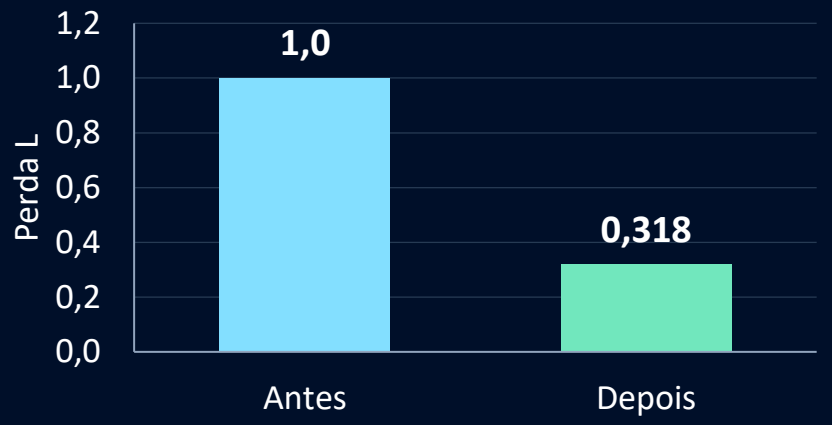
$$\frac{\partial L}{\partial u} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial h} \cdot \frac{\partial h}{\partial z} \cdot \frac{\partial z}{\partial u}$$

$\partial L/\partial u = (-2) \times 2 \times 1 \times 2 = -8$

Atualização dos parâmetros

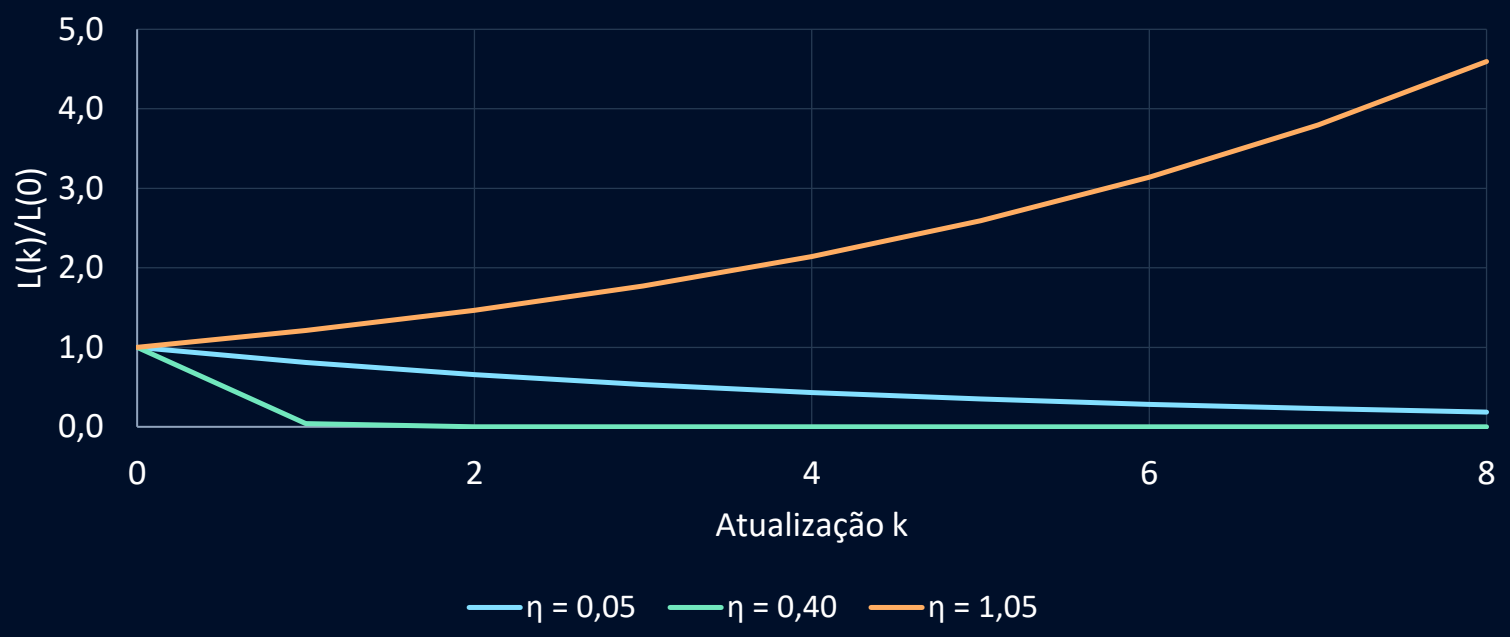
$\theta_{novo} = \theta - \eta \nabla_\theta L \qquad \eta = 0{,}01$

Parâmetro	Antes	Gradiente	Depois
u	0,50	-8,00	0,580
b_h	-0,20	-4,00	-0,160
v	2,00	-1,60	2,016
b_o	0,40	-2,00	0,420



$\hat{y}$ novo = 2,436
L novo ≈ 0,318

Taxa de aprendizado



η = 0,05

Redução lenta.

η = 0,40

Redução rápida neste exemplo.

η = 1,05

Passos instáveis. A perda cresce.

Exemplo exato: $L(w) = (w - 2)^2$, w inicial = −2. Não são taxas recomendadas para uma RNA.

Early stopping e o melhor estado da rede

Época	MSE de validação	Épocas sem melhora
40	0,240	0
41	0,220	0
42	0,225	1
43	0,224	2
44	0,226	3

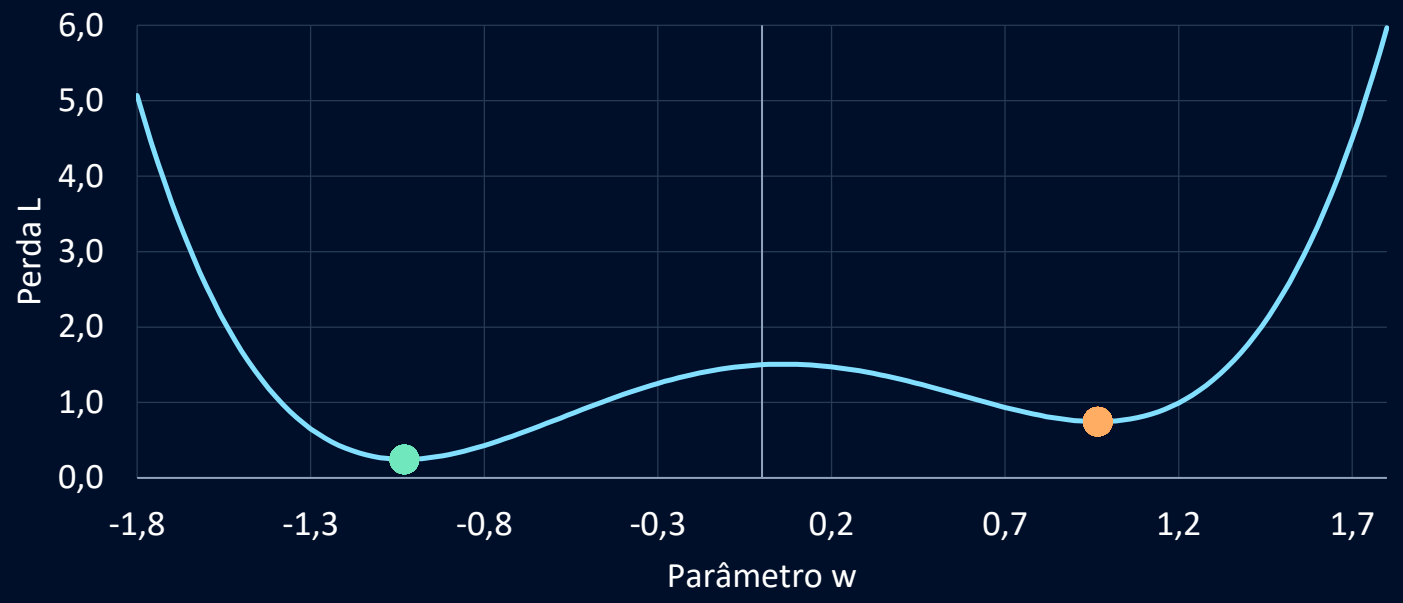
Patience = 3

Parada na época 44.
Retorno aos pesos
da época 41.

A tolerância define o que conta como melhora.

Exemplo hipotético. Regra ilustrada com tolerância zero e preservação do melhor checkpoint.

Paisagem da perda e inicialização



Redes com ativações não lineares costumam ter perdas não convexas.

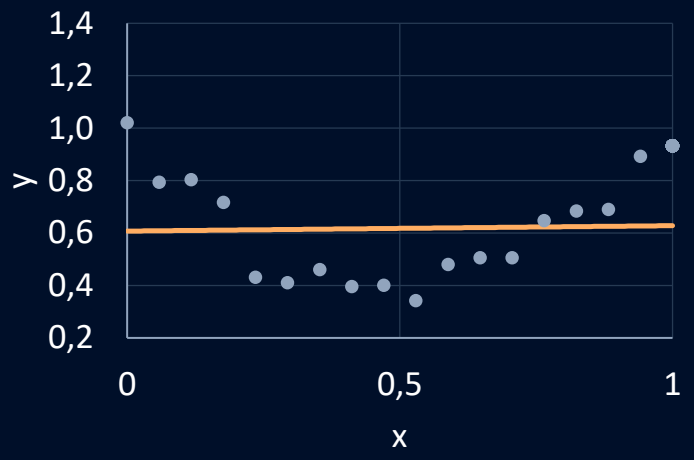
A inicialização influencia o caminho do ajuste.

Gradiente descendente não garante o mínimo global.

Corte esquemático: $L(w) = (w^2 - 1)^2 + 0{,}25w + 0{,}5$.

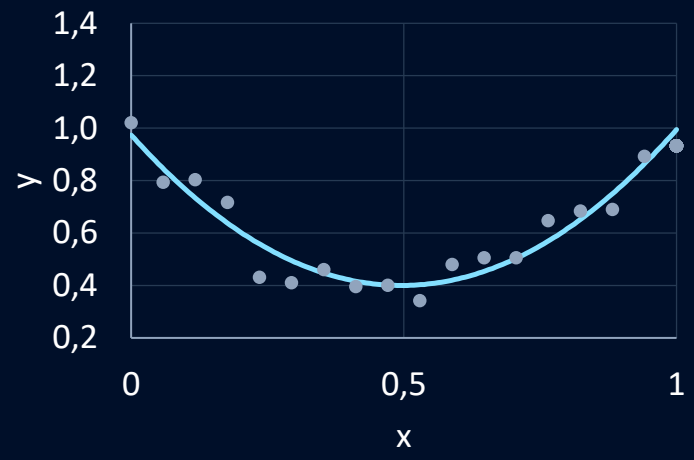
Underfitting e overfitting

Underfitting



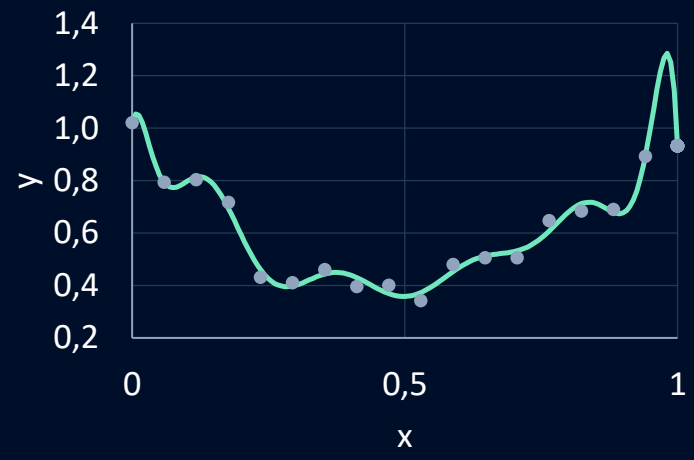
MSE treino: 0,0412
MSE valid.: 0,0342

Ajuste intermediário



MSE treino: 0,0036
MSE valid.: 0,0048

Overfitting



MSE treino: 0,0005
MSE valid.: 0,0125

Dados sintéticos. Comparação com polinômios de graus 1, 2 e 12, como analogia da capacidade.

Validação temporal

A avaliação de uma previsão usa períodos posteriores ao ajuste.



Ajuste dos pesos
e das transformações.

Escolha da rede
e da parada.

Avaliação final
reservada.

Linha do tempo ilustrativa. As larguras não definem uma proporção obrigatória.

Padronização sem vazamento de dados

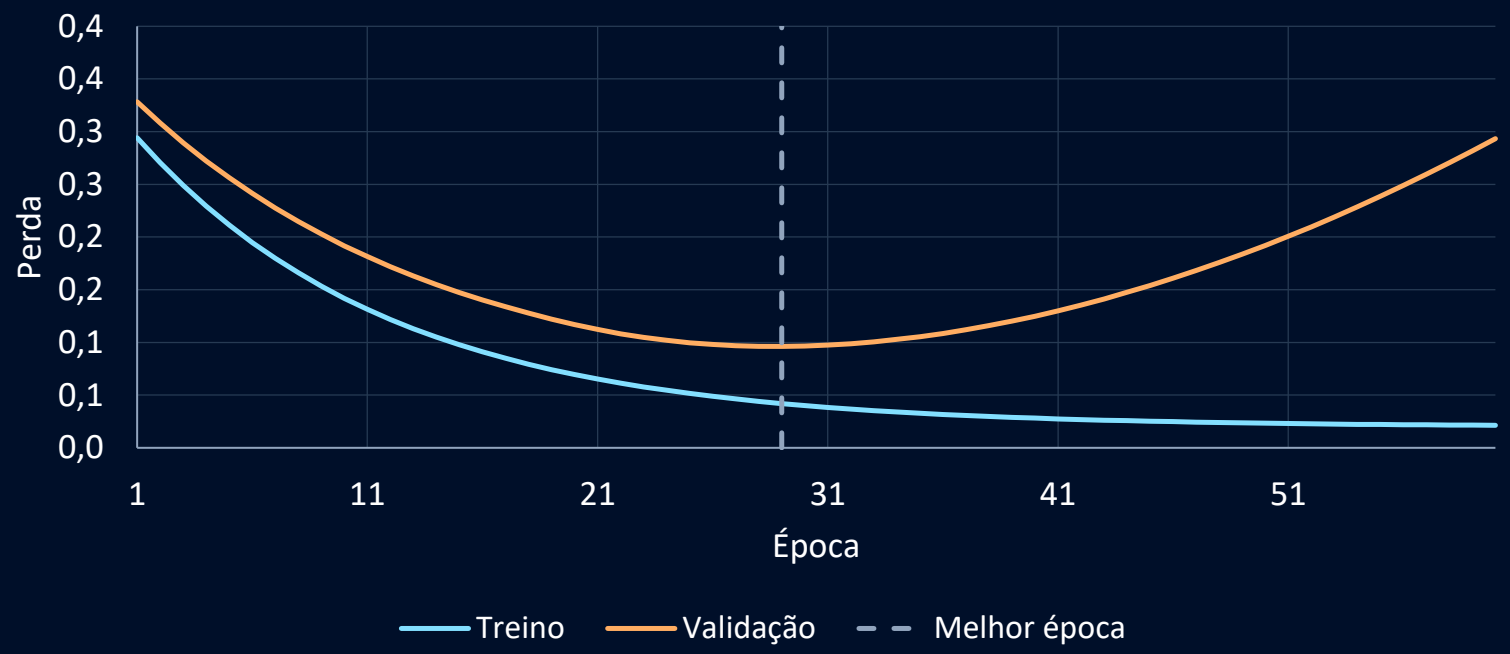
$z_j = (x_j - \mu_j)/s_j$

μ e s vêm do treino.

Variável	μ	s	x	z
P (mm)	10	20	30	1,0
Q(t) (m^3/s)	100	40	140	1,0
Q(t−1) (m^3/s)	100	40	80	−0,5

Escalas hipotéticas. A mesma transformação vale para validação e teste.

Curvas de perda por época



Melhor validação

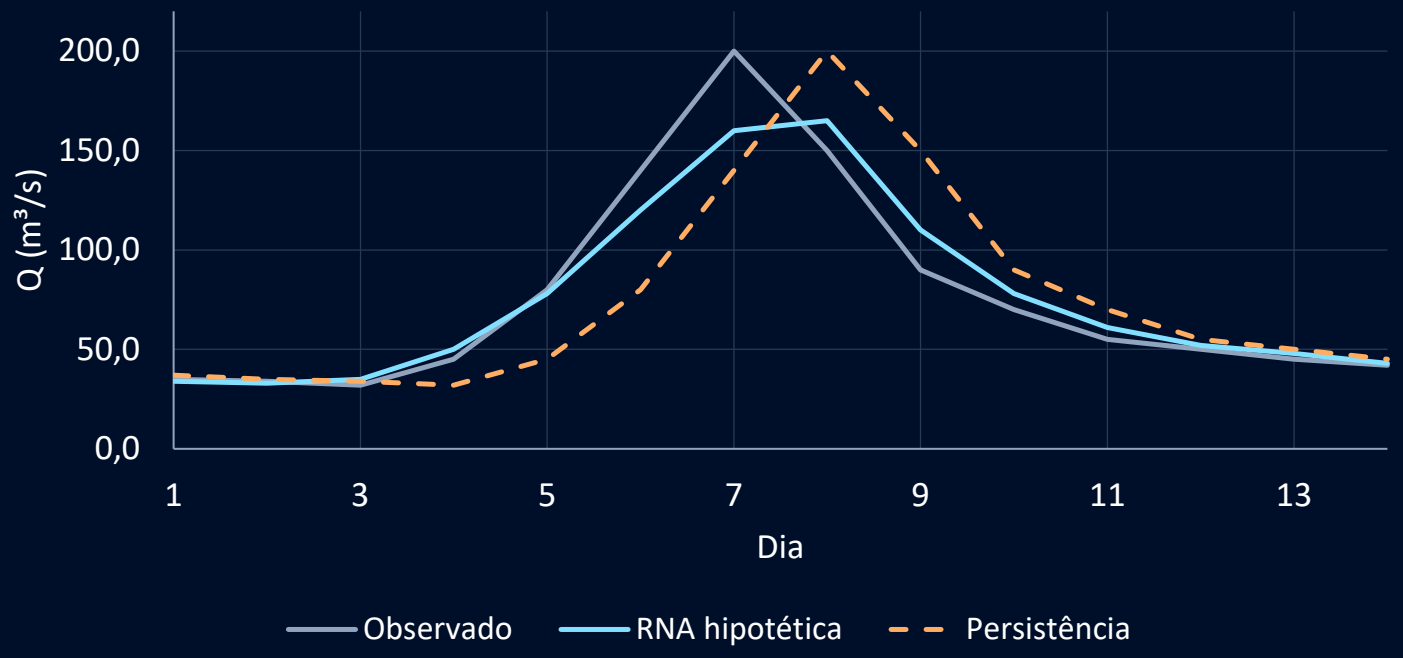
Época 29
Perda ≈ 0,096

Parada antecipada

6 épocas sem melhora.
Parada na época 35.
Restaura a época 29.

Curvas esquemáticas, sem treino real. O teste permanece reservado.

Avaliação da previsão hidrológica

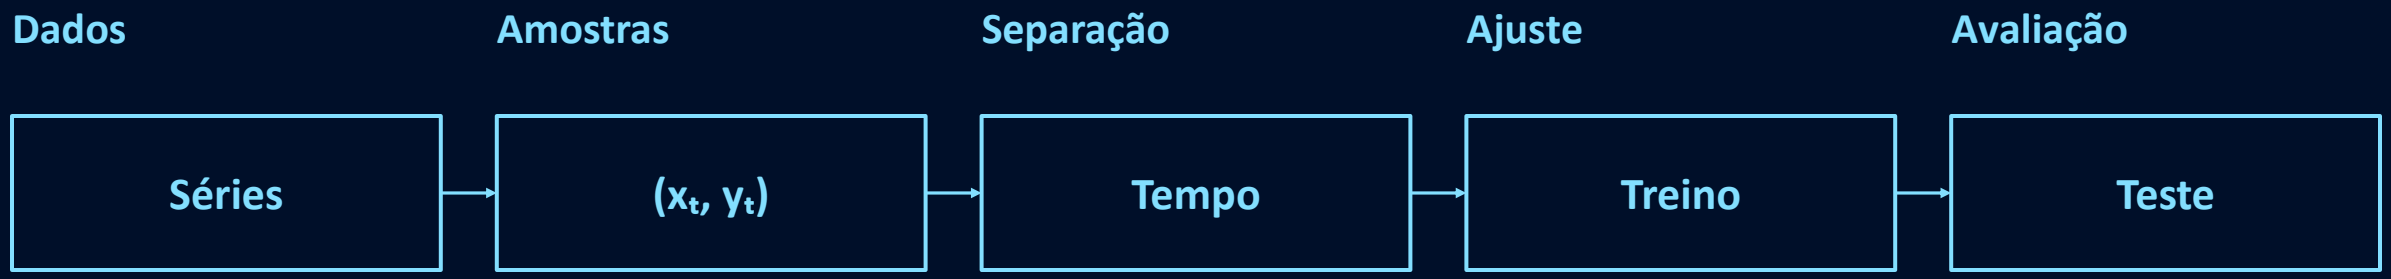


Métrica	RNA	Persist.
MAE m³/s	9,1	23,6
RMSE m³/s	14,1	33,2
NSE	0,920	0,557

O pico, o atraso e o viés completam a leitura das métricas.

Séries sintéticas e previsões hipotéticas. Persistência: $Q(t+1) = Q(t)$.

Fluxo de uma aplicação



Verificar unidades, falhas e datas.

Definir defasagens e horizonte.

Reservar validação e teste futuro.

Treinar pesos; selecionar pela validação.

Avaliação em série de dados reservados

Registro do experimento: entradas, horizonte, arquitetura e critérios de seleção.

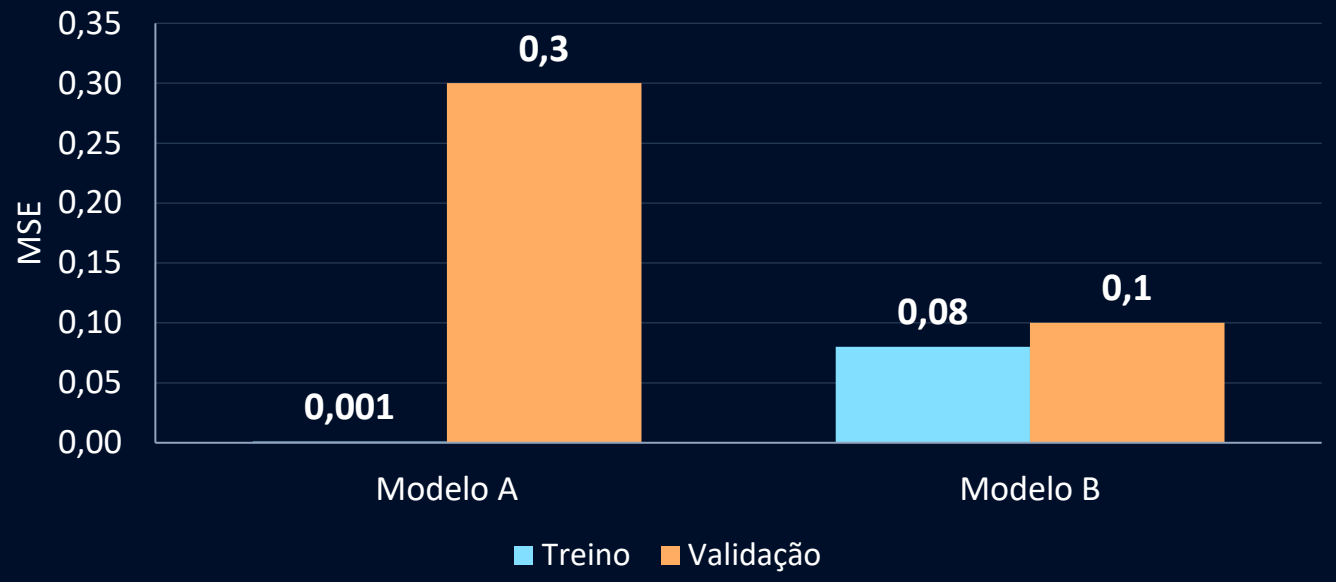
Atividade: uma atualização de um neurônio

Neurônio linear: $\hat{y} = wx + b$

x	y	w	b	η
2	6	1	1	0,05

1. Qual é a previsão e a perda $L = (y - \hat{y})^2$?
2. Quais são os gradientes de w e b?
3. Como ficam w, b e a previsão após um passo?

Discussão: seleção e generalização



Qual modelo você selecionaria para a avaliação final?

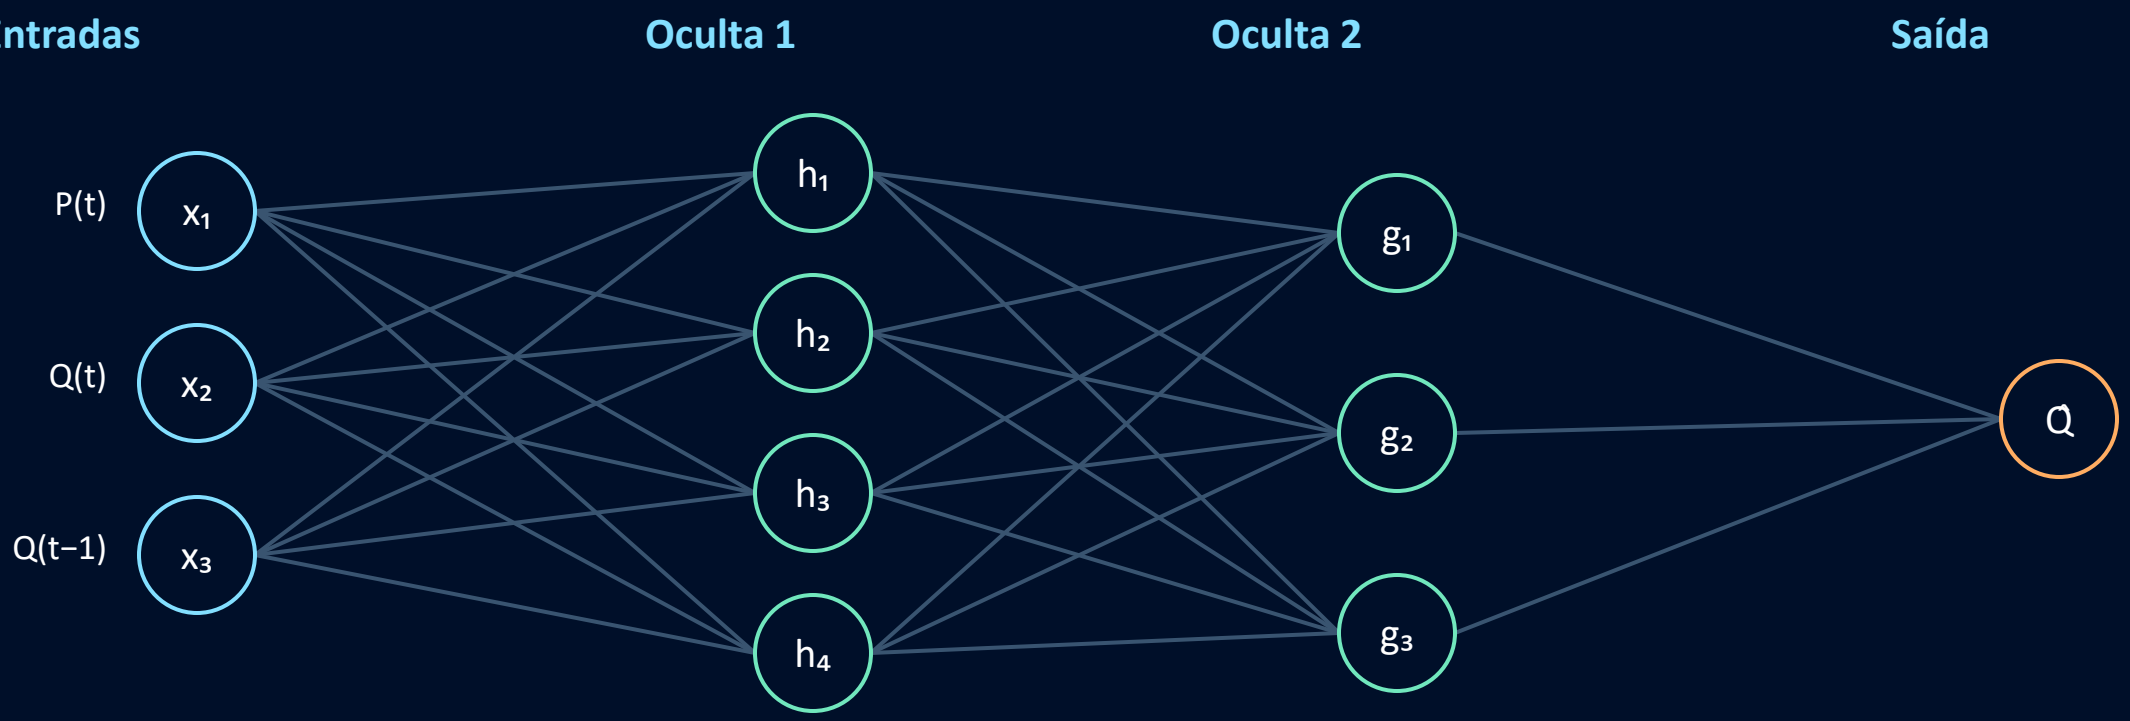
Qual conjunto permanece fora dessa decisão?

Valores hipotéticos. Mesma variável, transformação e conjuntos nos dois modelos.

Conceitos e critérios de uso

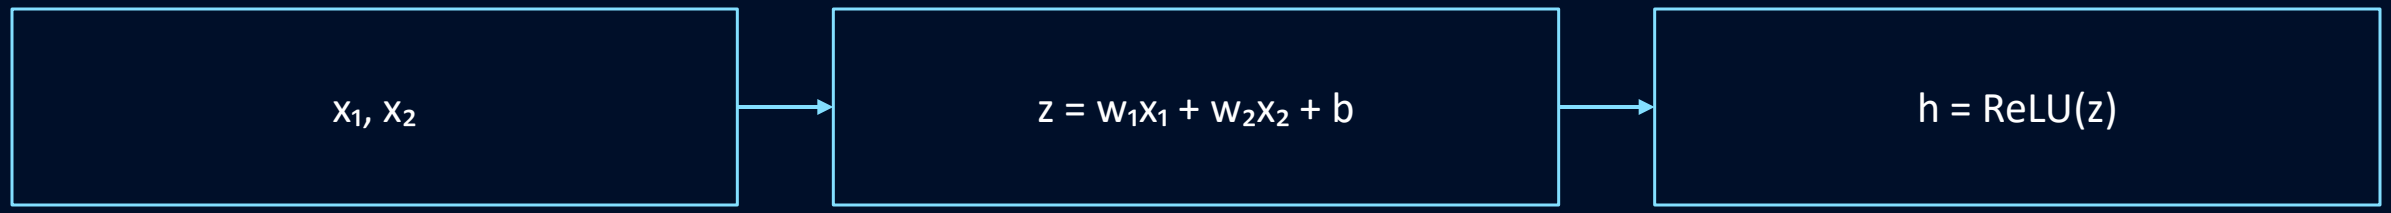
Modelo	Pesos, vieses e ativações definem a previsão.
Aprendizado	A perda e seus gradientes orientam o ajuste.
Generalização	A validação orienta a escolha e a parada.
Aplicação	O teste futuro e a análise física avaliam o uso.

Arquitetura do perceptron multicamadas



A combinação de camadas com ativações não lineares permite representar relações não lineares.

Um neurônio: combinação e ativação

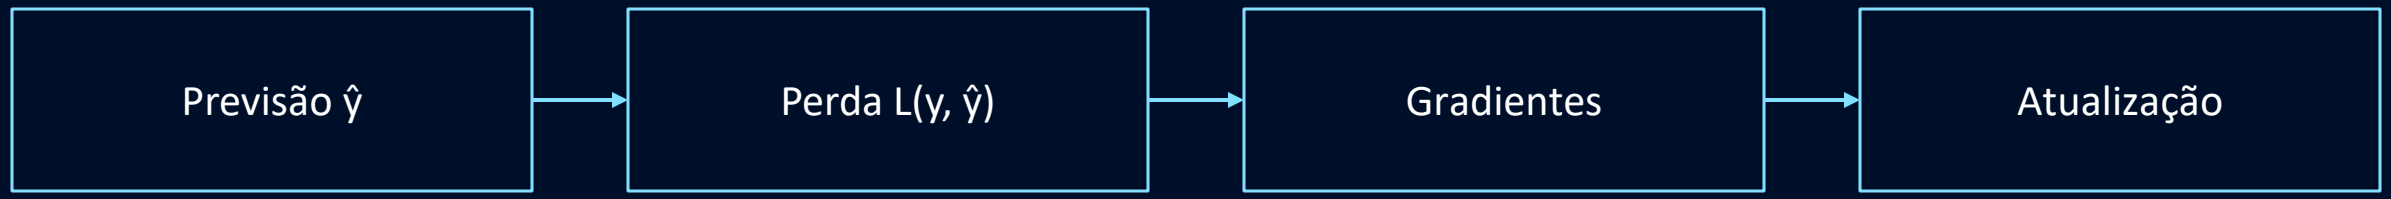


Exemplo com entradas já padronizadas

Entradas	Pesos e viés	Cálculo
$x_1 = 1{,}0$ $x_2 = 0{,}5$	$w_1 = 0{,}8$ $w_2 = -0{,}4$ $b = 0{,}1$	$z = 0{,}8 - 0{,}2 + 0{,}1$ $z = 0{,}7$ $h = \max(0, z) = 0{,}7$

Valores hipotéticos e adimensionais. ReLU(z) = max(0, z).

O ciclo de treinamento



L = média dos erros quadráticos

$w_{novo} = w - \eta \cdot \partial L / \partial w$

Backpropagation calcula gradientes.
O otimizador usa esses gradientes
para modificar pesos e vieses.

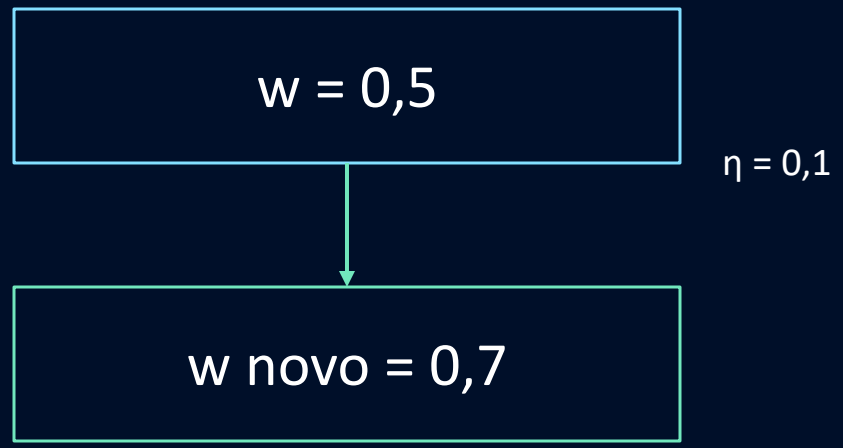
η é a taxa de aprendizado. O exemplo representa a atualização por gradiente descendente.

Uma atualização calculada à mão

Modelo: $\hat{y} = w \cdot x$

$x = 2$, $y = 2$, $w = 0{,}5$
$\hat{y} = 1$
$L = \frac{1}{2}(\hat{y} - y)^2 = 0{,}50$

$\partial L/\partial w = (\hat{y} - y) \cdot x$
$\partial L/\partial w = (1 - 2) \cdot 2 = -2$



$\hat{y}$ novo = 1,4
L novo = 0,18

Exemplo escalar hipotético. w novo = 0,5 − 0,1 × (−2) = 0,7.

Parâmetros e hiperparâmetros

Conceito	Exemplos	Como obter
Parâmetros	Pesos w e vieses b	Aprendizado com o treino
Hiperparâmetros	Camadas, neurônios, η, batch size, regularização	Escolha e comparação na validação

Ao trocar um hiperparâmetro, treinamos uma nova configuração e comparamos seu desempenho no mesmo protocolo.

Diagnóstico orienta a intervenção

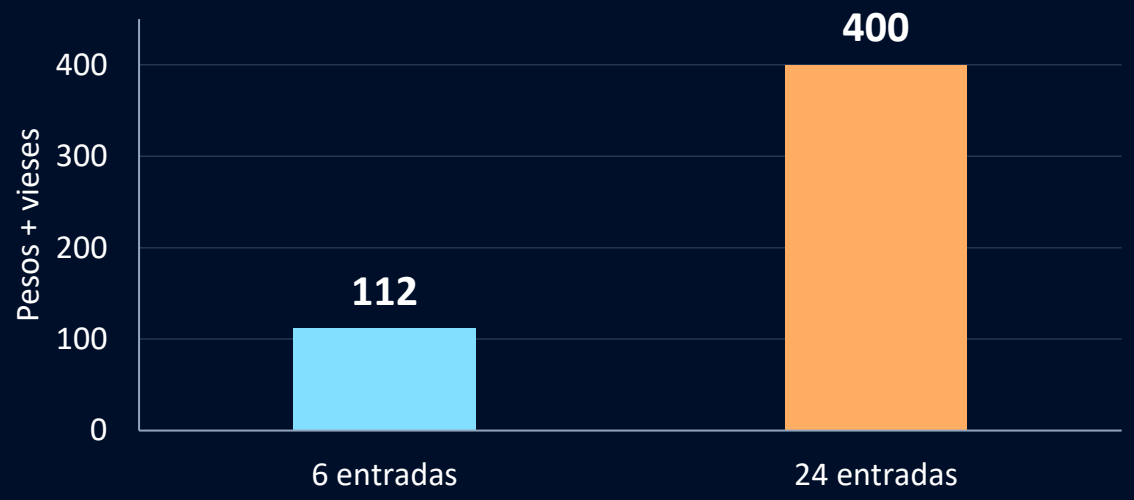
Sinal observado	Hipótese a investigar	Intervenção a comparar
Erros altos no treino e na validação	Capacidade insuficiente, entradas fracas ou treino curto	Melhorar atributos, rever arquitetura e treino
Treino melhora, validação piora	Overfitting	Early stopping, regularização, menor rede
Perda oscila ou cresce	Taxa alta, escala das entradas, outliers ou instabilidade	Padronização, revisão de η e dos dados

As curvas sugerem hipóteses. Cada intervenção precisa de validação.

Seleção de atributos

Mais atributos aumentam a carga de ajuste

Camada inicial com 16 neurônios



$$N = (p + 1) \cdot 16$$

p = 6: 112 parâmetros
p = 24: 400 parâmetros

Entradas redundantes ou irrelevantes podem aumentar o esforço de ajuste sem melhorar a previsão.

Contagem exata para uma camada densa com viés. p é o número de entradas.

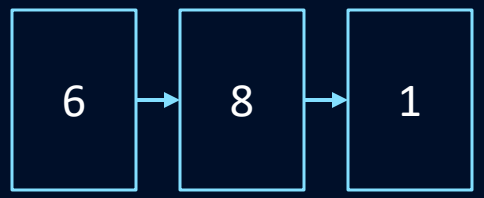
Hiperparâmetros e seus efeitos

Configuração	O que controla	Efeito a observar
Camadas e neurônios	Capacidade e número de parâmetros	Ajuste insuficiente ou overfitting
Taxa de aprendizado η	Tamanho dos passos do otimizador	Velocidade e estabilidade
Batch size	Exemplos por atualização	Custo e ruído do gradiente

Ajuste de hiperparâmetros

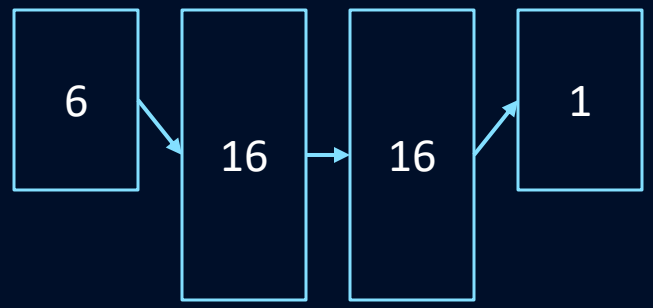
Arquitetura e número de parâmetros

6 – 8 – 1



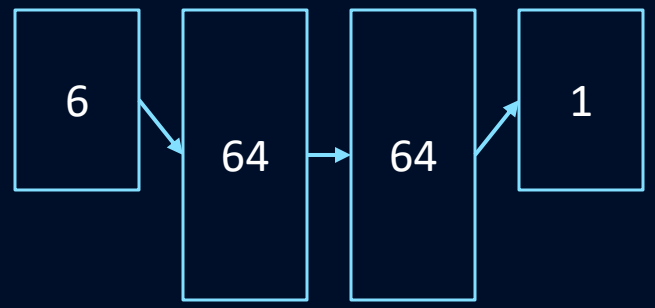
65 parâmetros

6 – 16 – 16 – 1



401 parâmetros

6 – 64 – 64 – 1



4673 parâmetros

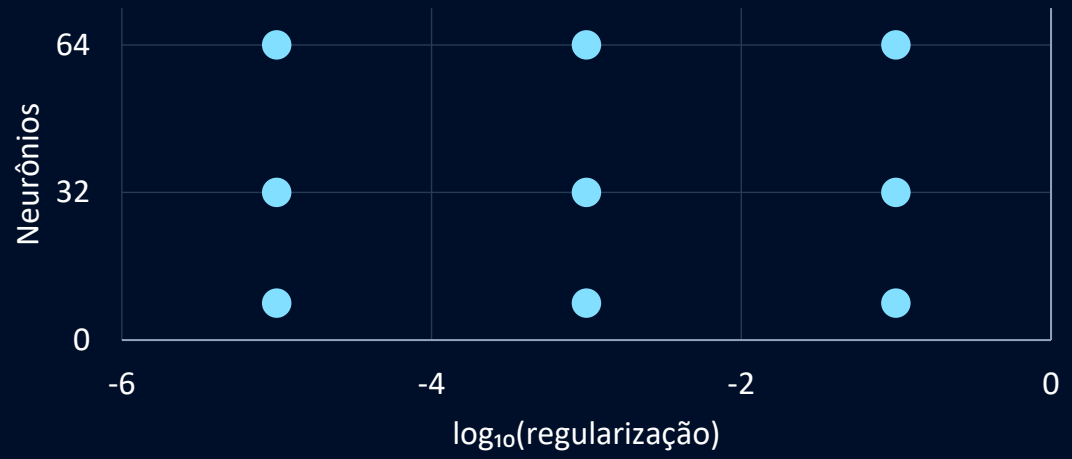
$N = \Sigma\ (n\ \text{anterior} + 1) \cdot n\ \text{atual}$

Redes densas com viés e uma saída. Cada número no diagrama representa neurônios em uma camada.

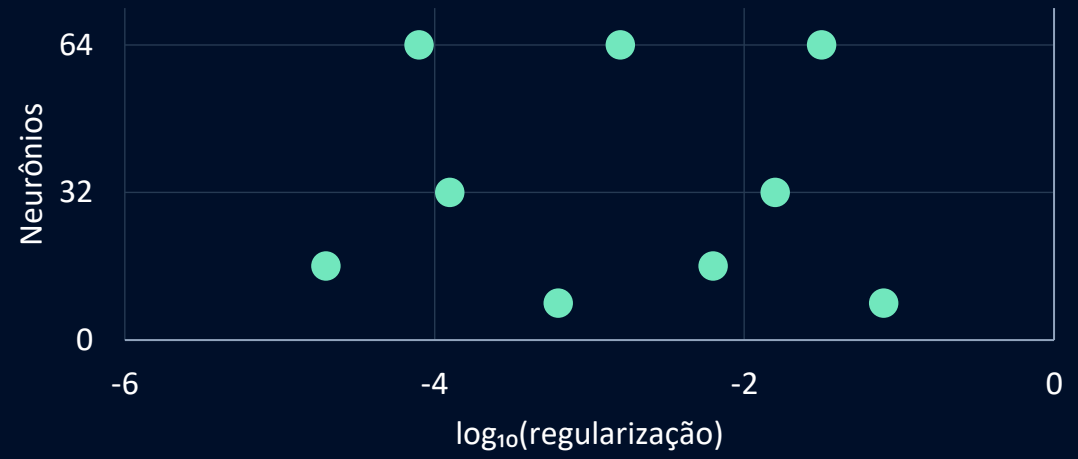
Ajuste de hiperparâmetros

Busca em grade e busca aleatória

Grade: 9 combinações



Aleatória: 9 combinações



Cada ponto exige treinar e validar uma configuração.

Espaço e amostras ilustrativos. Mesma quantidade de candidatos nos dois painéis.

Discussão em sala

Atividade final: melhoria de um modelo de vazão

Cenário: há 8 anos de dados diários, 24 entradas e um MLP com erro baixo no treino e crescente na validação.

1. Como separar os períodos para seleção e avaliação?
2. Qual diagnóstico as curvas sugerem?
3. Que comparação de atributos vale testar primeiro?
4. Como registrar a busca e decidir a configuração?
5. IC da média [98; 102] cobre 95% das vazões futuras?

7 minutos em pequenos grupos. Justificar disponibilidade, validação, custo e tipo de intervalo.

Síntese da aula

Procedimento de melhoria do modelo

Definição do problema

Horizonte, entradas disponíveis
e referência de desempenho.

Diagnóstico do ajuste

Curvas de treino e validação,
erros por regime e qualidade dos dados.

Experimentos controlados

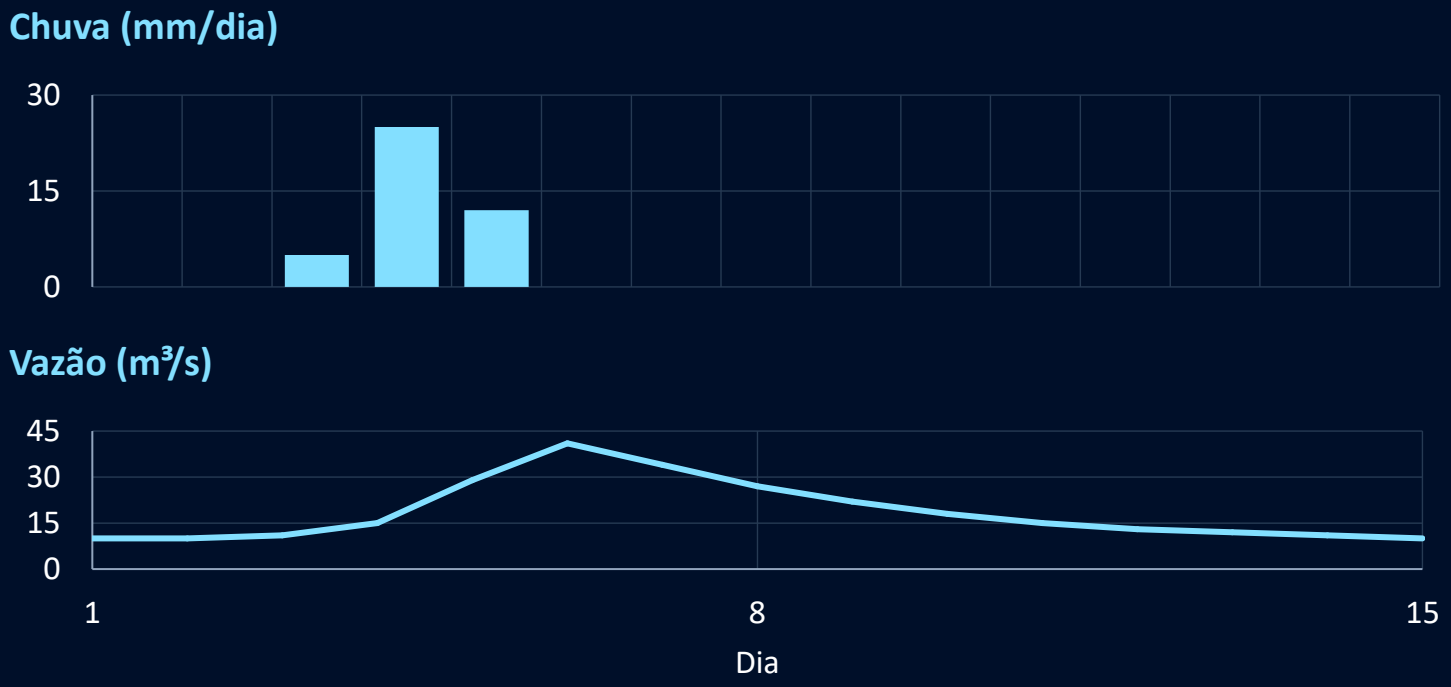
Atributos, componentes, arquitetura
e treinamento em blocos comuns.

Decisão e avaliação final

Erro, estabilidade, custo,
intervalos e teste reservado.

O que está por vir na próxima aula

Memória hidrológica



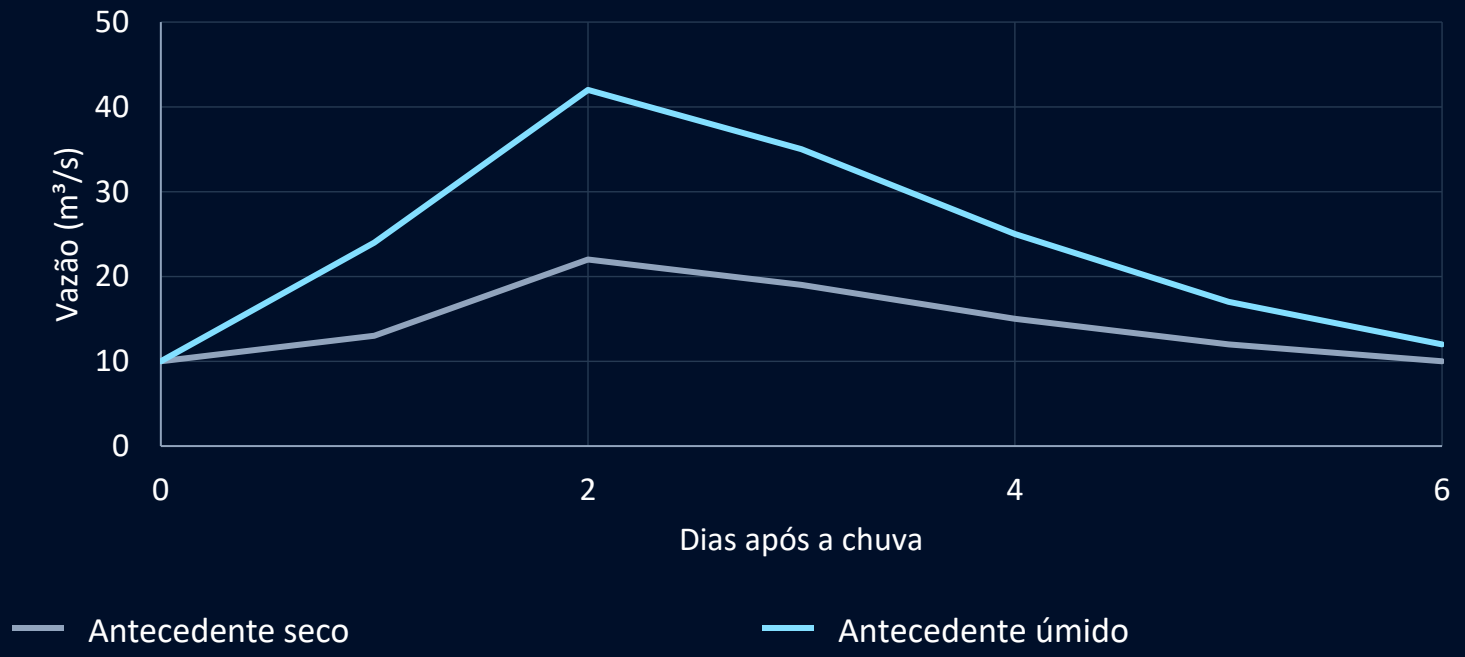
A resposta continua após o evento de chuva.

Armazenamento e trânsito da água conectam o passado ao estado atual da bacia.

Hidrograma sintético. O atraso ilustra memória e não representa uma bacia observada.

Sequências e memória

Mesma chuva, condições antecedentes diferentes



Evento: 30 mm de chuva

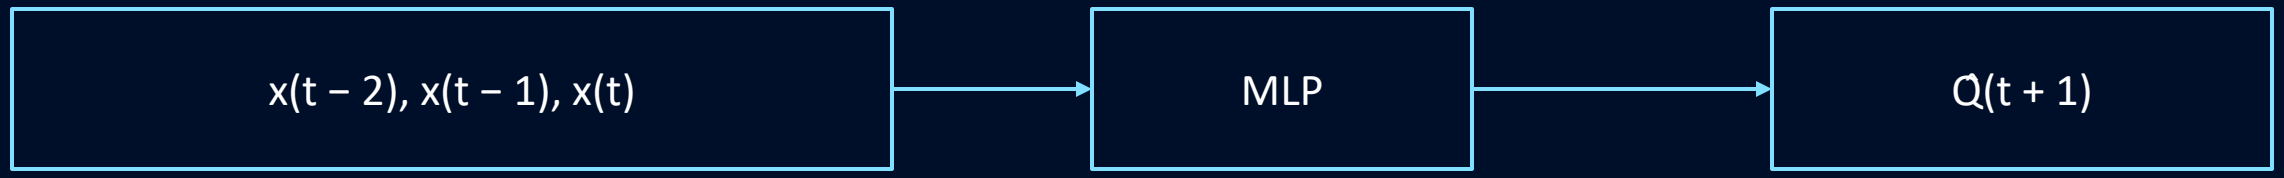
O histórico pode ajudar a representar condições que mudam a resposta.

Qual informação passada você incluiria?

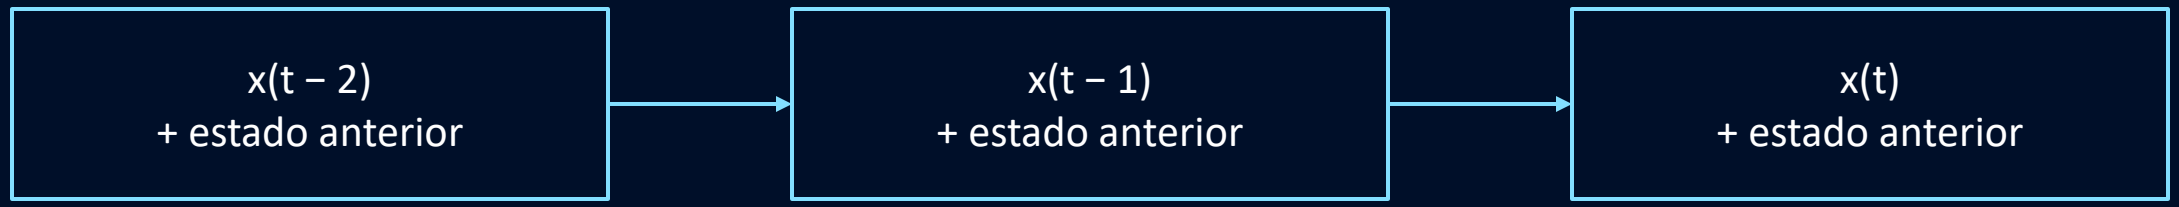
Cenários sintéticos, com o mesmo valor inicial de vazão para isolar a ideia didática.

MLP com defasagens e rede recorrente

MLP: histórico empilhado



RNN: leitura sequencial



Ambas as abordagens podem usar histórico. A recorrência compartilha a transformação ao longo do tempo.

Uma janela de entrada e um alvo futuro

Passo	P (mm)	T (°C)	Q (m³/s)
t − 6	0	20	15
t − 5	2	21	15
t − 4	10	21	17
t − 3	25	20	25
t − 2	12	19	38
t − 1	0	20	31
t	0	22	25

Uma amostra: (7, 3)

7 passos temporais
3 atributos em cada passo

Alvo: Q(t + 1)

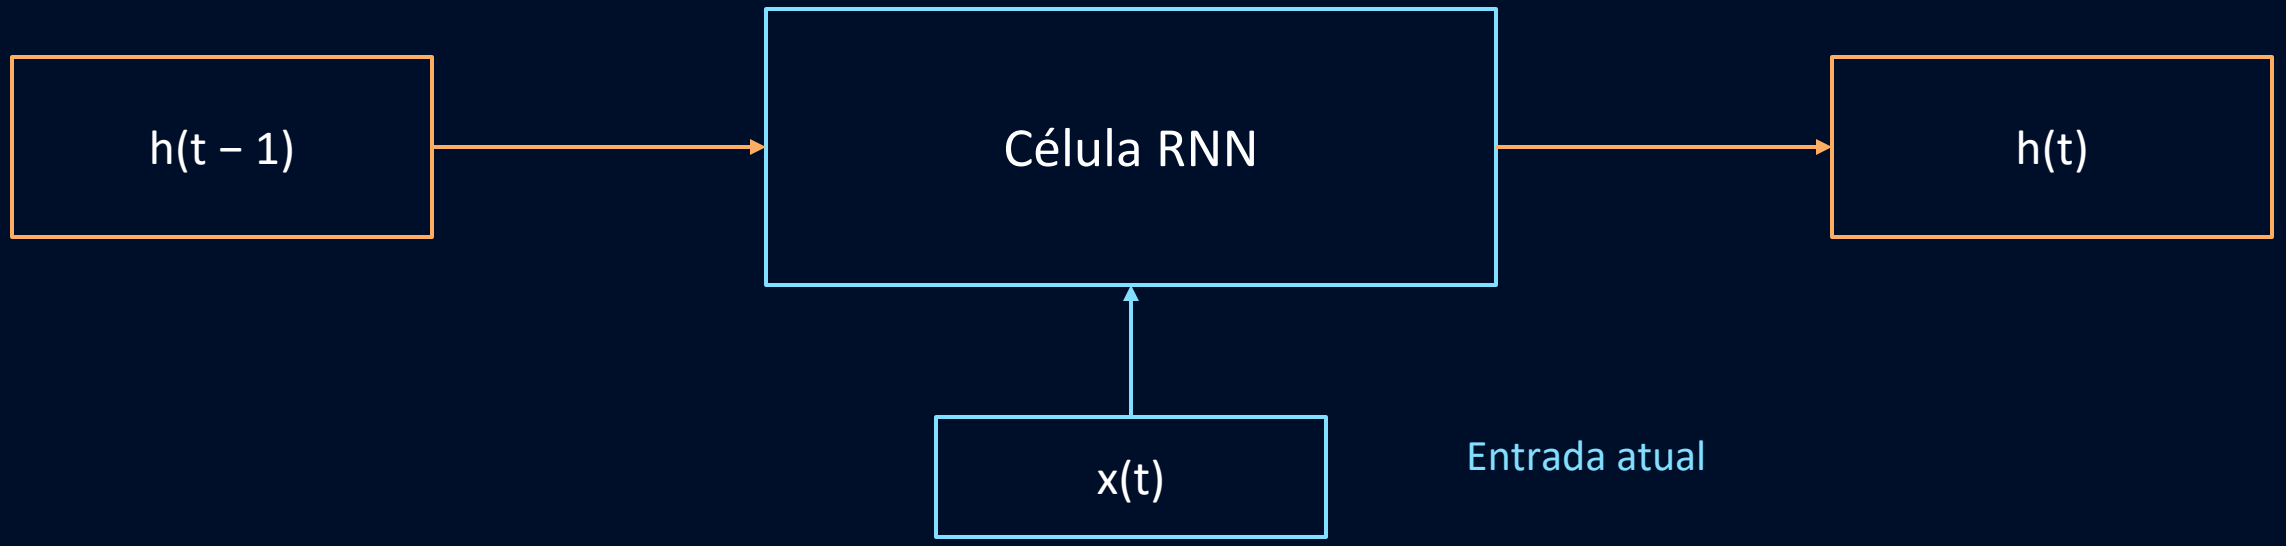
Lote de 32 amostras:
X.shape = (32, 7, 3)

Valores sintéticos. Q(t) só entra se estiver disponível no instante real de emissão da previsão.

Uma célula recorrente simples

A mesma célula reaparece a cada passo temporal.

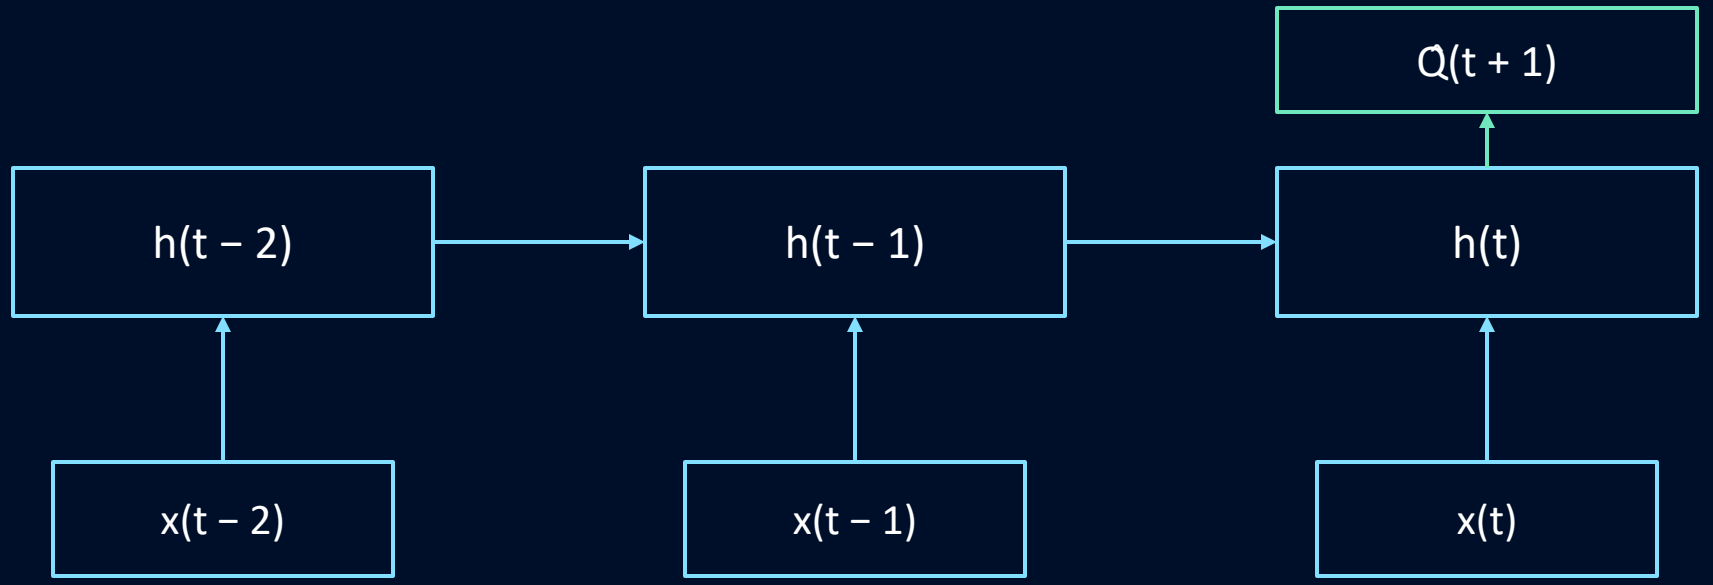
Resumo anterior



Rede neural recorrente

RNN desenrolada no tempo

h inicial = 0



Pesos compartilhados em todos os passos

O desenho mostra três aplicações da mesma célula. Uma janela maior repete a mesma transformação.