Hydro-UAI Course

Transfer Learning com LSTM

Definições, aplicações e estudo de caso

André Ferreira Rodrigues
Bruno Melo Brentan
Rodrigo Perdigão Bezerra
Taís Fonte Boa de Campos Maia



Percurso da aula

01 · CONTEXTUALIZAÇÃO E CONCEITOS	Fonte, alvo e transferência
02 · ESTRATÉGIAS	Zero-shot e fine-tuning
03 · SELEÇÃO	Quantidade e similaridade
04 · ESTUDOS DE CASO	Gao (2026) e Heidari (2026)
05 · EXERCÍCIO PRÁTICO	Resultados e discussão

Contextualização

Por que transferir conhecimento entre bacias?

DESAFIO

Séries de vazão curtas ou inexistentes

Monitoramento hidrológico esparso e espacialmente desigual

→

OPORTUNIDADE

Aprender padrões em bacias monitoradas

→

PERGUNTA

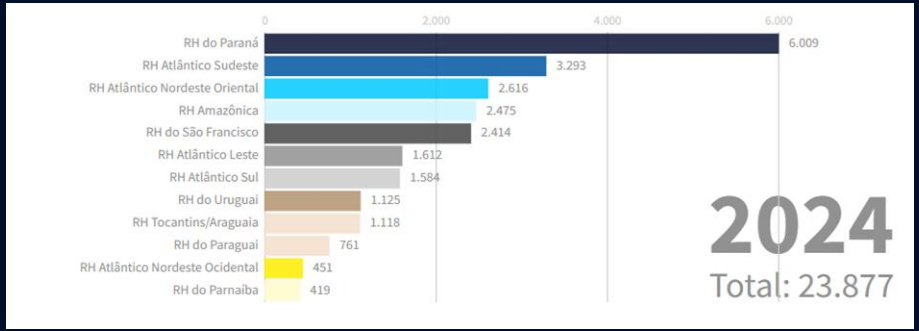
Esse conhecimento pode ajudar no alvo?

Contextualização

Por que transferir conhecimento entre bacias?



Número de estações de monitoramento por RH



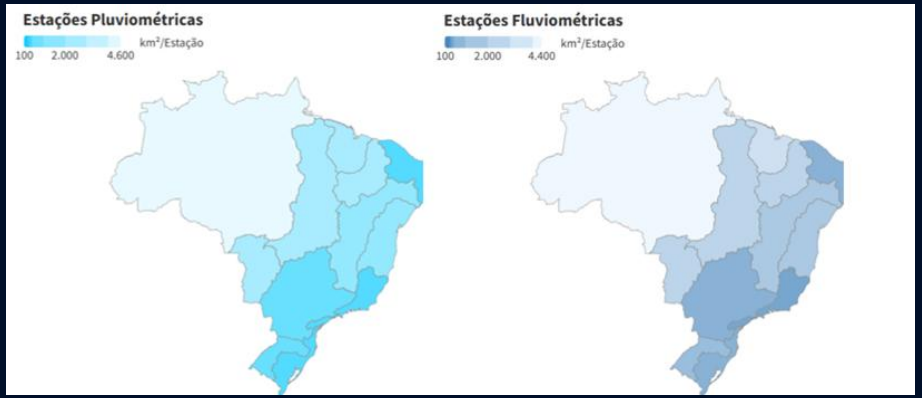
Fonte: ANA (2025)

Contextualização

Por que transferir conhecimento entre bacias?



Densidade de estações por RH



Fonte: ANA (2025)

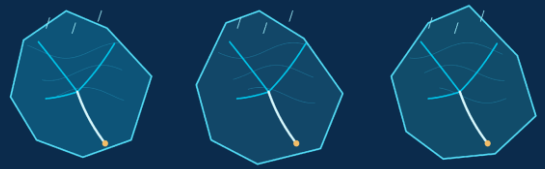
Conceitos

Bacias-fonte × bacia-alvo

A bacia-fonte ensina o modelo; a bacia-alvo é onde queremos estimar a vazão.

01 BACIAS-FONTE

doadoras · source



P e T **Q observada**

Histórico hidrometeorológico e de vazão para o pré-treinamento da LSTM.

LSTM

modelo pré-treinado

aprende padrões

reutiliza conhecimento

02 BACIA-ALVO

receptora · target



P e T **Q escassa / ausente**

P e T locais permitem estimar vazão; Q observada possibilita fine-tuning.

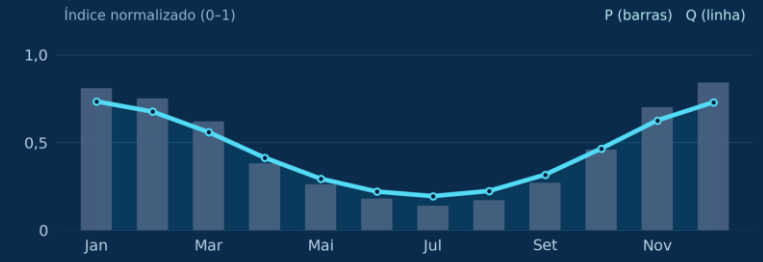
IDEIA-CHAVE **Transferem-se parâmetros e padrões aprendidos, não a série de vazão de uma bacia para outra.**

Conceitos

Bacias diferentes, respostas hidrológicas diferentes

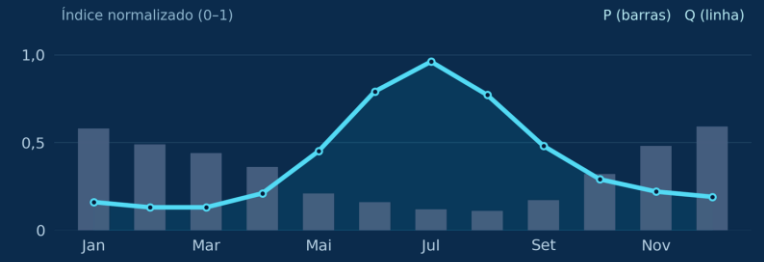
Bacias-fonte (doadoras) e bacias-alvo (receptoras) podem apresentar dinâmicas distintas.

EXEMPLO 1 **Bacia com resposta pluvial**



Picos de vazão relativamente próximos aos períodos de maior precipitação.

EXEMPLO 2 **Bacia com influência nival**



A neve armazena parte da precipitação; o degelo pode deslocar o pico de vazão.

POR QUE ISSO IMPORTA?

A similaridade hidroclimática e fisiográfica favorece a transferência; diferenças podem causar transferência negativa.

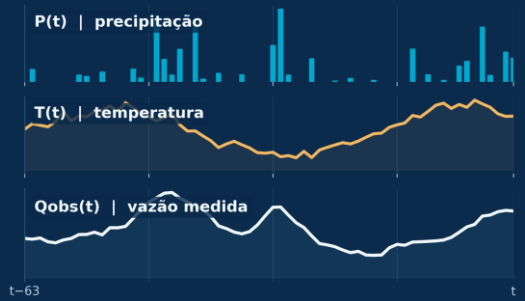
Conceitos

Etapa 1 · Pré-treinamento nas bacias-fonte

A LSTM aprende relações entre sequências de variáveis hidrometeorológicas e a vazão observada.

01 DADOS DAS FONTES

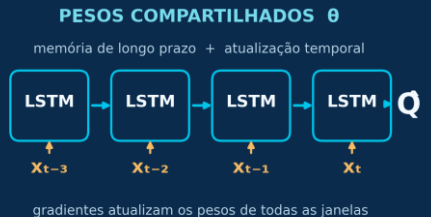
Exemplos de janelas temporais



Várias bacias com P, T e vazão observada. Pares de entrada e saída supervisionam o ajuste.

02 LSTM COMPARTILHADA

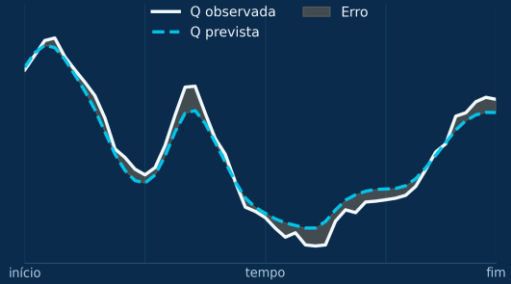
Janelas de entrada → estados ocultos



Os pesos θ são atualizados por backpropagation ao longo do tempo.

03 APRENDIZADO

Previsão e minimização da perda



O erro entre Q prevista e Q observada guia a atualização dos parâmetros.

SAÍDA DA ETAPA 1 — **Modelo-fonte pré-treinado (θ*) que codifica padrões hidrológicos reutilizáveis.**

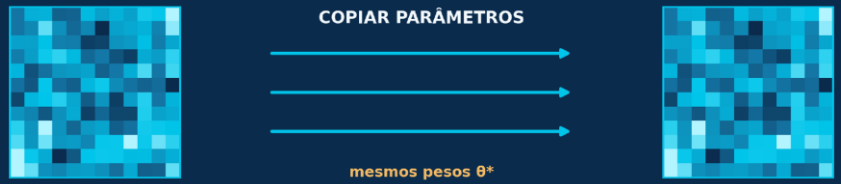
Conceitos

Etapa 2 · Transferência para a bacia-alvo

Transferimos os parâmetros aprendidos (θ*), não os hidrogramas das bacias-fonte.

MODELO-FONTE
parâmetros aprendidos θ*

MODELO-ALVO
inicialização com θ*



θ alvo (inicial) = θ fonte (pré-treinado)

No alvo entram as variáveis preditoras locais (ex.: P e T). A rede produz a estimativa de vazão Q.

ZERO-SHOT	usar θ* sem atualizar pesos no alvo
FINE-TUNING	ajustar pesos com Q observada no alvo

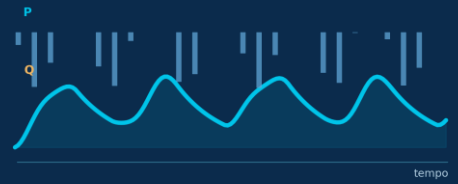
Pré-requisito: entradas, unidades e pré-processamento compatíveis entre fontes e alvo.

Conceitos

Da aprendizagem à aplicação: fluxo completo

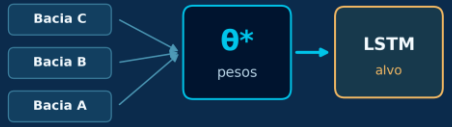
O conhecimento hidrológico aprendido nas fontes é reutilizado para gerar previsões na bacia-alvo.

01 FONTES: APRENDER



Treinamento supervisionado com P, T e Q observada.

02 PESOS: TRANSFERIR



Cópia dos parâmetros θ* para inicializar o modelo-alvo.

03 ALVO: PREVER



Entradas locais (ex.: P e T) geram a vazão estimada.

PRÓXIMA DECISÃO **Manter θ* fixo (zero-shot) ou atualizar os pesos com vazões locais (fine-tuning).**

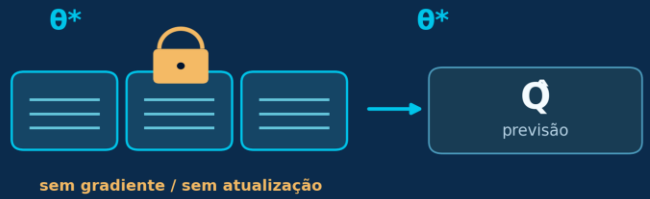
Estratégias

Zero-shot × fine-tuning: o que muda?

Ambos começam da mesma LSTM pré-treinada. A diferença está no uso de vazões locais para atualizar os pesos.

A ZERO-SHOT

Aplicação direta ao alvo



θ alvo = θ* pesos congelados

Não exige Q local para treinamento.

B FINE-TUNING

Adaptação com dados observados no alvo



θ alvo ← ajuste(θ*) pesos atualizados

Exige Q observada para supervisionar o ajuste.

ESCOLHA PRÁTICA Zero-shot: sem calibração local se há poucos dados. | Fine-tuning: adaptação, com risco de sobreajuste

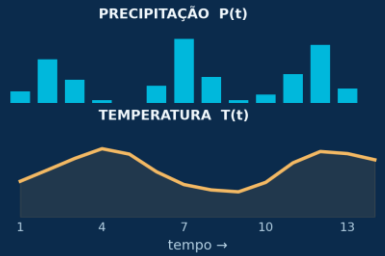
Estratégias

Zero-shot · aplicar sem retreinar

Executar a LSTM pré-treinada na bacia-alvo, mantendo todos os seus parâmetros fixos.

01 ENTRADAS LOCAIS

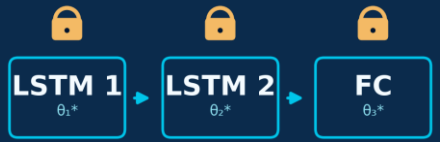
P, T e atributos compatíveis



Sem utilizar Q local para ajuste dos parâmetros do modelo.

02 MODELO CONGELADO

LSTM + FC com pesos θ*



PESOS CONGELADOS · SEM GRADIENTES

Não há backpropagation;
θ alvo permanece igual a θ*.

03 INFERÊNCIA DE Q

Vazão prevista na bacia-alvo



Produz Q̂ usando as entradas disponíveis no período-alvo.

REGRA CENTRAL **θ alvo = θ*** · **Sem gradientes ou atualização dos pesos no alvo.**

Estratégias

Fine-tuning · três níveis de adaptação

Partindo dos pesos pré-treinados θ*, escolhemos quais camadas serão atualizadas com Q observada no alvo.

01 FC APENAS

Adaptação da camada de saída



LSTM fixa; ajusta a relação entre estados ocultos e vazão.

02 FC + ÚLTIMA LSTM

Adaptação da camada recorrente final



Primeiras LSTMs fixas; última LSTM e FC treináveis.

03 REDE COMPLETA

Adaptação de todos os parâmetros



LSTM e FC treináveis; maior flexibilidade e mais parâmetros.

congelada treinável

Mais camadas atualizadas → maior flexibilidade e maior risco de sobreajuste.

Seleção

Bacias-fonte: quantidade ou similaridade?

QUESTÃO CENTRAL

Como selecionar conjuntos de bacias doadoras que favoreçam a transferência para a Ásia Central?

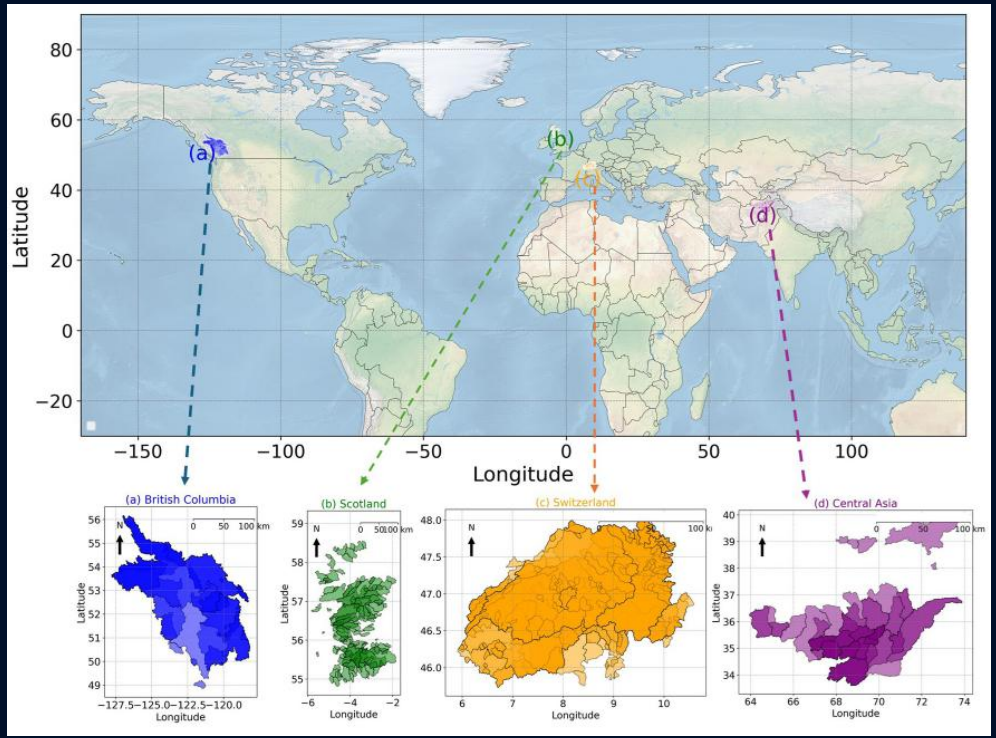
Hipótese discutida: um conjunto hidrologicamente relevante pode superar um conjunto maior e heterogêneo.

Seleção

Área de estudo

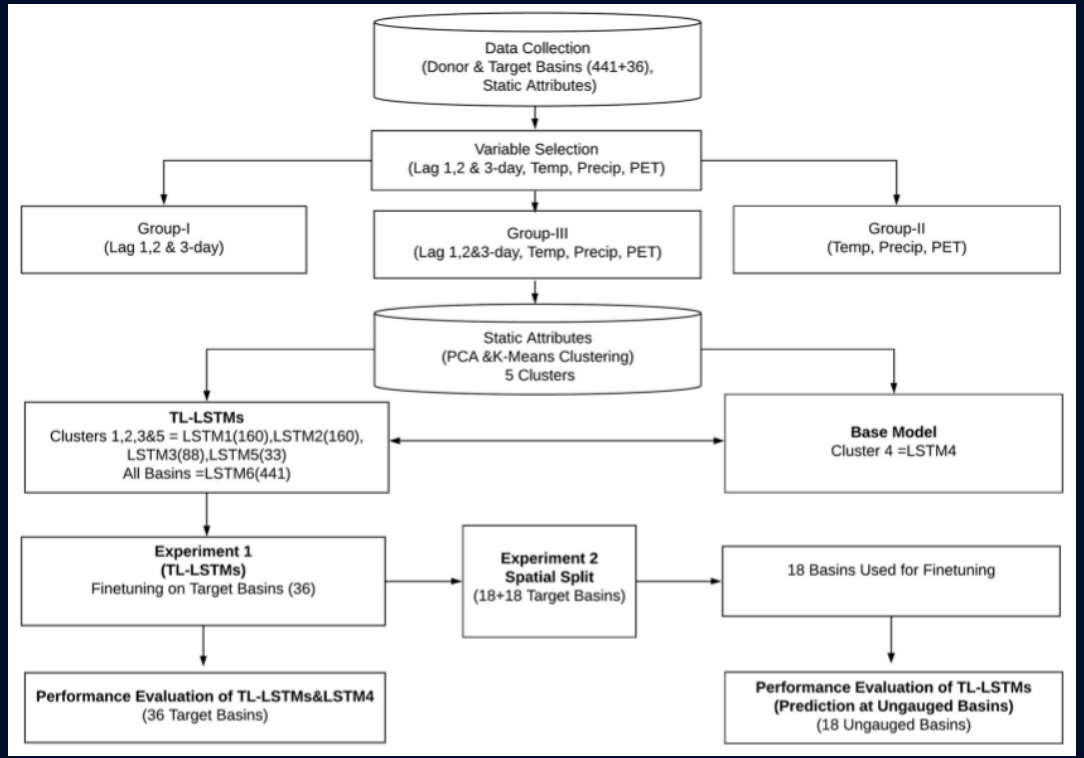
PESQUISA

441 bacias doadoras
36 bacias-alvo
5 clusters hidroambientais



Seleção

Metodologia



Seleção

Quais conjuntos foram comparados?

Metodologia: K-Means

LSTM1	**Cluster 1**	Suíça: bacias de menor altitude
LSTM2	**Cluster 2**	Escócia: resposta predominantemente pluvial
LSTM3	**Cluster 3**	Suíça: bacias alpinas, neve e geleiras
LSTM4	**Cluster 4**	Ásia Central: referência
LSTM5	**Cluster 5**	Colúmbia Britânica: doadoras
LSTM6	**Conjunto amplo**	441 bacias doadoras combinadas

Seleção

Dois experimentos, duas perguntas

Experimento 1: 36 Bacias

Pré-treinamento nas bacias doadoras

↓

Fine-tuning nas 36 bacias da Ásia Central

↓

Comparação com LSTM4 regional

Experimento 2: 18 + 18

Pré-treinamento nas doadoras

↓

Fine-tuning em 18 bacias-alvo

↓

Teste em outras 18 bacias, sem usar suas vazões no ajuste

Seleção

Experimente 1: quais bacias e quantas?

Composição: LSTM3 × LSTM6

LSTM3: Cluster 3, bacias alpinas mais semelhantes à região-alvo

LSTM6: conjunto combinado com 441 bacias

Resultado: LSTM3 apresentou melhor desempenho geral; LSTM6 teve leve redução.

Quantidade: LSTM2

Mesmo modelo, Cluster 2 (Escócia)

Cenário A: 40 bacias-fonte

Cenário B: 160 bacias-fonte

Resultado: aumentar de 40 para 160 piorou a transferência para a Ásia Central.

Seleção

Experimente 2: Diferenças hidroclimáticas e fisiográficas entre bacias-fonte e bacias-alvo

01

Incompatibilidade dos regimes hidrológicos

Bacias de treinamento predominantemente pluviais versus bacias-alvo influenciadas por neve e geleiras.

02

Desempenho variável conforme a bacia

Baixas vazões: fluxos artificiais na estiagem e picos não capturados; bacias extensas: heterogeneidade espacial.

03

Similaridade hidrológica favorece a transferência

LSTM3 superou LSTM2: bacias escocesas do Cluster 2 diferem do clima e relevo das bacias-alvo.

A representatividade hidroclimática das bacias-fonte é mais importante do que apenas aumentar sua quantidade.

Seleção

O que podemos aprender com o estudo?

01 **Similaridade > quantidade**

Bacias semelhantes podem transferir conhecimento mais relevante.

02 **Mais bacias ≠ melhor modelo**

A inclusão de doadoras pouco relevantes pode reduzir o desempenho.

03 **Agrupamento estratégico**

PCA e K-Means orientam a formação de conjuntos de bacias-fonte.

04 **Dados regionais fazem diferença**

Fine-tuning em 18 bacias beneficiou previsões nas 18 não monitoradas.

05 **Entradas dependem do regime**

Vazões defasadas e forçantes meteorológicas têm efeitos regionais distintos.

Estudos de caso

Gao et al. (2026)

Multi-Source Adaptive-Fusion Transfer Learning for Streamflow Forecasting in Data-Scarce Catchments

Heidari et al. (2026)

Probabilistic Sub- Daily Streamflow Forecasting in Data- Scarce Catchments Through a Zero- Shot Inductive Transfer Learning Approach

Estudos de caso

Por que repensar a transferência de conhecimento entre bacias?

PROBLEMA

- Bacias-alvo possuem poucas observações de vazão.
- Usar muitas bacias-fonte pode incluir informações pouco relevantes.
- A fusão convencional na entrada pode não aproveitar o conhecimento complementar das fontes.

PROPOSTA

Desenvolver a MSAF-TL: selecionar fontes por similaridade dos regimes de vazão e combinar adaptativamente os conhecimentos aprendidos em cada fonte.

Pergunta central: poucas fontes bem selecionadas e bem combinadas podem melhorar a previsão de vazões?

Estudos de caso

Metodologia

BASE DE DADOS

4 bacias-alvo

668 fontes candidatas por alvo

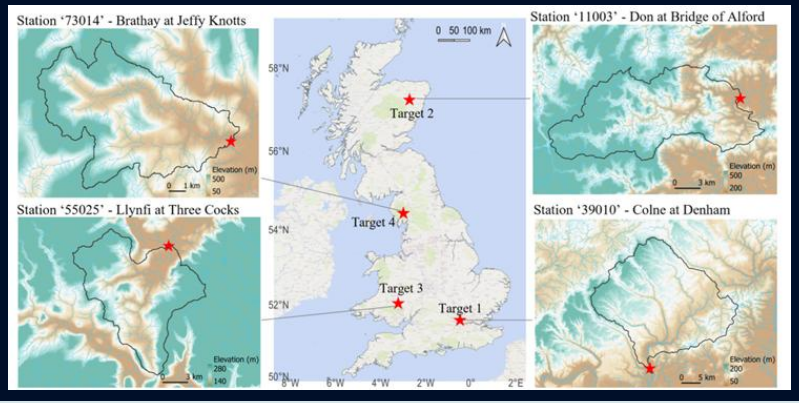
ENTRADAS

Dinâmicas: precipitação, temperatura e evapot. potencial

21 atributos estáticos

SELEÇÃO DAS FONTES

Hidrogramas semanais padronizados → comparação por DTW → ordenação por similaridade



Estudos de caso

Metodologia: Como funciona a MSAF-TL?

1 Seleção

Escolhe as fontes com hidrogramas semanais mais semelhantes (DTW).

2 Pré-treinamento

Treina uma LSTM independente para cada bacia-fonte selecionada.

3 Fusão adaptativa

Pondera fontes por atributos estáticos (SSM) e combina características com cross-attention (AFM).

4 Fine-tuning

Adapta o modelo com os dados disponíveis da bacia-alvo para prever vazão diária.

Diferença-chave: não junta apenas os dados de entrada; combina representações aprendidas separadamente.

Estudos de caso

Metodologia: Três experimentos

01

QUANTIDADE DE FONTES

Bacia-alvo 39010;
1 ano de dados locais;
2, 6 e 10 fontes mais semelhantes.

02

DIFERENTES ALVOS

4 bacias-alvo;
1 ano de dados locais;
2 fontes mais semelhantes por alvo.

03

ESCASSEZ DE DADOS

4 bacias-alvo;
2 fontes por alvo;
6 meses, 1 ano e 2 anos de dados locais.

MODELOS COMPARADOS

NTL: somente dados do alvo, sem TL.
ASTL: TL com todas as 668 fontes.
MSTL: TL convencional com fontes selecionadas.
MSAF-TL: LSTMs independentes e fusão adaptativa.

Estudos de caso

Resultados e discussão

RESULTADOS

•Experimento 1 (bacia-alvo 39010, com 1 ano local): NSE = 0,850 (2 fontes), 0,853 (6 fontes) e 0,776 (ASTL, 668 fontes).

•Experimento 2: Em 4 alvos, MSAF-TL superou MSTL: ganhos relativos de NSE de 4,19% a 10,41%.

• Experimento 3: Com 6 meses locais, ganho médio relativo sobre MSTL: 21,70%.

INTERPRETAÇÃO DOS AUTORES

• Seleção por similaridade pode reduzir a necessidade de maior número de fontes.

• A complementaridade entre fontes também importa: fontes muito parecidas entre si podem ser redundantes.

• MSAF-TL não superou ASTL em todos os alvos.

Estudos de caso

Qual problema o artigo investiga?

- Prever vazões em bacias com séries históricas insuficientes para treinar um modelo local.
- Transferir conhecimento de bacias monitoradas para bacias novas.
- Fazer isso sem novo treinamento ou fine-tuning na bacia-alvo.

Zero-shot indutivo · sem ajustar pesos no alvo

Estudos de caso

Metodologia

15

Bacias-fonte: treinamento

10

Bacias-alvo: zero-shot

25

Bacias nos EUA

ENTRADAS

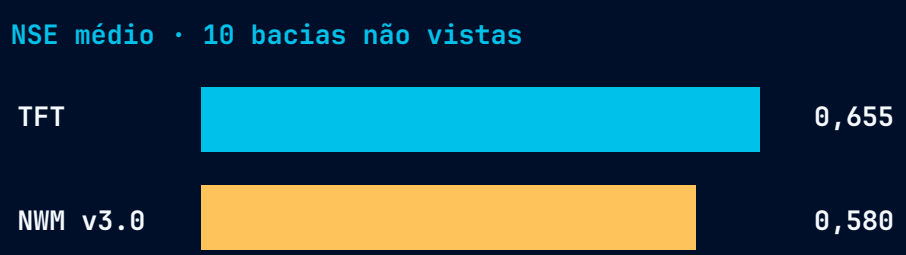
- 30 dias de histórico observado
- Vazão anterior + dados meteorológicos
- Características estáticas da bacia

SAÍDAS

- Previsões para horizontes de 1 a 24 h
- Intervalos probabilísticos de 95%

Estudos de caso

Resultados e Discussão



91%
Observações dentro do intervalo de 95%

CHEIAS
Avaliação de magnitude e tempo do pico

- O modelo apresentou bons resultados em previsão horária e em eventos de cheia.
- Limitação: precisa de observações recentes de vazão na bacia-alvo.

Exercício prático

OBJETIVO E DADOS

Avaliar a transferência de conhecimento entre bacias com LSTM para previsão diária de vazões.

BACIAS-FONTE

60250000, 60265000, 60850000, 86100000, 86160000 e 86480000

Áreas: 1.100 a 2.500 km²

BACIA-ALVO

60220000

ESTRATÉGIAS DE MODELAGEM

01 Modelo fonte

Pré-treinamento nas seis bacias-fonte.

02 Modelo alvo (baseline)

Treinamento apenas com dados da bacia-alvo.

03 Transfer Learning: Zero-shot

04 Transfer Learning: Fine-tuning (1, 2, 5, 10, todos)

Entradas: precipitação e temperatura - vazão observada (somente target)

Exercício prático

Possibilidades de experimentação:

01 Hiperparâmetros

Testar camadas, neurônios, learning rate e batch size.

02 Seleção das bacias-fonte

Investigar o efeito da inclusão ou exclusão de bacias.

03 Variáveis de entrada

Comparar diferentes combinações de preditores.

04 Homogeneidade das bacias-fonte

Analisar similaridade hidrológica, climática e fisiográfica; identificar grupos homogêneos.

Como cada alteração no modelo interferiu nos resultados?