HYDRO-UAI • EPAGRI

Curso Epagri

2026

REVISÃO GERAL

MLP · LSTM · Transfer Learning

Previsão hidrológica • Aula de encerramento



Roteiro da aula

Síntese do curso: da chuva observada à previsão de vazão operacional

01

MLP

Atributos hidrológicos, treinamento e validação

02

LSTM

Chuva-vazão, janelas e memória temporal

03

Transfer Learning

Pré-treino e adaptação entre bacias

04

Encerramento

Decisão operacional e lições do curso

Um problema hidrológico, três caminhos de aprendizagem

Da precipitação e dos estados antecedentes à vazão futura

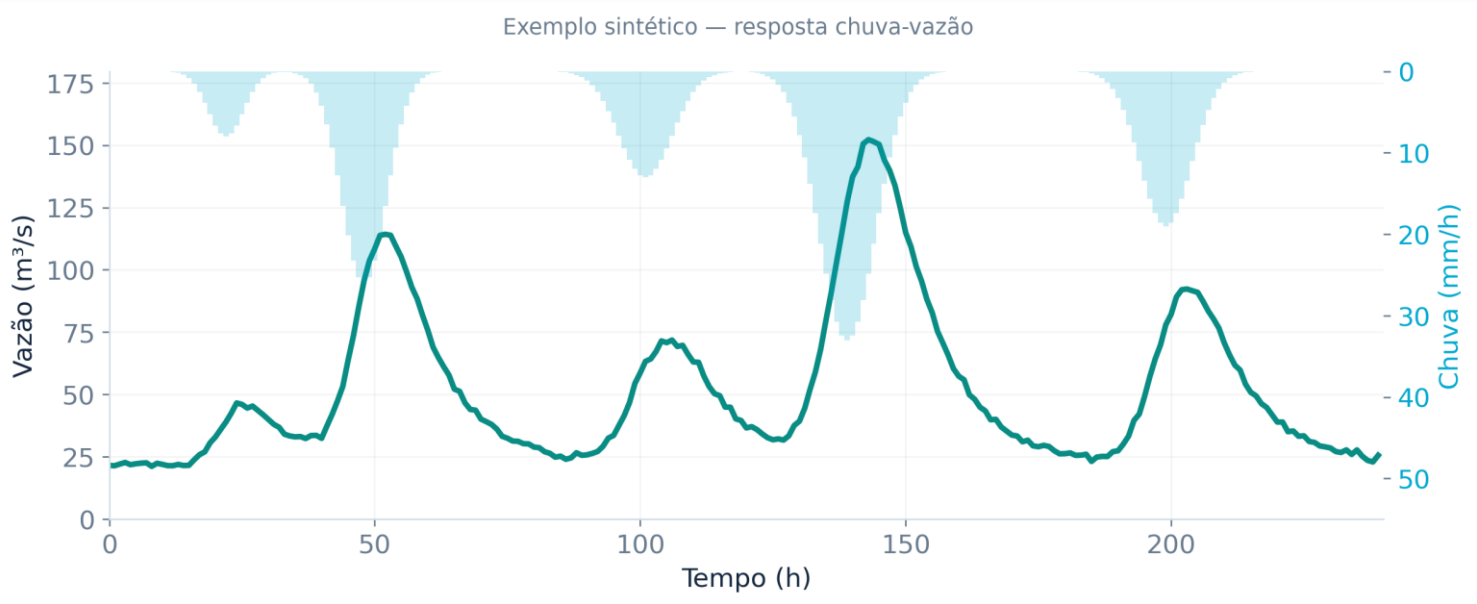


Figura ilustrativa: precipitação e resposta de vazão sintéticas.

MLP

Aprender chuva + vazão passada → vazão futura.

LSTM

Representar a memória da bacia na sequência.

Transfer Learning

Adaptar conhecimento de uma bacia para outra.

Da série temporal ao conjunto supervisionado

A unidade de treino é uma amostra (x_t, y_{t+h})

$$x_t = [\ Q_{t-1}, Q_{t-2}, P_t, P_{t-1}, T_t, \text{atributos estáticos}, \dots\ ]$$

↓

$$\text{modelo}\quad f\theta(x_t)$$

↓

$$\hat{y}_{t+h} = \text{vazão futura } (m^3/s)$$

MLP: aproximação não linear com camadas densas

Multilayer Perceptron — uma função de entrada fixa para saída

Entrada

Atributos em vetor: Q passada, chuva antecedente, umidade e temperatura.

Camadas ocultas

Combinações lineares e funções de ativação aprendem relações não lineares.

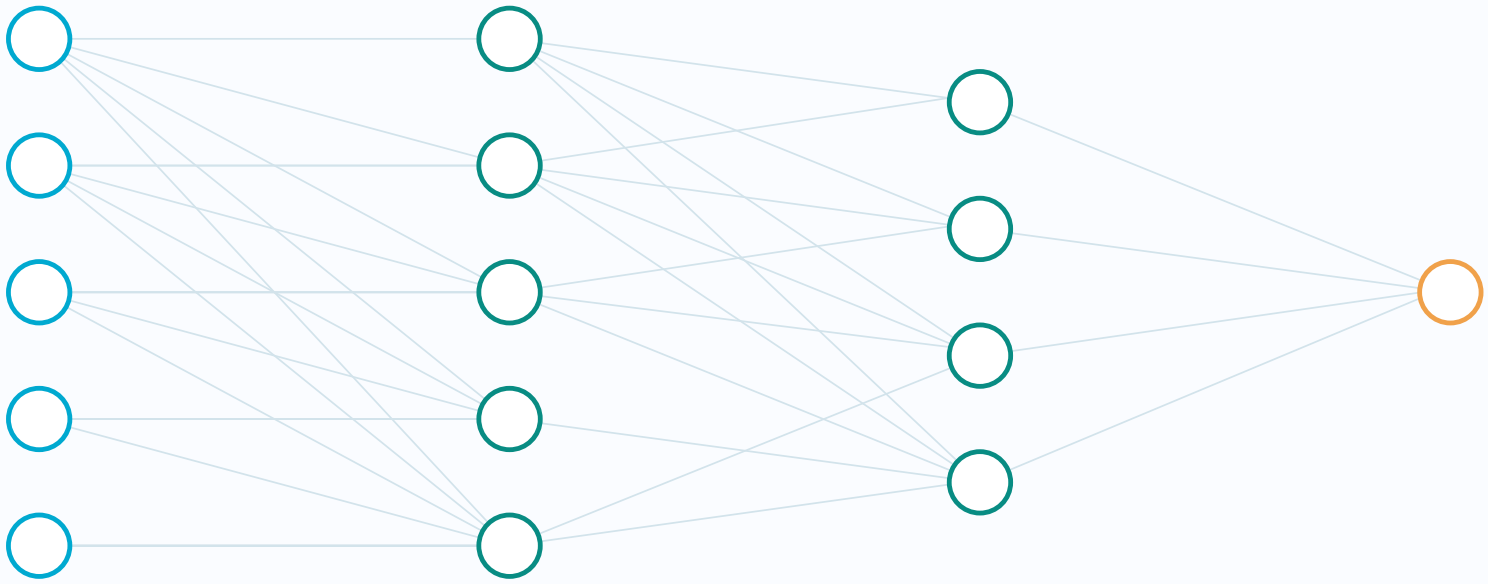
Saída

Vazão em t+6, t+24 h ou toda a curva do hidrograma.

Ideia-chave: a MLP não retém um estado temporal próprio; o histórico precisa estar nas entradas.

Por dentro de uma MLP

Arquitetura 5 → 5 → 4 → 1: exemplo didático



Entradas | Oculta 1 | Oculta 2 | Saída

EXEMPLO

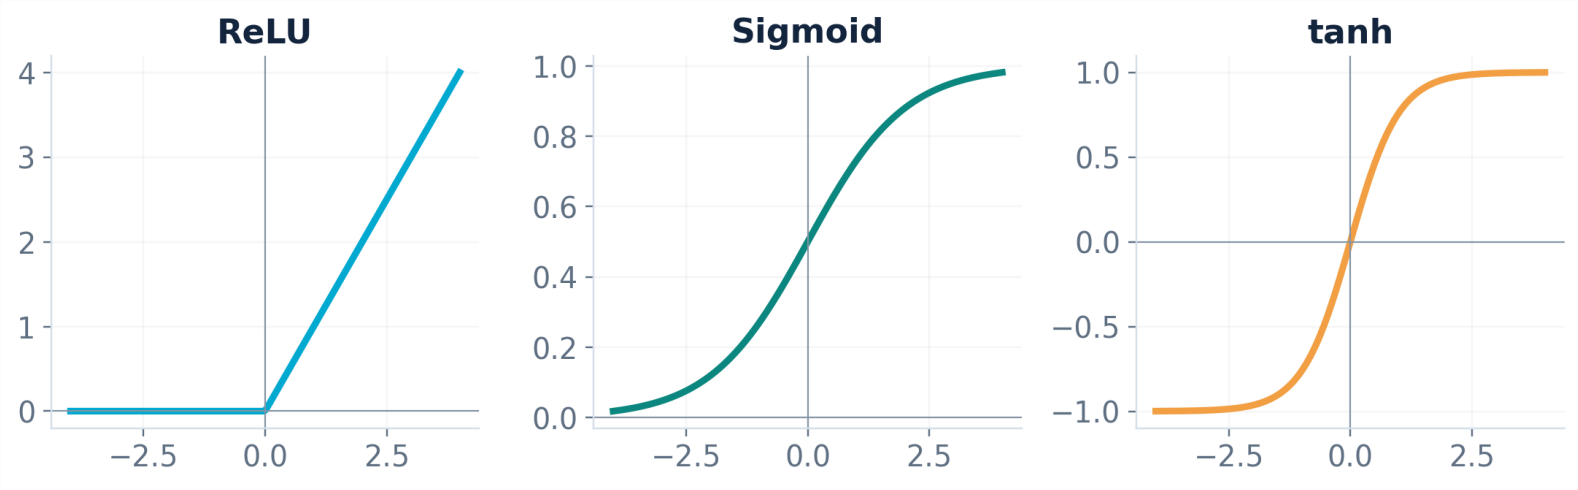
P acumulada
Q_{t-1}
Q_{t-6}
Umidade do solo
Temperatura

→ $\hat{y}_{t+24}$

Forward pass: a operação essencial

Pesos + viés + não linearidade

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)} \qquad a^{(l)} = \phi(z^{(l)})$$



Por que ϕ?

Sem ativação não linear, várias camadas densas colapsam em uma única transformação linear.

Treinamento: como os pesos são ajustados

O ciclo de otimização pode ser resumido em quatro etapas

01

Predizer

Forward pass

02

Medir erro

MAE / MSE

03

Retropropagar

Gradientes

04

Atualizar

Otimizador

Objetivo: minimizar erro de previsão sem perder generalização fora do treino.

MLP para séries temporais: construir boas entradas

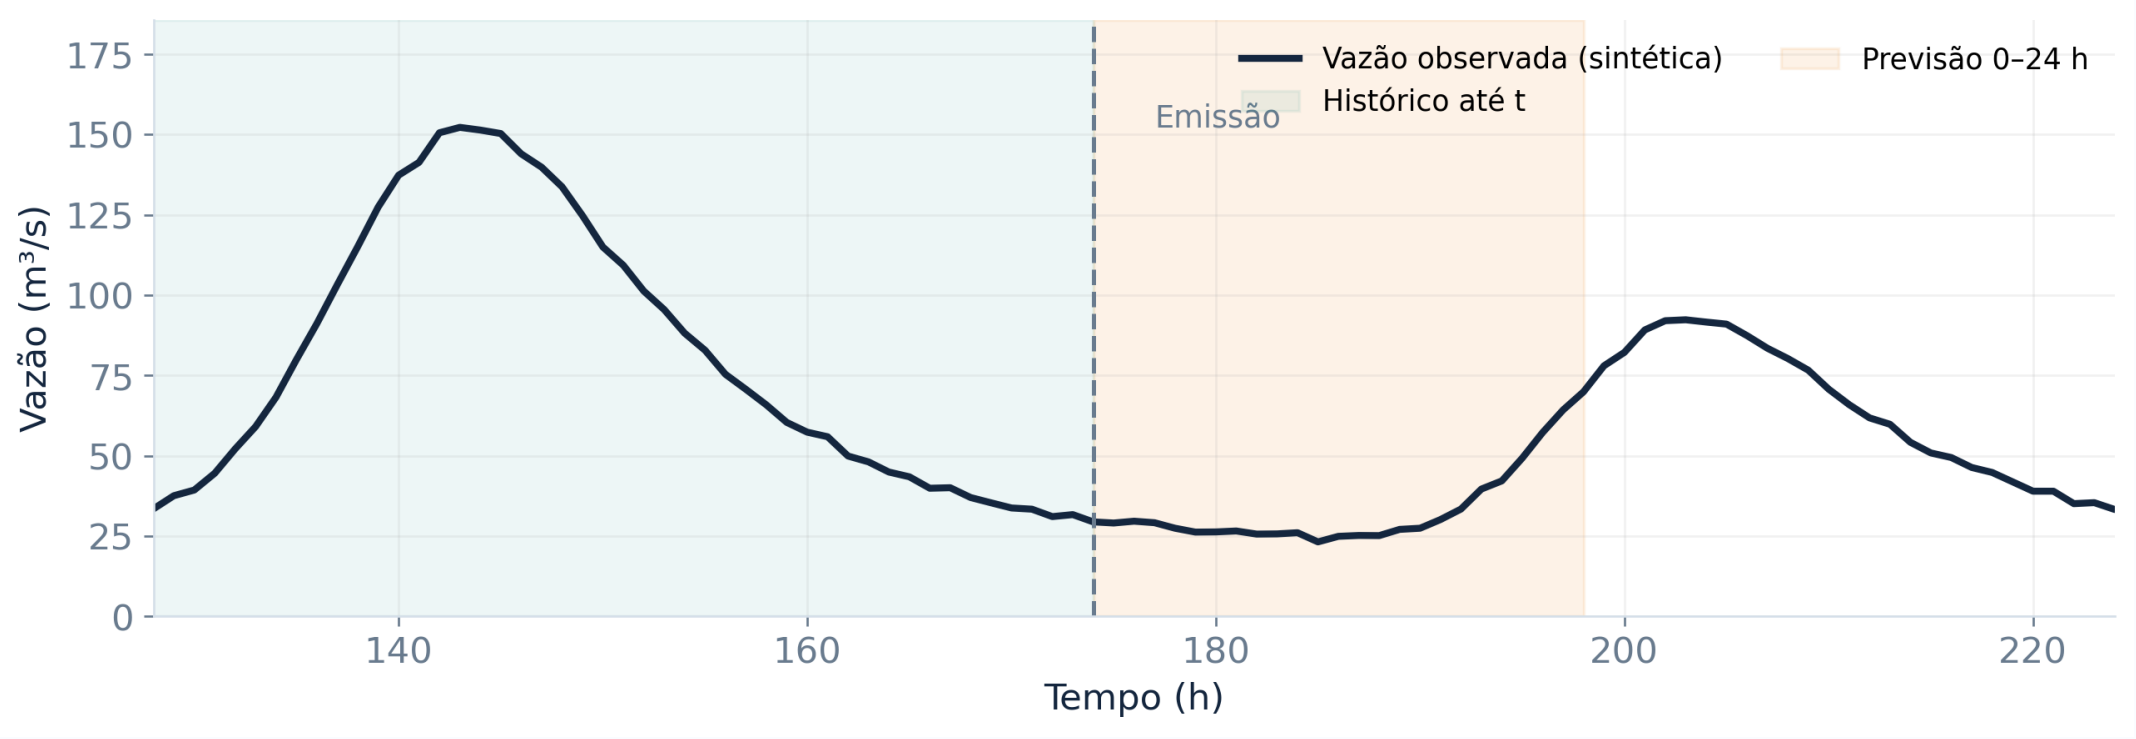
Feature engineering como substituto explícito da memória

Histórico	Q_t, Q_{t-1}, Q_{t-6}, Q_{t-24}
Acumulados	Chuva 24 h / 48 h / 72 h / 168 h
Estado antecedente	Umidade do solo, evapotranspiração, Q média
Contexto	Temperatura, área de drenagem, relevo, solo

A seleção de entradas deve combinar conhecimento físico, disponibilidade operacional e análise exploratória.

Exemplo: previsão de vazão nas próximas 24 horas

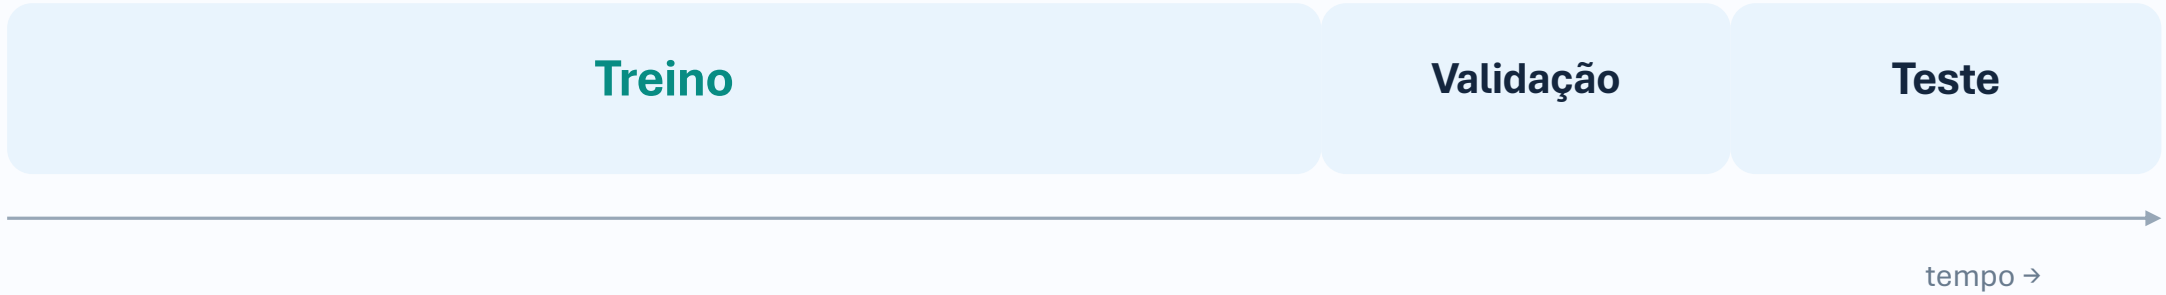
Um hidrograma, uma data de emissão e entradas disponíveis até t



Histórico: chuva + vazão observadas | Futuro: somente chuva prevista, se disponível

Avaliação: o tempo importa tanto quanto a arquitetura

Particionar em blocos cronológicos e monitorar generalização



Sem leakage

Normalização e imputação aprendidas só no treino.

Baselines

Persistência de Q e modelo chuva-vazão simples.

Métricas

MAE, RMSE, NSE / KGE; picos e recessões.

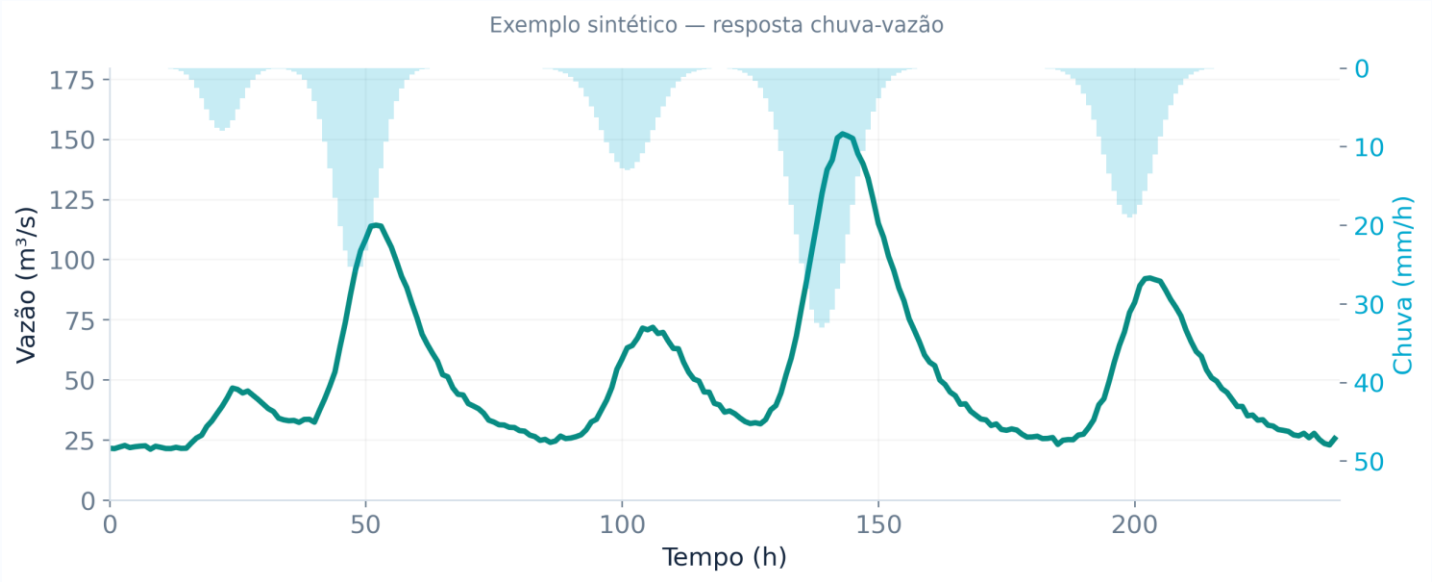
02 / MEMÓRIA TEMPORAL

LSTM

A arquitetura processa sequências e aprende dependências ao longo do tempo.

Por que precisamos de memória?

A resposta atual depende também do que aconteceu antes



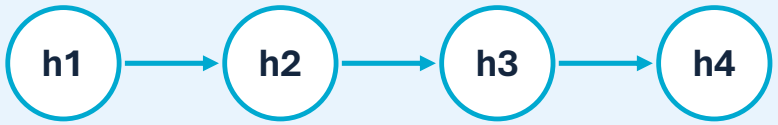
Em uma bacia...

- Chuva antecedente
- Armazenamento no solo
- Propagação hidrológica
- Persistência do escoamento

RNN convencional × LSTM

A diferença prática está no controle da memória

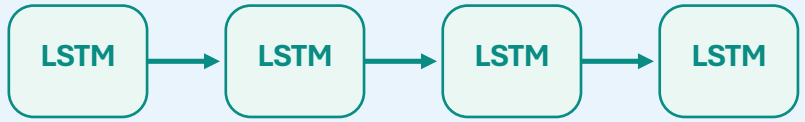
RNN simples



Recorrência: estado oculto que se atualiza em cada passo.

Gradiente pode desaparecer

LSTM



Estado da célula + portas de esquecimento, entrada e saída.

Fluxo de informação controlado

Célula LSTM: três portas e dois estados

O que entra, o que permanece e o que sai



f_t ESQUECER

quanto da memória anterior manter

i_t ESCREVER

quanto da nova informação incorporar

o_t EXPOR

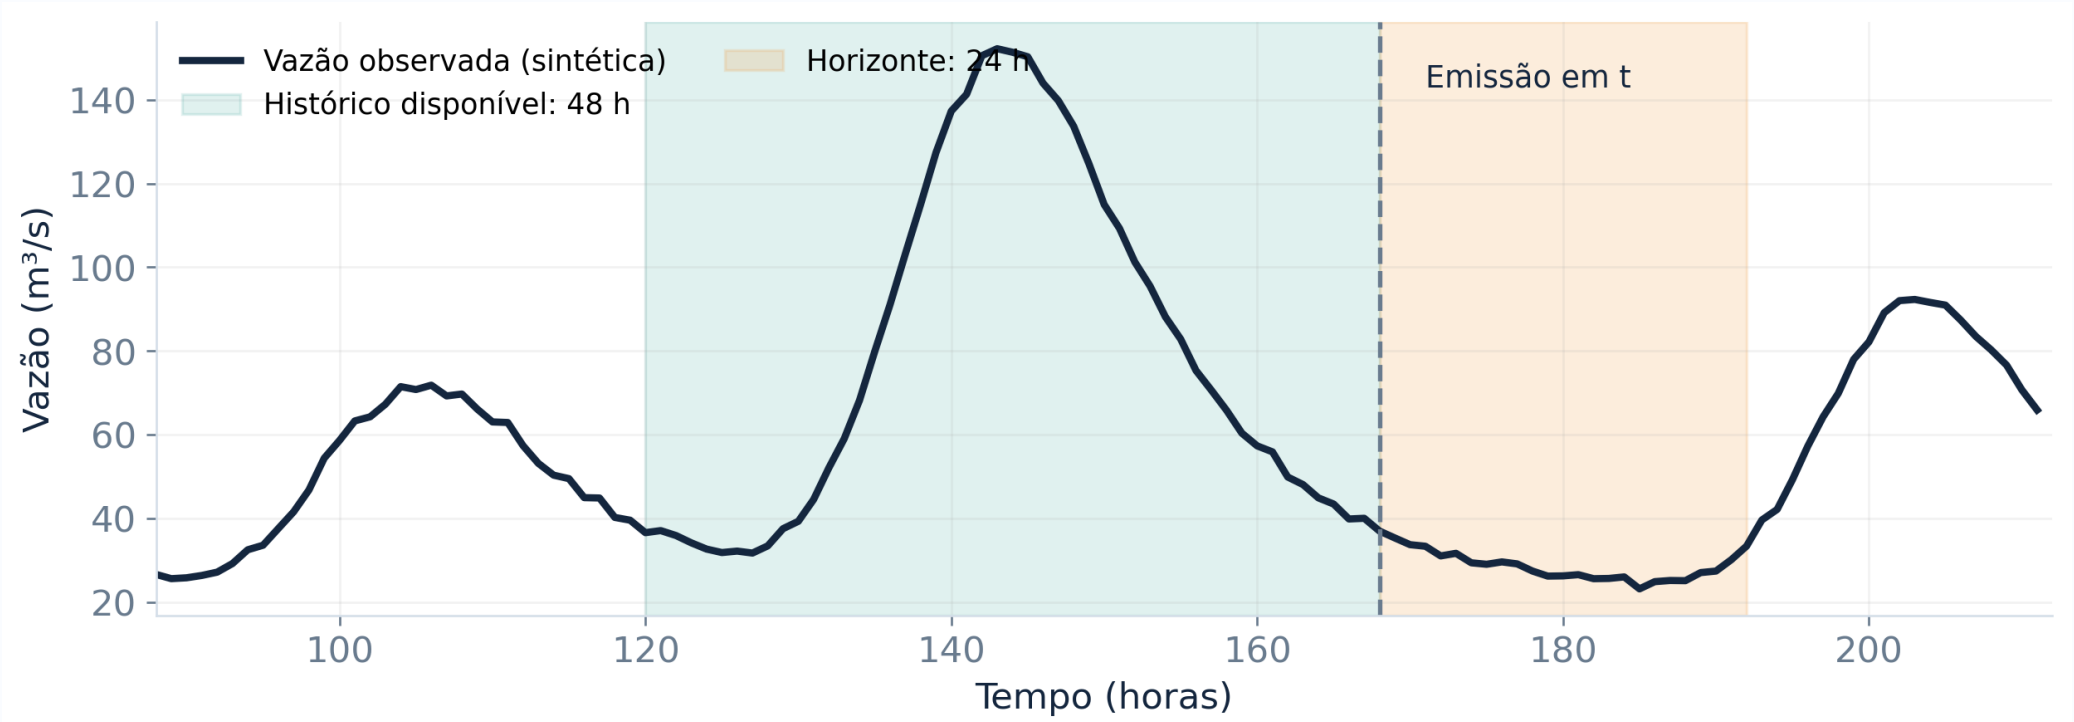
quanto da memória virar saída

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$h_t = o_t \odot \tanh(c_t)$$

Como a LSTM recebe os dados?

Uma amostra = sequência de T passos × F atributos



Formato (amostras × horas × variáveis) · Ex.: 10.000 × 48 × 5

Uma LSTM pode resolver tarefas diferentes

Escolha da saída determina a configuração do problema

Many-to-one

Lê 48 horas e prevê a vazão 24 horas à frente.

X[48,F] → y[1]

Many-to-many

Lê 48 horas e prevê o hidrograma das próximas 24 horas.

X[48,F] → y[24]

Seq2seq / encoder-decoder

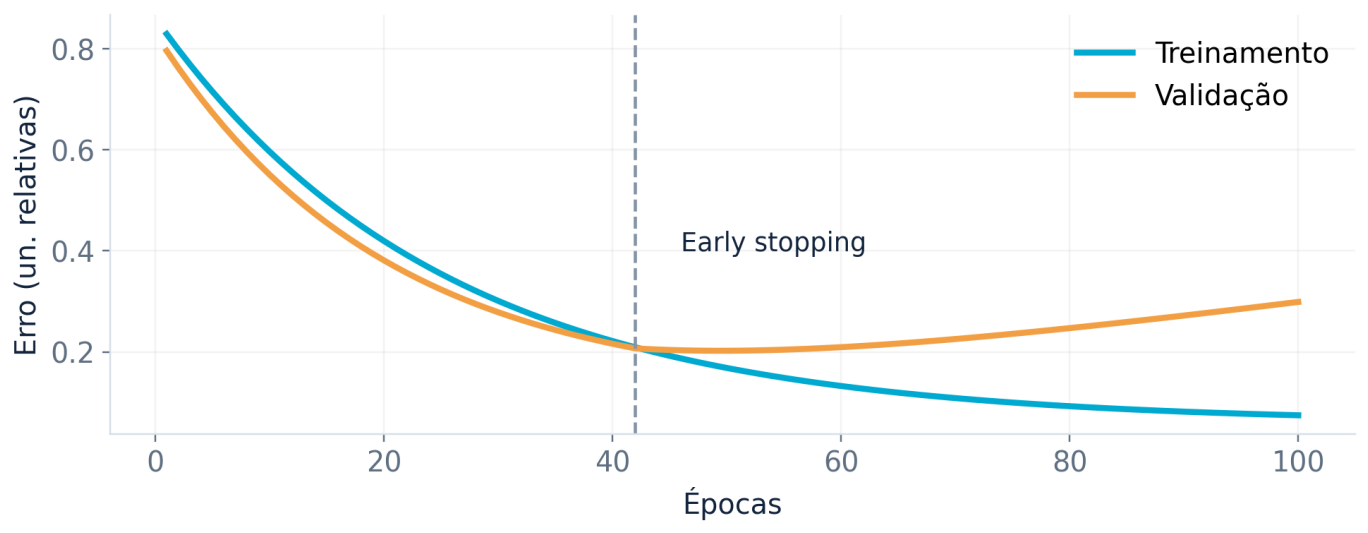
Codifica histórico e gera uma sequência futura autoregressiva ou direta.

Encoder → decoder

Mais complexidade só se justifica com ganho robusto em previsão e validação.

Treinar LSTM exige disciplina experimental

Sequências mal construídas podem parecer bons modelos

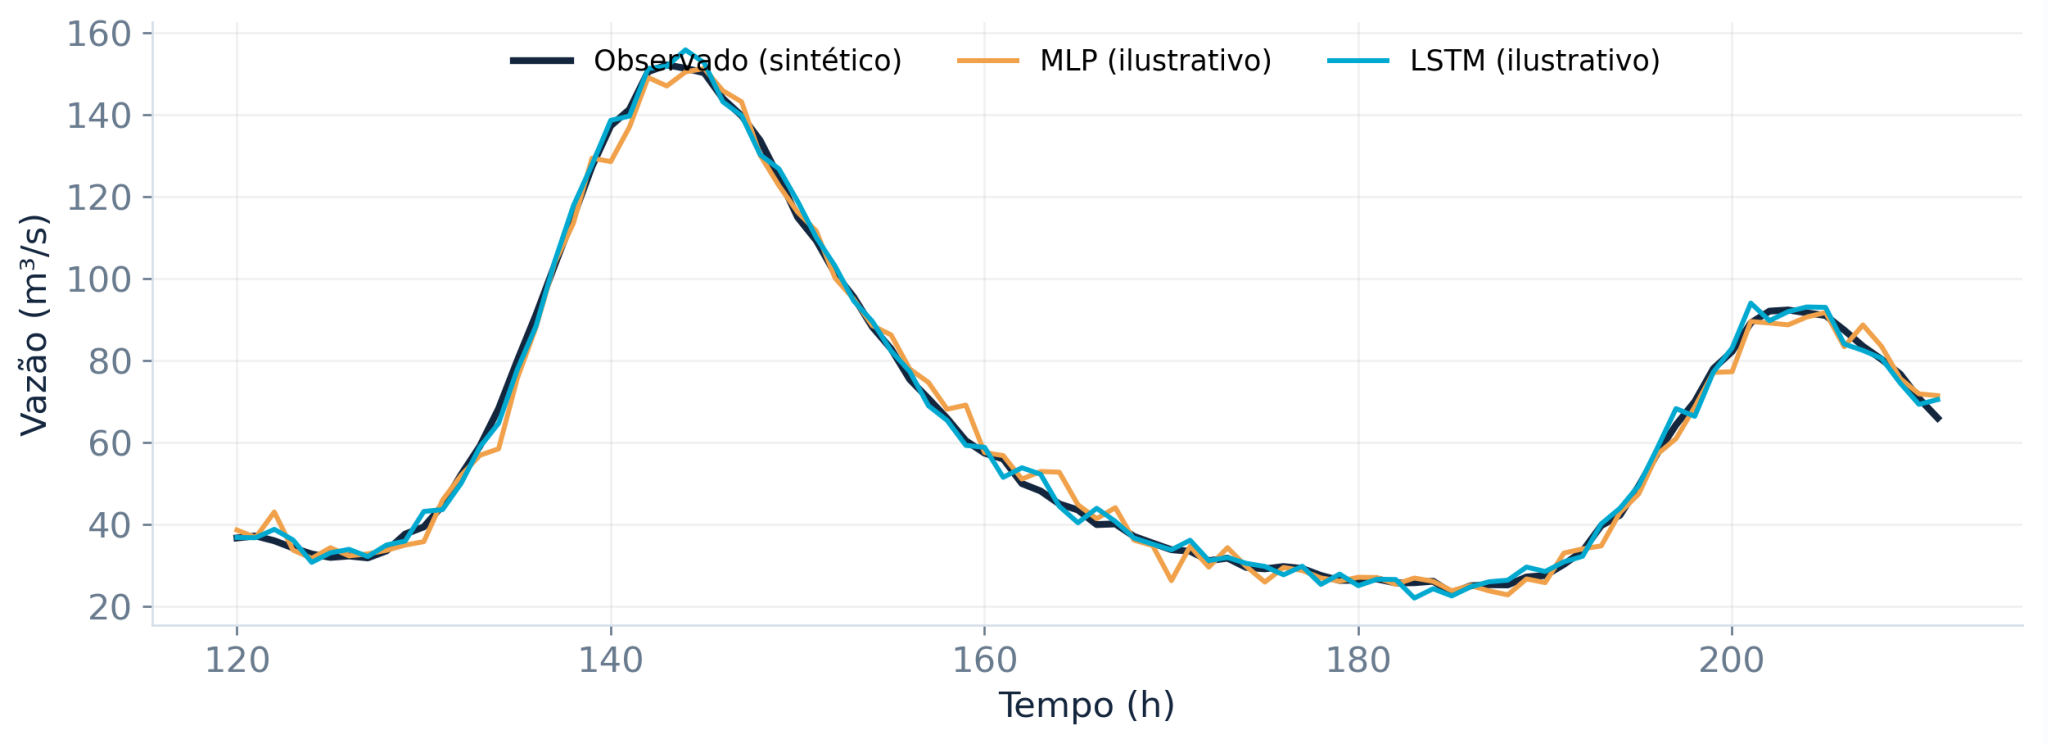


CHECKLIST

- Lookback hidrológico
- Escalonamento no treino
- Validação por período
- Regularização e dropout
- Seed e repetições

MLP × LSTM: a comparação precisa ser justa

Mais parâmetros não significam necessariamente menor erro



Mesmas entradas disponíveis • mesmo particionamento temporal • mesma métrica • múltiplas execuções

03 / TRANSFERÊNCIA DE CONHECIMENTO

Transfer Learning

Aproveitar o que um modelo aprendeu onde os dados são abundantes.

A ideia central do Transfer Learning

Modelos podem carregar representações úteis entre domínios

DOMÍNIO FONTE

Muitos dados
Treino inicial

pesos / representações



DOMÍNIO ALVO

Poucos dados
Adaptação local

Exemplo: pré-treinar com bacias monitoradas e adaptar para uma bacia com série curta.

Três maneiras práticas de transferir

Da reutilização simples à adaptação completa

01 Feature extraction

Congela a base e treina apenas a camada final no domínio alvo.

Vantagem: estável com poucos dados.

02 Fine-tuning parcial

Congela camadas iniciais e libera algumas camadas finais.

Vantagem: equilíbrio entre memória e adaptação.

03 Fine-tuning completo

Atualiza a rede inteira com taxa de aprendizado menor.

Vantagem: maior flexibilidade; maior risco.

Estratégia ideal depende do volume de dados alvo e da semelhança fonte–alvo.

Fine-tuning: procedimento em duas fases

Primeiro aprender padrões gerais; depois adaptar a previsão local

1 PRÉ-TREINO

Fonte: bacias com chuva + vazão bem monitoradas

2 ADAPTAÇÃO

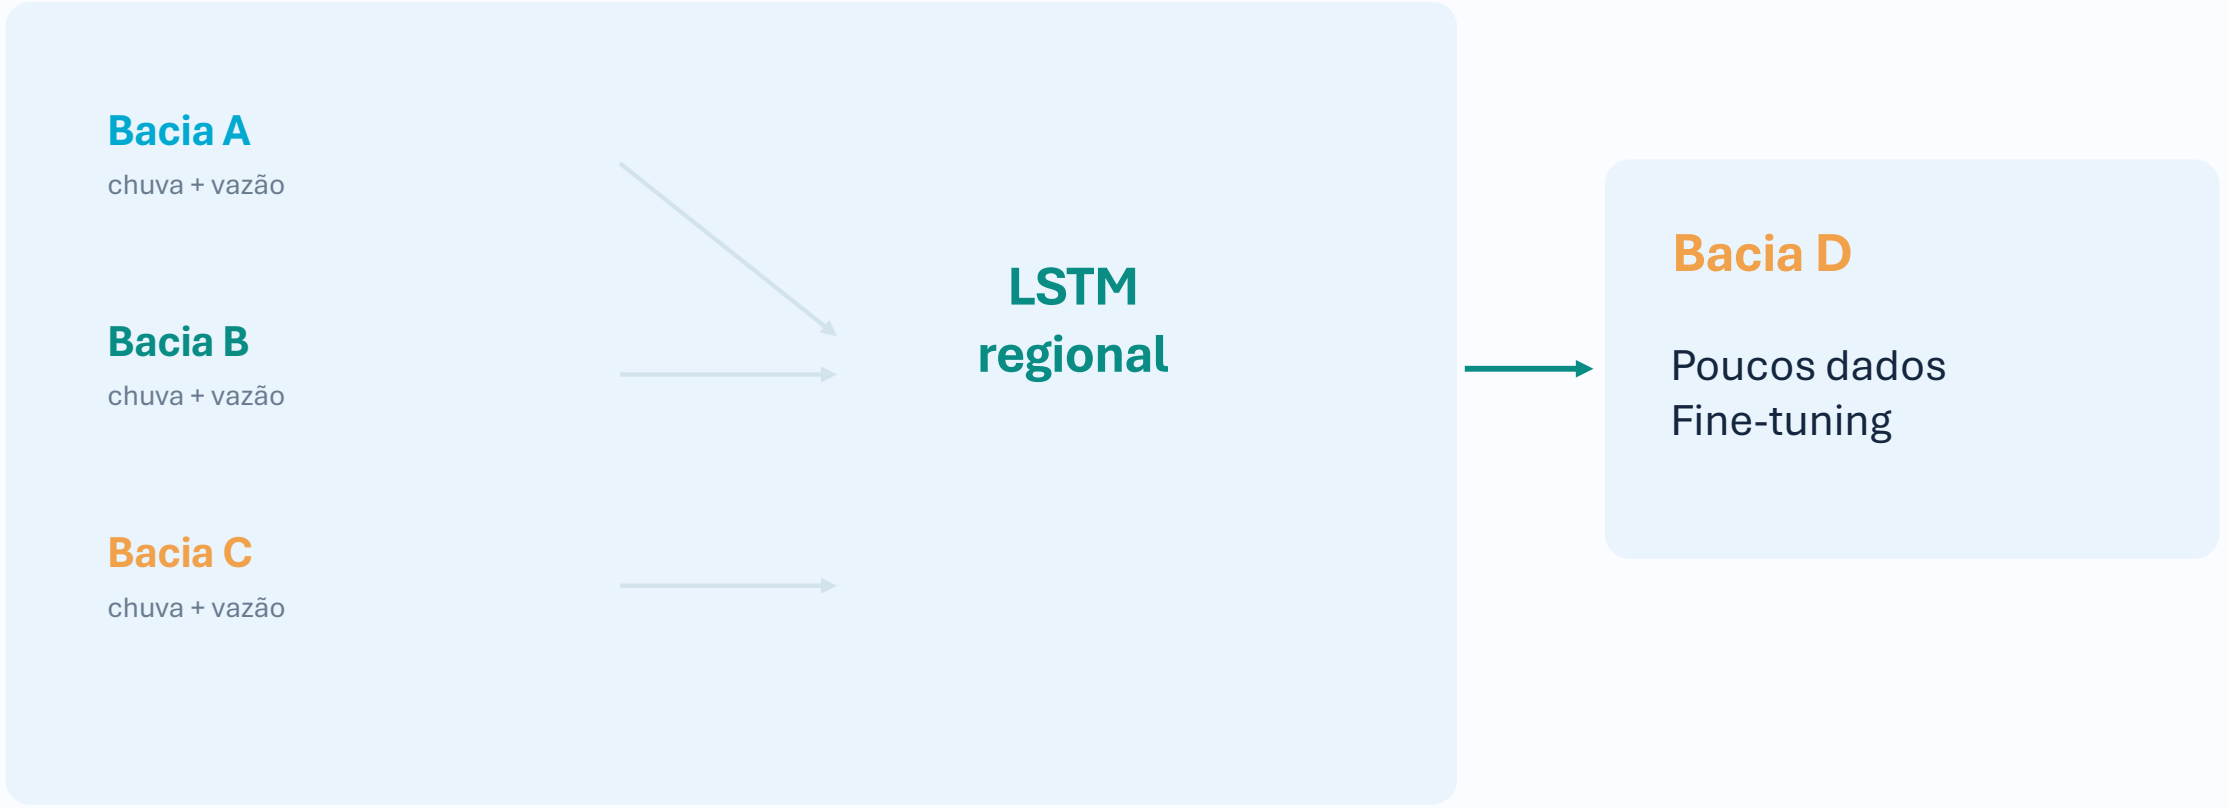
Alvo: bacia com série curta e teste cronológico

Carregar pesos → substituir cabeça → congelar → ajustar → descongelar seletivamente

Seleção de hiperparâmetros no alvo = validação; avaliação final = teste intocado.

Caso em recursos hídricos: transferência entre bacias

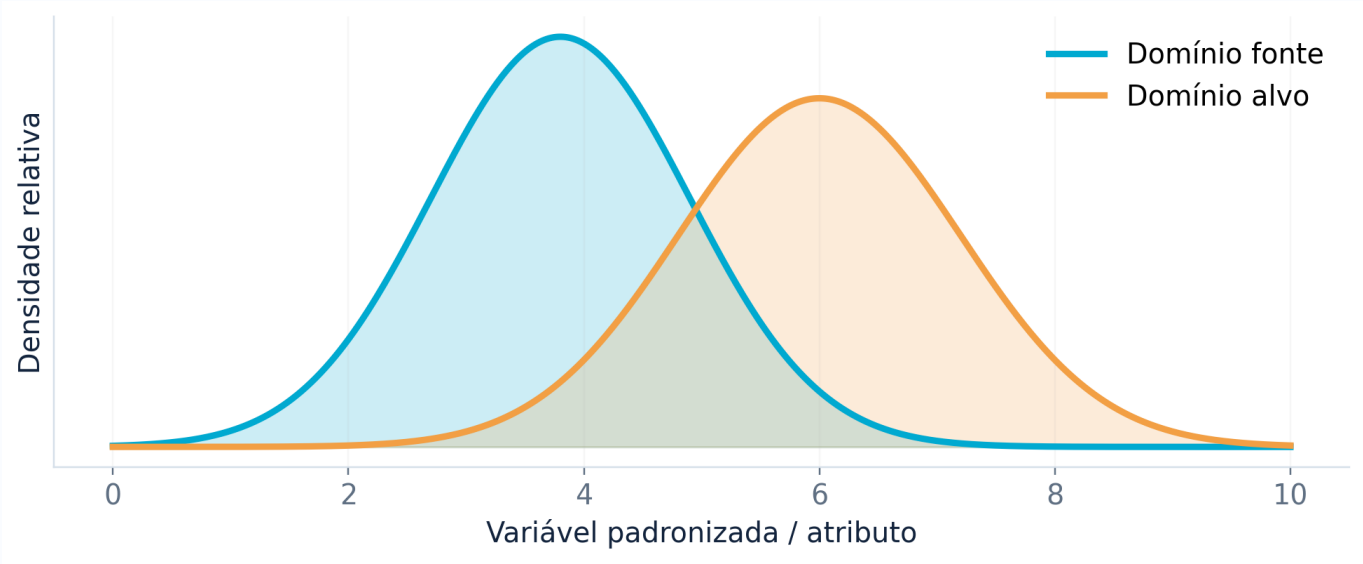
Generalização regional, mas com heterogeneidade física



Variáveis de contexto: área, relevo, solo, clima e comportamento hidrológico.

Quando a transferência falha: negative transfer

Semelhança estatística e física não é garantida



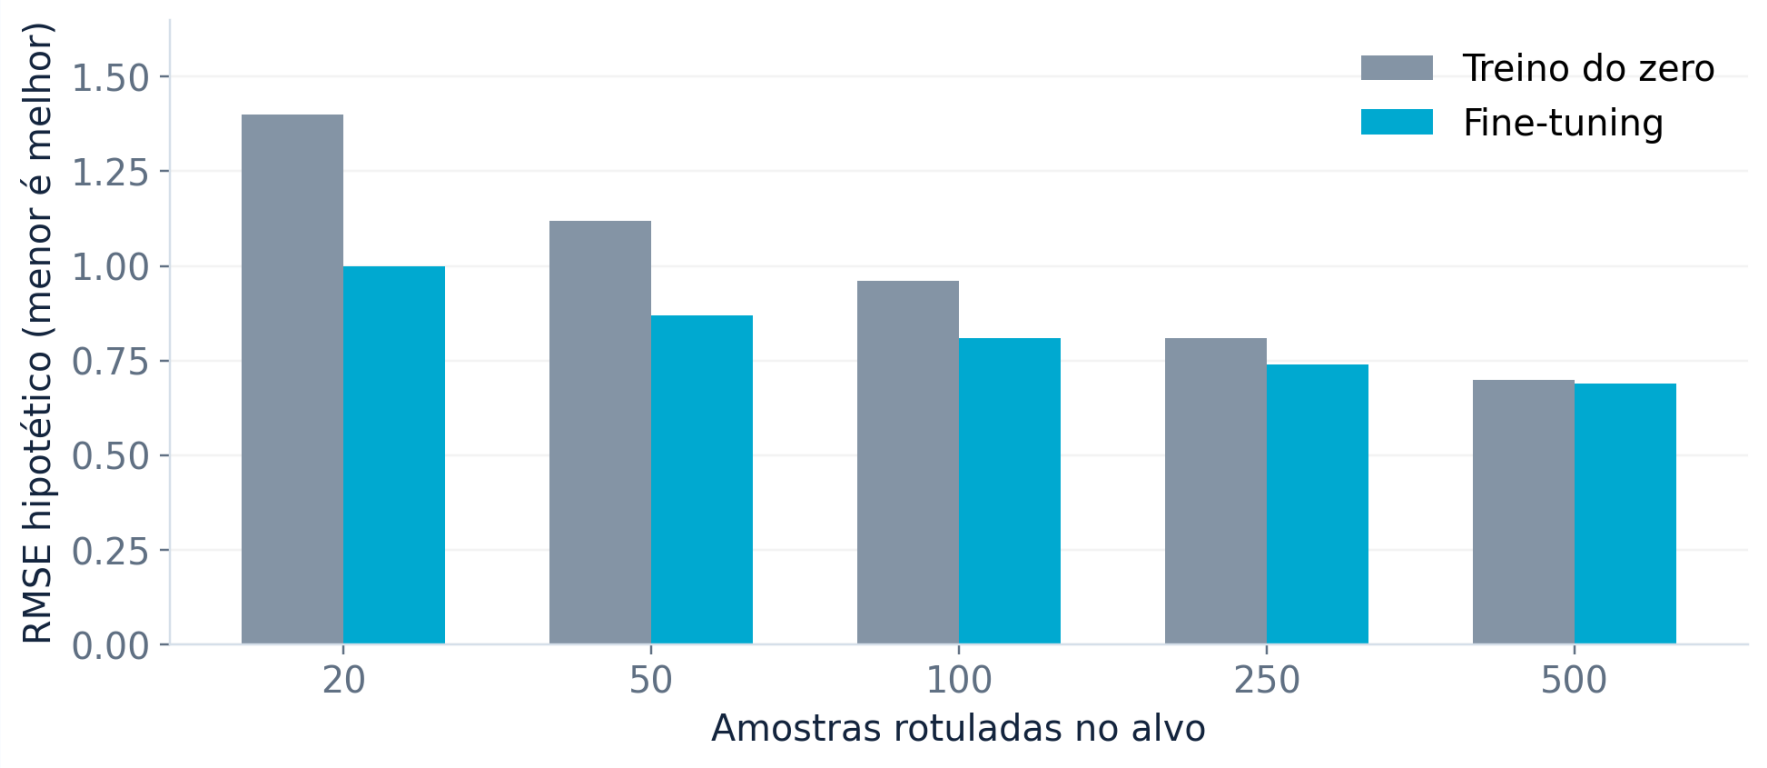
ALERTAS

- Clima e escala distintos
- Relações entrada–saída diferentes
- Sensores e frequências distintos
- Mudanças do regime hidrológico

Transferir não é copiar: toda adaptação requer comparação contra o treino do zero.

Como provar que Transfer Learning ajudou?

Comparar em condições equivalentes, com diferentes quantidades de dados alvo



4 testes

- Do zero
- Congelado
- Fine-tuning
- Baseline

Resultados simulados: ganhos relativos podem diminuir quando o alvo tem muitos dados.

Desafio final (3 min): planeje uma previsão hidrológica

Cenário hipotético: 8 anos na bacia A; 10 meses na bacia B

Objetivo: prever Q de 6 a 24 h, apoiando o acompanhamento de cheias e estiagens.

1. Quais Q e chuvas antecedentes entrariam no modelo?
2. **Quando usar MLP, LSTM ou transferência da bacia A?**
3. Qual teste temporal e métrica protegem a decisão?

DISCUSSÃO · 1 min para pensar + 2 min para respostas

Regra prática: qual abordagem escolher?

Comece com a hipótese mais simples que resolve o problema

MLP

Previsão com atrasos de Q, chuva acumulada e poucos dados.

Baseline forte e de baixo custo.

LSTM

Efeitos antecedentes e tempos de resposta variáveis, com sequência histórica suficiente.

Exige mais ajuste.

Transfer Learning

O domínio alvo tem poucos dados, mas existe domínio fonte relevante.

Avaliar risco de negative transfer.

Escolha técnica = desempenho por horizonte + robustez nos extremos + viabilidade operacional.

O que fica do curso para a prática na Epagri?

Três princípios para transformar modelos em previsões confiáveis

01

Entradas disponíveis na hora da previsão

Não usar chuva futura observada: usar previsão meteorológica, se houver.

02

Validação realista de eventos hidrológicos

Testar por tempo, horizonte, extremos e limiares de interesse.

03

Complexidade deve trazer ganho comprovado

Comparar persistência, MLP, LSTM e transferência entre bacias.

Obrigado! Referências para continuar aprofundando

Encerramento do curso Epagri • visão integrada da previsão hidrológica

Hochreiter & Schmidhuber (1997)
Long Short-Term Memory. Neural Computation.
doi.org/10.1162/neco.1997.9.8.1735

Pan & Yang (2010)
A Survey on Transfer Learning. IEEE TKDE.
doi.org/10.1109/TKDE.2009.191

Kratzert et al. (2019)
Towards learning universal, regional, and local hydrological behaviors.
neuralhydrology.github.io

Previsão útil combina dados confiáveis, boa validação e julgamento hidrológico.