HYDRO-UAI • EPAGRI

Curso Epagri 2026

REDES RECORRENTES E LSTM

Memória, gradientes e previsão de séries hidrológicas

André Ferreira Rodrigues • Bruno Melo Brentan
Rodrigo Perdigão Bezerra

<hydro_uai>

AULA 04



Percurso da aula

01 **Memória de uma série**

Chuva, estado antecedente e resposta da bacia

02 **RNN e treinamento**

Estado oculto, pesos compartilhados e BPTT

03 **Gradientes no tempo**

Vanishing / exploding gradient

04 **Célula LSTM**

Portas, estados da célula e do gradiente

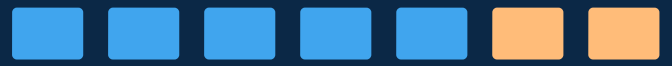
05 **Previsão hidrológica**

Janelas, validação temporal e aplicação



Objetivos de aprendizagem

01 REPRESENTAR O HISTÓRICO



Definir sequências de entradas e um alvo futuro.

02 ENTENDER O TREINAMENTO



Relacionar gradientes distantes a Jacobianas.

03 CALCULAR UMA CÉLULA LSTM



Interpretar as portas f, i, o e os estados c, h.

04 PLANEJAR UMA PREVISÃO



Selecionar entradas, validação e baselines.

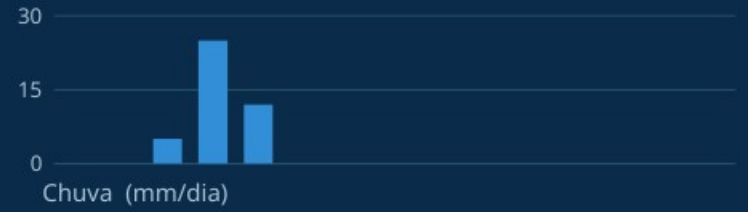
Memória hidrológica

Por que a vazão ainda responde quando a chuva já terminou?

PROCESSOS HIDROLÓGICOS DA BACIA



EVENTO DE CHUVA



RESPOSTA DA VAZÃO



A CHUVA ATIVA OS PROCESSOS

Precipitação, infiltração, escoamento superficial

A BACIA ARMAZENA E TRANSPORTA

Solo, aquífero e rede de drenagem

A VAZÃO RESPONDE DEPOIS

Pico de chuva: dia 4
Pico de vazão: dia 6

Hidrograma sintético. O atraso ilustra memória e não representa uma bacia observada.

Mesma chuva, condições antecedentes diferentes

Um evento de 30 mm pode produzir hidrogramas muito diferentes.

MESMO EVENTO: 30 mm DE CHUVA

ANTECEDENTE SECO

MENOR RESPOSTA





Solo mais seco. Resposta menor ao evento de chuva.

ANTECEDENTE ÚMIDO

MAIOR RESPOSTA





Condições úmidas. Vazão mais intensa após a mesma chuva.

A condição antecedente pode alterar a resposta: chuva passada, umidade do solo, evapotranspiração e sazonalidade.

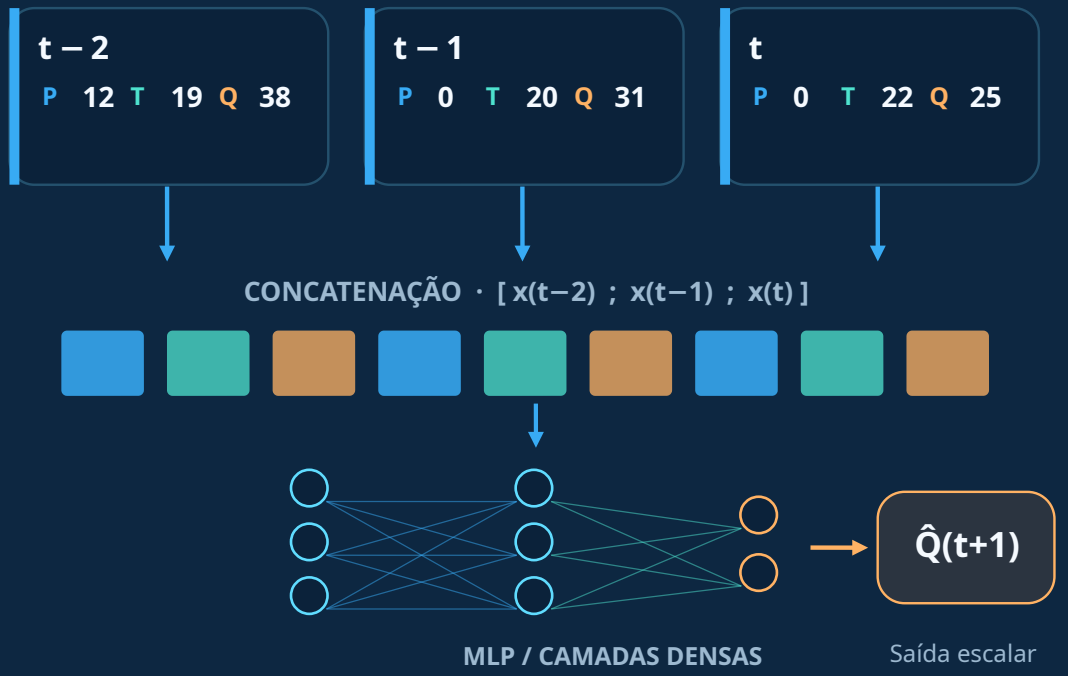
Cenários sintéticos. Mesmo valor inicial de vazão (10 m³/s); curvas conceituais, não observadas.

MLP com defasagens × rede recorrente

Duas maneiras de explorar o mesmo histórico hidrológico.

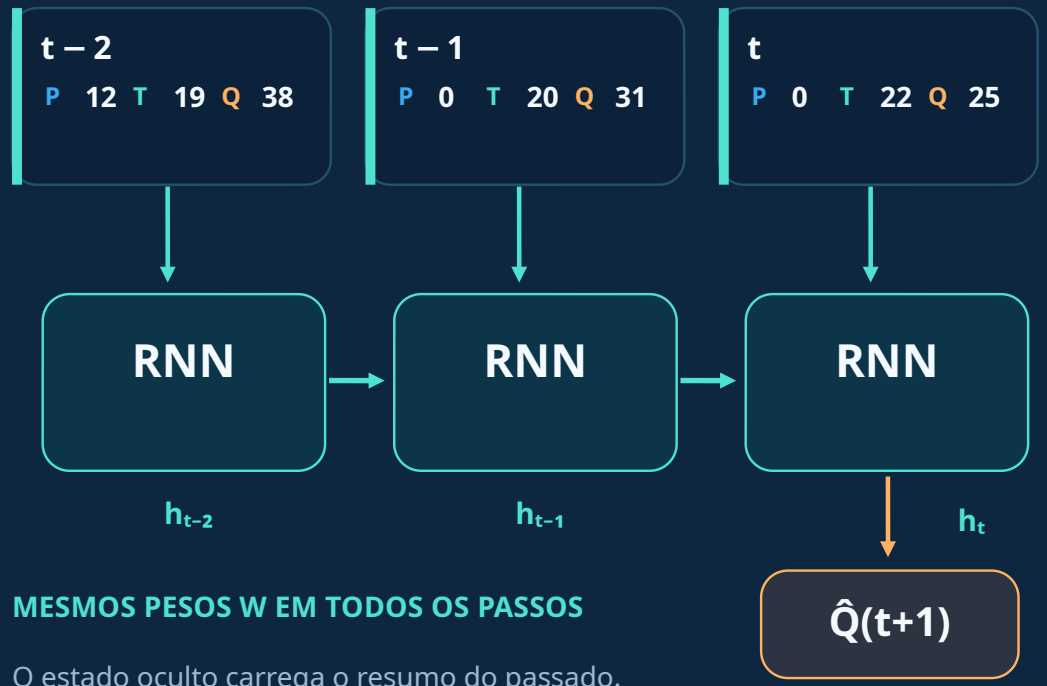
MLP / HISTÓRICO EMPILHADO

Uma janela → vetor de atributos → previsão



RNN / LEITURA SEQUENCIAL

Uma atualização de estado em cada passo



MESMOS PESOS W EM TODOS OS PASSOS

O estado oculto carrega o resumo do passado.

MESMA JANELA DE ENTRADA • ORGANIZAÇÃO DO HISTÓRICO DIFERENTE

Da série temporal à janela de entrada

Exemplo: uma amostra com 7 tempos × 3 variáveis

Dados sintéticos usados para ilustrar a formação do tensor.

Tempo	Chuva (mm)	Temperatura (°C)	Vazão (m^3/s)
t – 6	0	20	15
t – 5	2	21	15
t – 4	10	21	17
t – 3	25	20	25
t – 2	12	19	38
t – 1	0	20	31
t	0	22	25

A janela de entrada termina em t — Q(t+1) não pertence a X.

1 Separe o histórico do alvo futuro

Vazão observada dentro da janela de 7 tempos



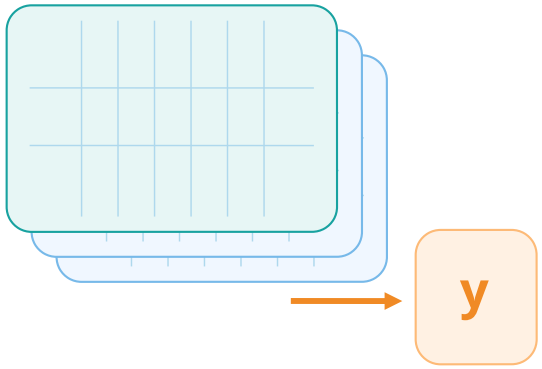
2 Empilhe as janelas em lotes

LOTE DE AMOSTRAS

X.shape

(32, 7, 3)

32 janelas • 7 tempos • 3 variáveis



Uma amostra usa somente informações disponíveis até t; o alvo é a vazão futura Q(t+1).

Como funciona uma célula recorrente simples

Duas informações entram

O instante atual é combinado com um resumo do passado.

h **Memória anterior**

$h(t-1)$

x **Nova observação**

$x(t) = [P, T, Q]$

Dentro da célula RNN

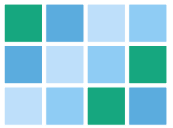
1 · COMBINAÇÃO LINEAR

$$a(t) = W_x \cdot x(t) + W_h \cdot h(t-1) + b$$

Pesos de entrada



Pesos recorrentes



Viés



2 · NÃO LINEARIDADE

$$h(t) = \tanh(a(t))$$

O novo estado é a memória

$h(t)$

Resumo atualizado do passado e da observação atual.

vai para o próximo instante

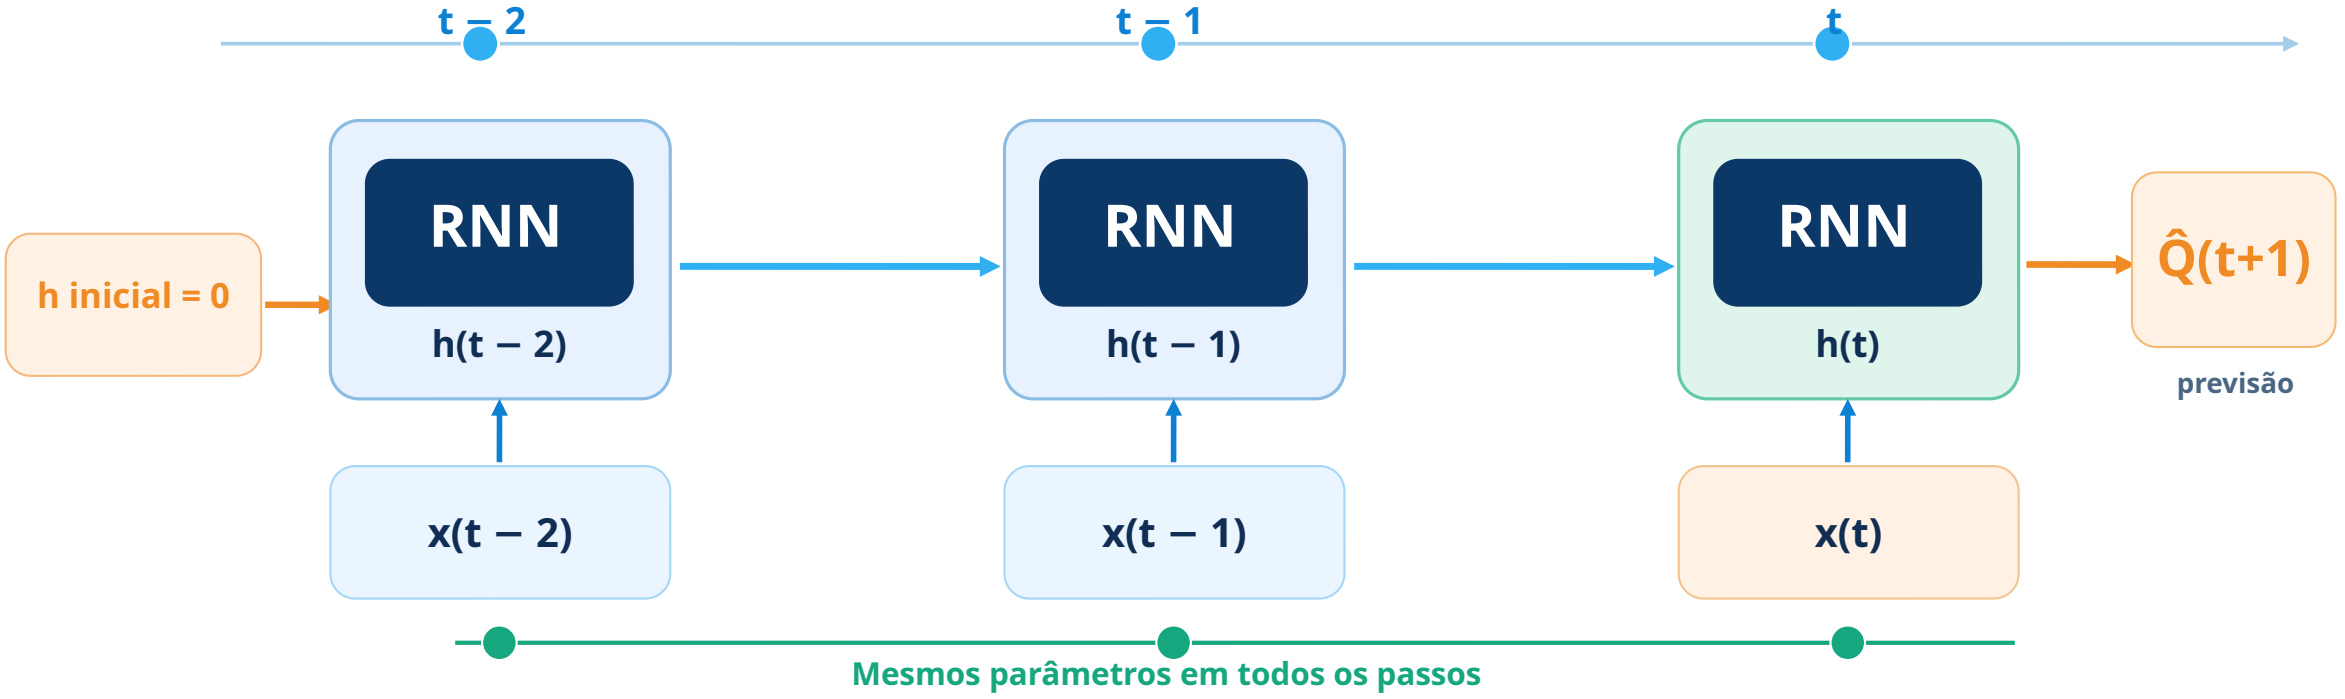
NO PRÓXIMO PASSO **h(t) vira a memória anterior, a célula recebe x(t+1) e repete o cálculo.**

A RNN aplica a mesma transformação em todos os instantes: W_x, W_h e b são compartilhados.

9 A mesma RNN desenrolada no tempo

Três instantes de uma mesma célula recorrente

A memória caminha da esquerda para a direita; os pesos W_x, W_h e b não mudam.



1 Estado inicial

O início da janela utiliza $h_0 = 0$ (ou estado definido).

2 Propagação da memória

O novo estado h(t−1) alimenta o instante seguinte.

3 Previsão futura

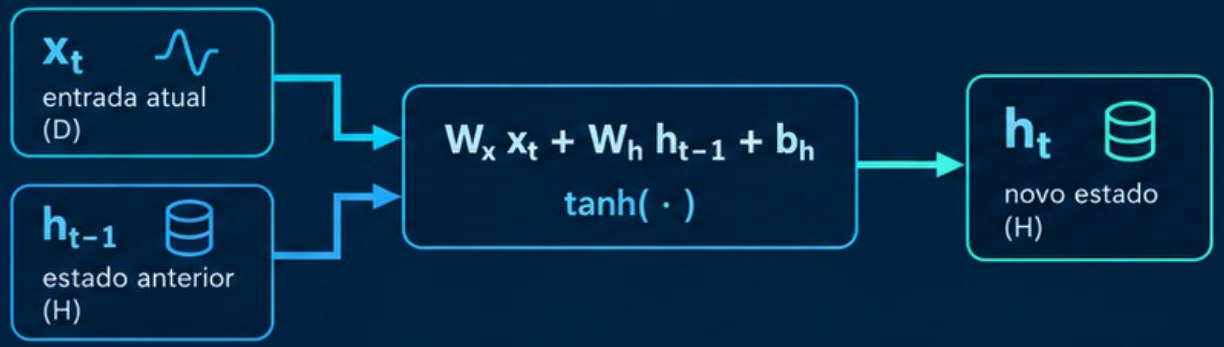
Uma camada de saída lê h(t) para estimar Q(t+1).

Desenrolar a RNN não cria células diferentes: apenas explicita o mesmo núcleo aplicado em vários tempos.

Equações e dimensões de uma RNN

ATUALIZAÇÃO DO ESTADO

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b_h)$$



LEITURA DA PREVISÃO

$$\hat{Q}_{t+1} = W_y^T h_t + b_y$$

tanh: ativação não linear
Saída escalar: previsão de vazão

DIMENSÕES PARA D ENTRADAS E H ESTADOS

x_t	D	atributos de entrada
h_t	H	estado oculto
W_x	H × D	transformação da entrada
W_h	H × H	transformação recorrente

1 b_h tem dimensão H; b_y é escalar.

Cálculo de um estado recorrente

EXEMPLO ESCALAR

$$h_t = \tanh(0{,}5\, h_{t-1} + 0{,}2\, x_t)$$

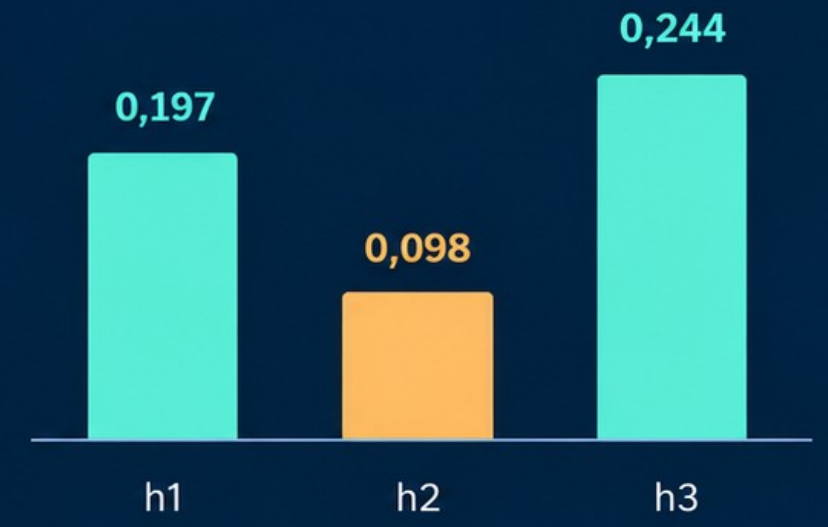
$h_0 = 0$



PASSO	x_t	ARGUMENTO	h_t
1	1	0,200	0,197
2	**0**	**0,099**	**0,098**
3	1	0,249	0,244

No passo 2, $x_2 = 0$: o estado ainda carrega parte do passado.

PERSISTÊNCIA DO ESTADO



Mesmo sem nova entrada, a memória não desaparece instantaneamente.

O significado do estado oculto

HISTÓRICO informações passadas

Chuva

$P(t-2)$
$P(t-1)$
...

Vazão

$Q(t-2)$
$Q(t-1)$
...

Condições antecedentes

Umidade$(t-2)$
Temperatura$(t-1)$
Uso do solo
...

Outras variáveis também podem ser usadas.

ESTADO OCULTO resumo do histórico

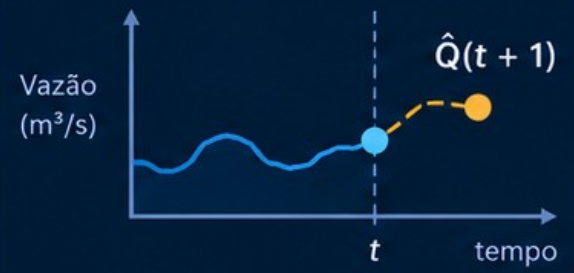
$$h_t = [h_{t,1}, h_{t,2}, \ldots, h_{t,H}]$$

$h_t =$ $h_{t,1}$, $h_{t,2}$, $h_{t,3}$, ..., $h_{t,H}$ — H componentes do estado oculto

1. O treinamento aprende um **resumo útil** para prever o alvo.
2. Cada componente **combina informações** do histórico.

SAÍDA previsão para o próximo instante

Vazão futura (exemplo)

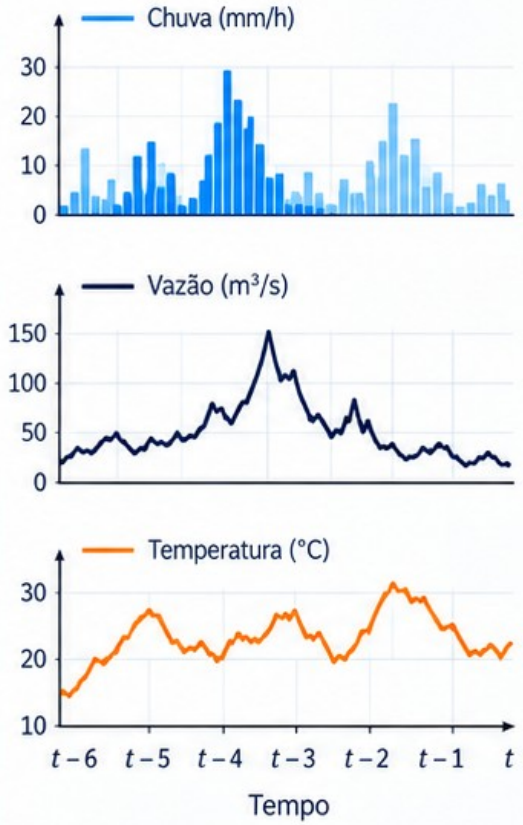


A interpretação como solo, aquífero ou reservatório exige análise e validação adicionais.

Saídas por janela e saídas por passo

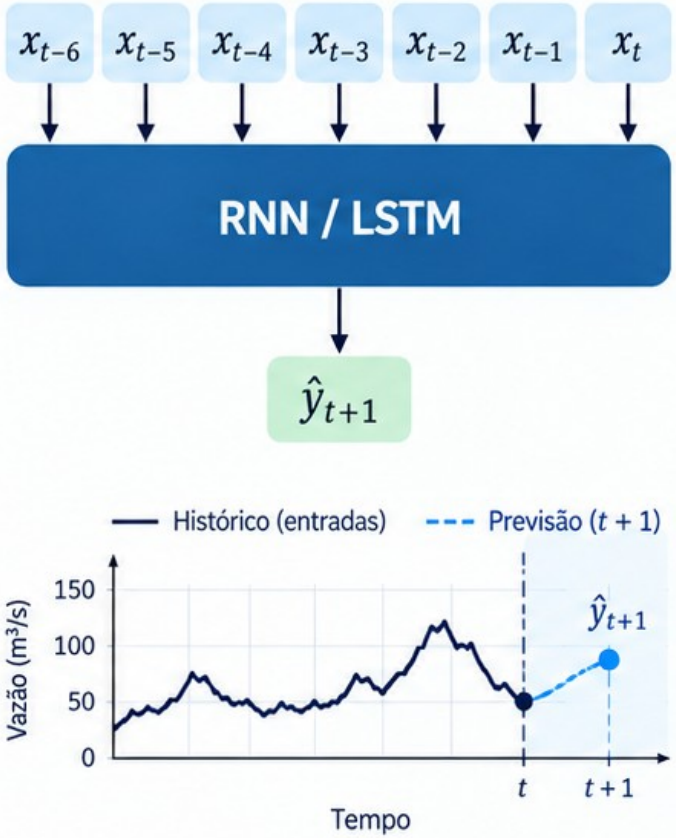
Sequência de entrada

Variáveis hidrológicas (janelas temporais)



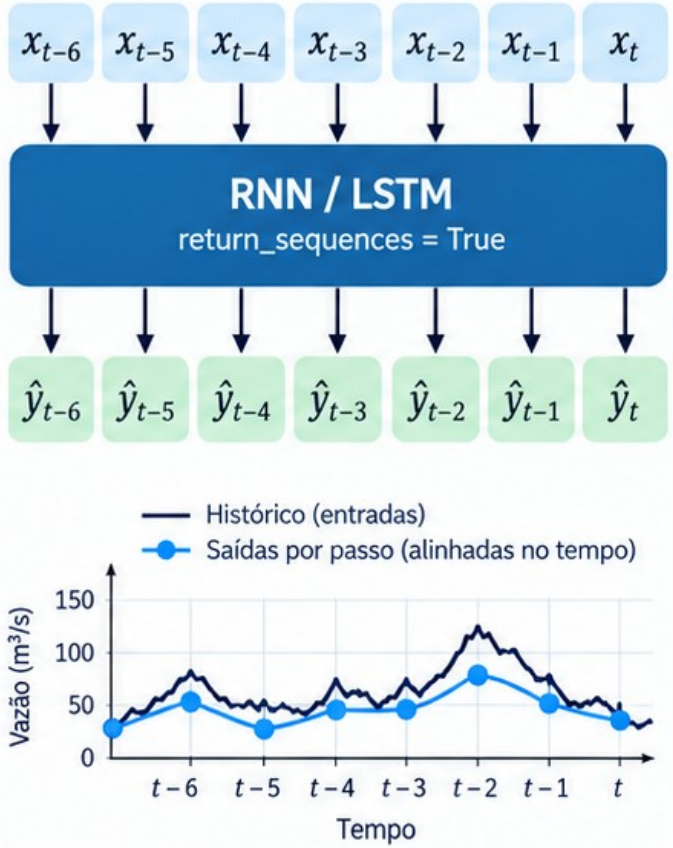
(a) Uma saída por janela (um passo à frente)

Usado para previsão pontual ($t + 1$)



(b) Uma saída por passo

Retorna uma saída (ou estado) em cada passo



Principais aplicações

Uma saída por janela

- Previsão de curto prazo
- Alertas (ex.: 1 dia à frente)
- Modelos simples e rápidos

Uma saída por passo

- Monitoramento da sequência
- Representações temporais detalhadas
- Base para arquiteturas mais avançadas

Importante: `return_sequences` **controla** a saída ao longo do tempo; não significa, por si só, previsão multi-horizonte futura.

14 Quantos parâmetros a recorrência aprende?

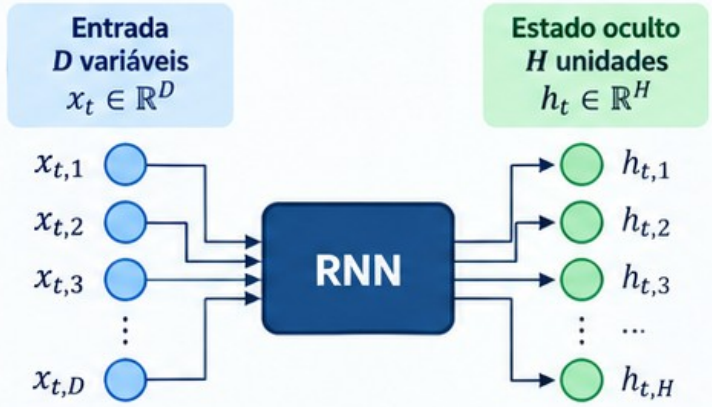
Ideia principal

Na RNN simples, o número de parâmetros do núcleo recorrente depende apenas do número **de variáveis de entrada (D)** e do **número de estados ocultos (H)**, e **não do tamanho da janela temporal.**

- D = número de variáveis de entrada *(ex.: chuva, vazão, temperatura, ...)*
- H = número de estados ocultos *(unidades da camada recorrente)*
- O tamanho da janela temporal (número de passos) **não altera o número de parâmetros**.

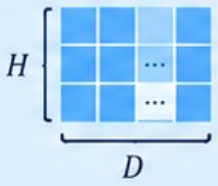
RNN simples

Núcleo recorrente e seus parâmetros



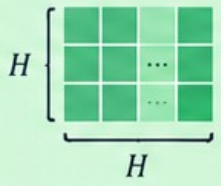
Parâmetros do núcleo recorrente

Matriz de entrada W_x $(H \times D)$



Conecta a entrada x_t ao estado oculto.

Matriz recorrente W_h $(H \times H)$



Conecta o estado oculto anterior h_{t-1} ao estado atual.

Vetor de viés b_h (H)



Viés da camada recorrente.

Número total de parâmetros

Soma dos parâmetros do núcleo recorrente da RNN simples.

$$N_p = \underbrace{H \cdot D}_{\text{Pesos de entrada } (W_x)} + \underbrace{H \cdot H}_{\text{Pesos recorrentes } (W_h)} + \underbrace{H}_{\text{Viés } (b_h)}$$

Exemplo: $D = 4$ e $H = 16$

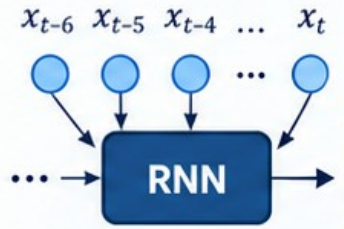
$$N_p = \underbrace{16 \cdot 4}_{64} + \underbrace{16 \cdot 16}_{256} + \underbrace{16}_{16}$$

$$N_p = 336$$

Independe da janela

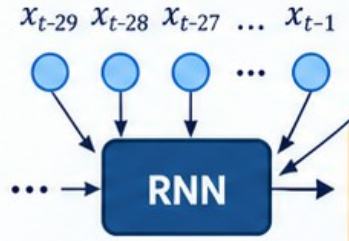
Duas sequências com tamanhos diferentes usando o mesmo núcleo recorrente (mesmos parâmetros).

Janela de 7 dias ($T = 7$)



336 parâmetros

Janela de 30 dias ($T = 30$)



336 parâmetros

Mais passos no tempo aumentam o custo computacional do treinamento, **mas não o número de parâmetros do núcleo recorrente.**

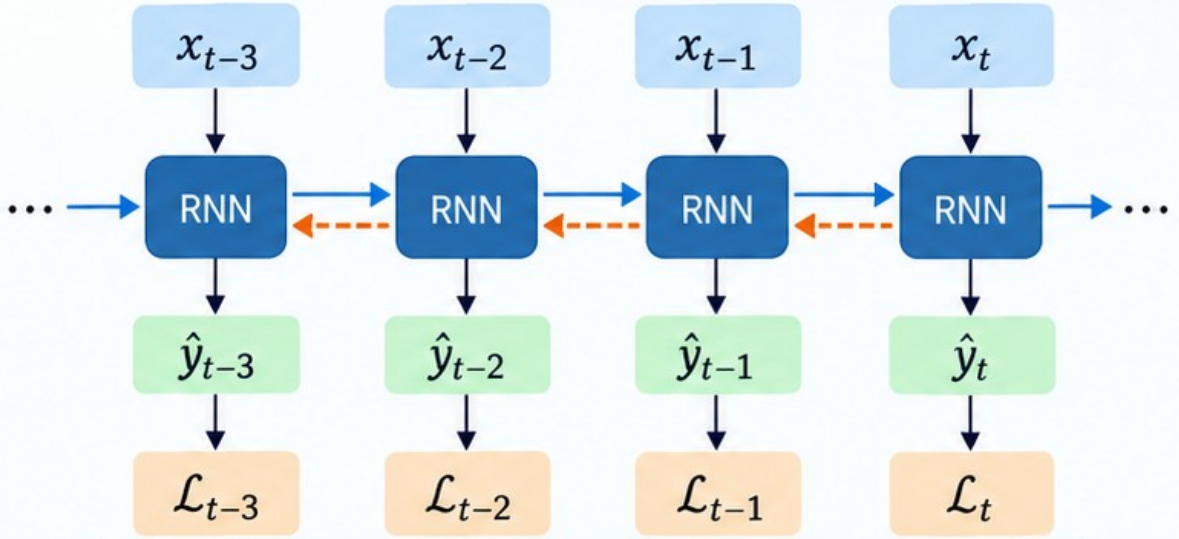
15 Backpropagation Through Time (BPTT)

O que é o BPTT?

O BPTT **propaga o erro de volta no tempo**, atualizando os **mesmos pesos** da RNN em todos os passos da janela.

A RNN é desenrolada no tempo, formando uma rede mais profunda, onde o erro é retropropagado através dos passos de tempo.

Fluxo de informações no tempo



Principais etapas

1. Cálculo da saída em cada passo da sequência.
2. Cálculo da perda total (soma ou média das perdas).
3. Retropropagação do erro no tempo (BPTT).
4. Atualização dos mesmos pesos da RNN/LSTM.

Propagação e pesos compartilhados

Propagação para frente (valores e estados)

Retropropagação (gradientes do erro)

Mesmos pesos em todos os passos



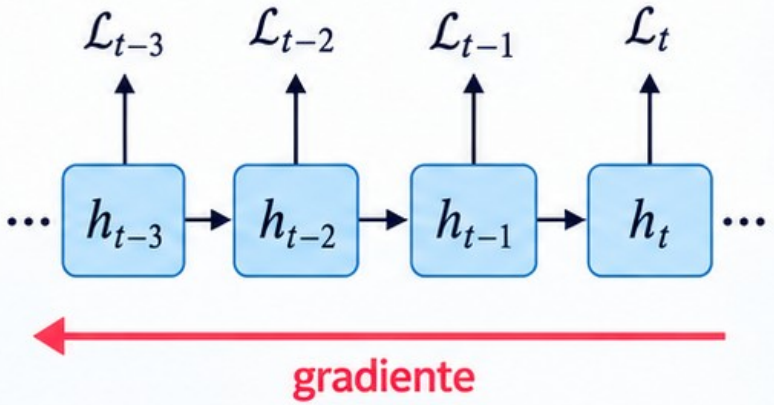
W_x	W_h	b_h
(entrada→estado)	(estado→estado)	(viés)
$(n_h \times n_x)$	$(n_h \times n_h)$	$(n_h \times 1)$

Atenção: gradientes que se atenuam ou explodem

Janelas muito longas podem dificultar o treinamento, pois os gradientes podem se atenuar (*vanishing gradients*) ou explodir (*exploding gradients*) durante a retropropagação no tempo.

Ideia central

Ao voltar no tempo, o gradiente é multiplicado sucessivamente pelas transformações recorrentes.



Produto de derivadas ao voltar no tempo

$$\frac{\partial \mathcal{L}}{\partial h_{t-k}} = J_{t-k+1}^T \cdots J_t^T \frac{\partial \mathcal{L}}{\partial h_t}$$

$$J_j = \frac{\partial h_j}{\partial h_{j-1}} = \operatorname{diag}\left(1 - h_j^2\right) W_h$$

Cada passo acrescenta uma transformação ao gradiente.

$$\frac{\partial \mathcal{L}}{\partial h_{t-k}} = J_{t-k+1}^T \; J_{t-k+2}^T \cdots J_t^T \; \frac{\partial \mathcal{L}}{\partial h_t}$$

Leitura intuitiva

Muitos passos
=> muitas multiplicações.

Se o ganho efetivo for < 1,
o gradiente se atenua.

Se o ganho efetivo for > 1,
o gradiente pode explodir.

Caso escalar ilustrativo

$$|g_k| = |a|^k |g_0|$$

$a < 1$ **atenuação**



$a \approx 1$ **preservação**

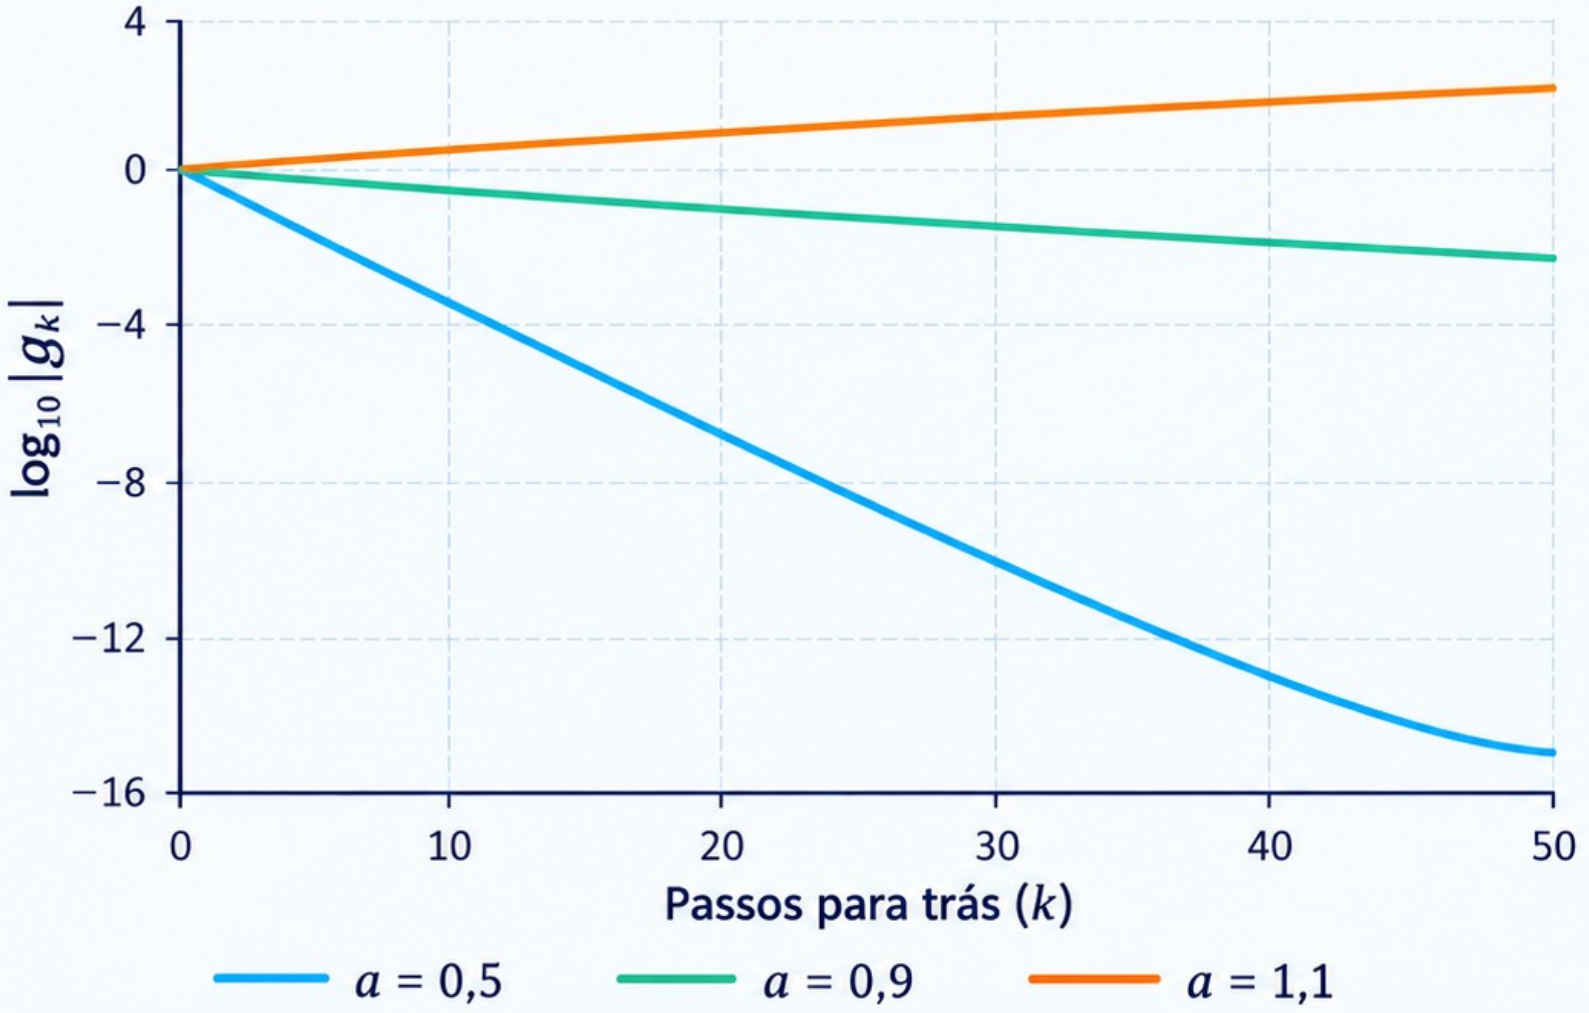


$a > 1$ **amplificação**



Expressão ilustrativa para perda no passo final; perdas intermediárias somam outros termos.

Gradiente pequeno ou grande após muitos passos



Interpretação

$a = 0{,}5$: forte atenuação



O gradiente diminui rapidamente com o número de passos, podendo se tornar muito pequeno.

$a = 0{,}9$: atenuação lenta



O gradiente diminui lentamente, preservando parte do sinal mesmo após muitos passos.

$a = 1{,}1$: amplificação



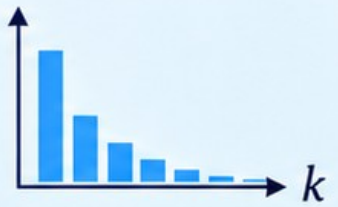
O gradiente aumenta com o número de passos, podendo se tornar muito grande (explodir).

Exemplo escalar exato, $g_0 = 1$. Eixo vertical logarítmico expresso como $\log_{10}$, sem unidade.

A multiplicação em números

Passos k	$0{,}5^k$	$0{,}9^k$	$1{,}1^k$
1	0,500	0,900	1,100
5	0,031	0,590	1,611
20	9,54e-7	0,122	6,727
50	8,88e-16	0,005	117,391

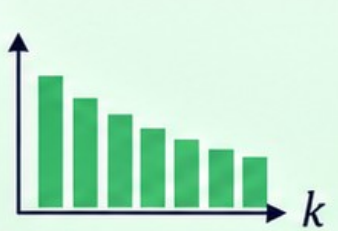
$0{,}5^k$



Decaimento rápido

A multiplicação repetida reduz o valor.

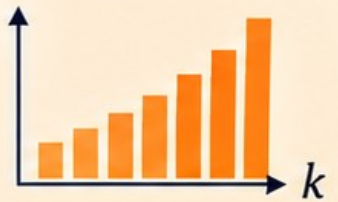
$0{,}9^k$



Decaimento lento

A multiplicação repetida reduz o valor lentamente.

$1{,}1^k$



Crescimento

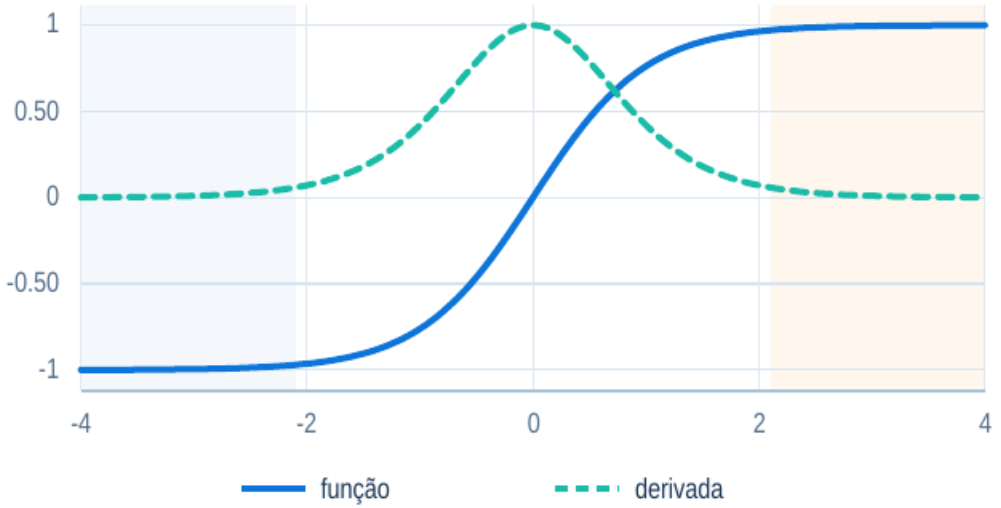
A multiplicação repetida aumenta o valor.

Após 20 passos, $0{,}5^{20} \approx 0{,}00000095$

A multiplicação repetida explica por que gradientes podem desaparecer ou crescer.

FUNÇÃO TANH

tanh(z) e sua derivada

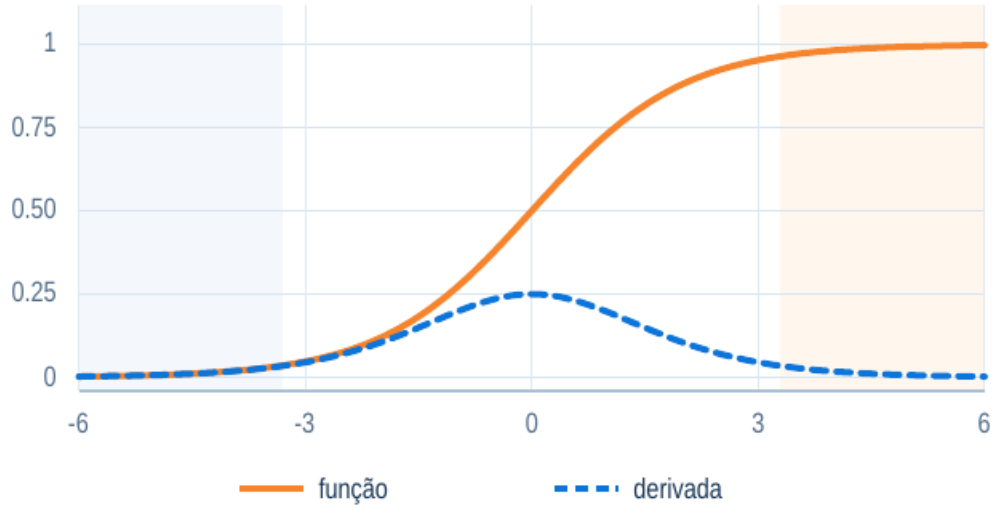


$$\tanh'(z) = 1 - \tanh^2(z)$$

Derivada máxima: 1 (em z = 0)

FUNÇÃO SIGMOID

σ(z) e sua derivada



$$\sigma'(z) = \sigma(z)\,[1 - \sigma(z)]$$

Derivada máxima: 0,25

REGIÕES SATURADAS

Nas extremidades, pequenas variações em z quase não alteram a saída.

O gradiente recorrente também depende das matrizes de pesos e das Jacobianas.

20 Vanishing gradient e a “memória de Dory”



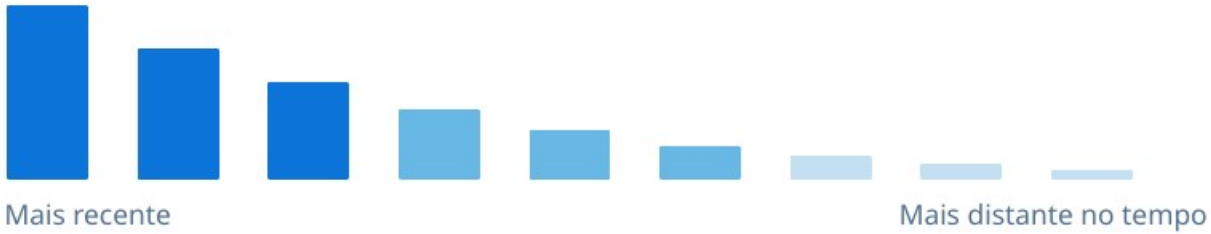
UMA ANALOGIA SOBRE O APRENDIZADO

NA SALA DE AULA

Professor: “E a chuva de 30 dias atrás?”

Gradiente: “Que chuva?”

O sinal de aprendizado enfraquece ao voltar no tempo



Importante: trata-se do gradiente, não de um apagamento obrigatório do estado oculto.

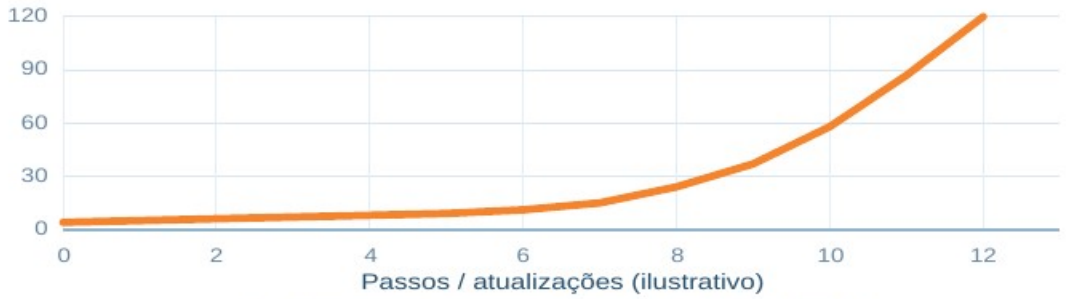
Exploding gradient: “tá tudo bem”

SINTOMA DO TREINAMENTO

loss = NaN

Eu, segurando o café: “Tá tudo bem.”

Gradientes grandes podem tornar o treino instável



Crescimento ilustrativo da norma do gradiente



ATENÇÃO

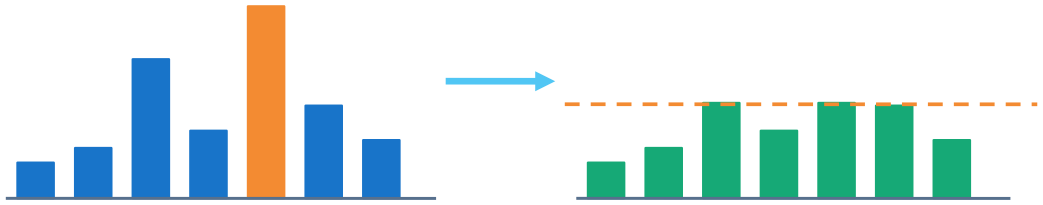
NaN, isoladamente, não prova explosão de gradientes.

Verifique dados, escalas, taxa de aprendizado e norma do gradiente.

22 Medidas para estabilizar o treinamento

01 Clipping da norma

Controla gradientes excessivamente grandes

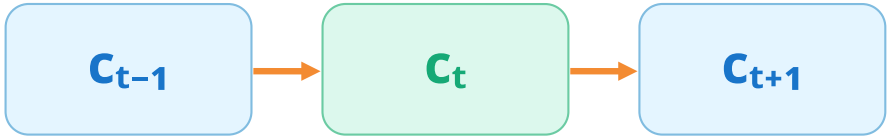


Antes

Depois (norma limitada)

02 LSTM e portas

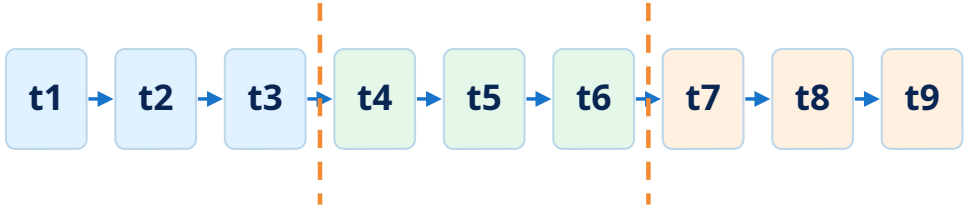
Caminho de memória com atualização aditiva



As portas controlam o que reter, acrescentar e expor.

03 BPTT truncado

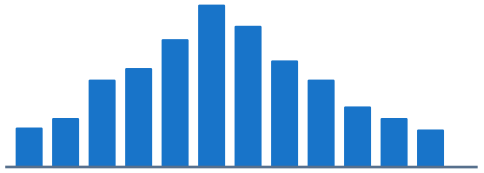
Processa trechos mais curtos da sequência



Gradientes cortados nas fronteiras; o estado pode seguir adiante.

04 Escala e inicialização

Favorecem condições numéricas de otimização



Entradas padronizadas



Ajuste mais regular

Atenção: clipping contém explosões, mas não recupera gradientes que já desapareceram.

23 LSTM: estado da célula e estado oculto

Dois caminhos de informação

c_t | memória da célula

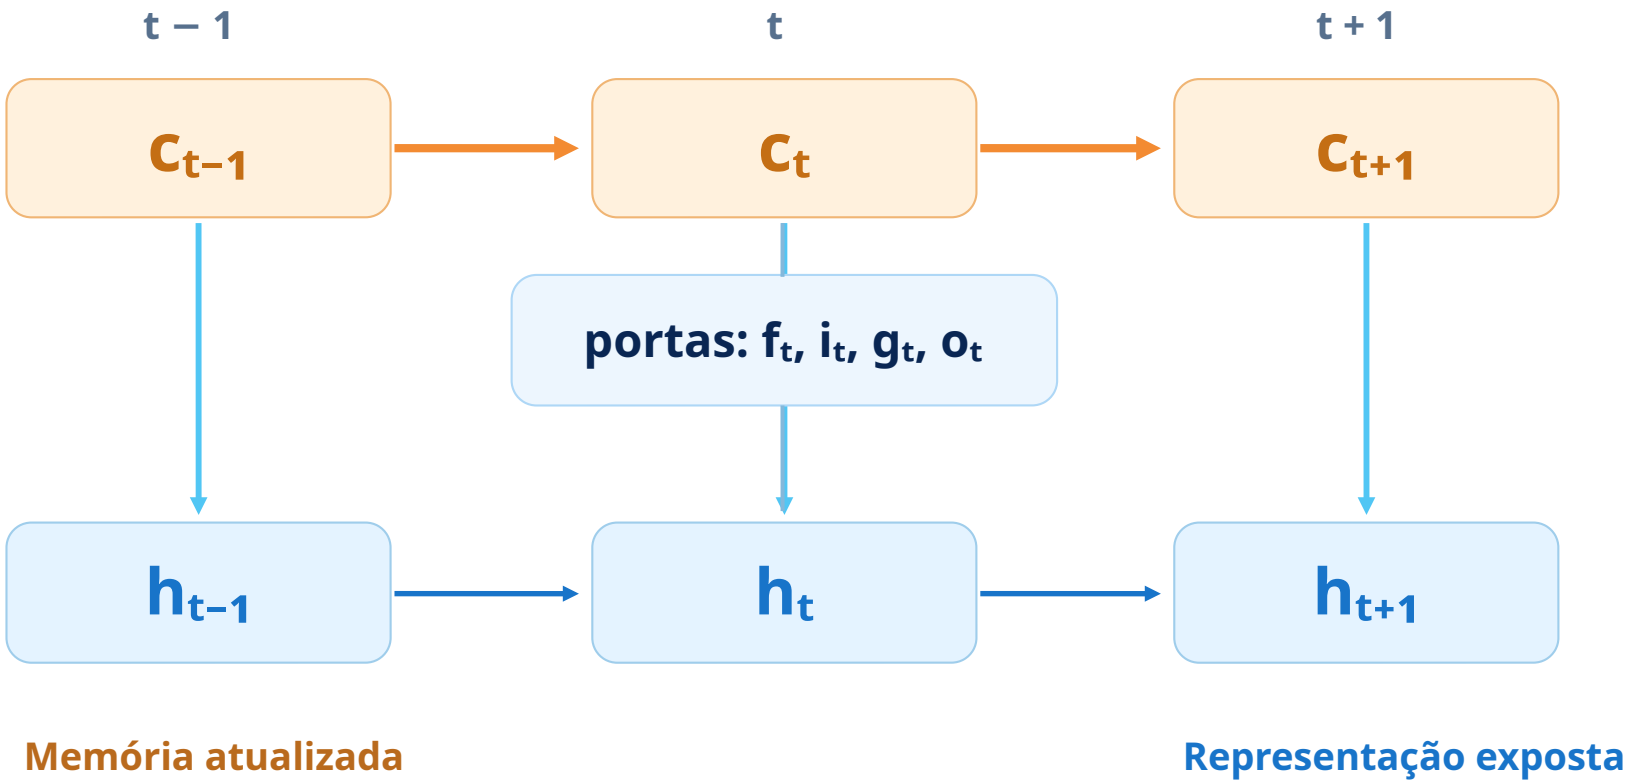
Estado interno atualizado ao longo do tempo. Armazena informação modulada pelas portas.

h_t | estado oculto

Resumo exposto pela célula e usado nas saídas e no cálculo das próximas portas.

Na LSTM, c_t e h_t são vetores distintos.

Evolução dos estados na sequência



O estado h_t também influencia o cálculo das portas no passo seguinte; c_t mantém a via de memória.

24 Equações de uma LSTM com esquecimento

$z_t = [h_{t-1} ; x_t]$ | σ = sigmoid | tanh = tangente hiperbólica | $\odot$ = produto elemento a elemento

Porta de esquecimento

$$f_t = \sigma(W_f z_t + b_f)$$

Modula o estado anterior

Porta de entrada

$$i_t = \sigma(W_i z_t + b_i)$$

Seleciona nova informação

Conteúdo candidato

$$g_t = \tanh(W_g z_t + b_g)$$

Propõe informação nova

Porta de saída

$$o_t = \sigma(W_o z_t + b_o)$$

Modula estado exposto

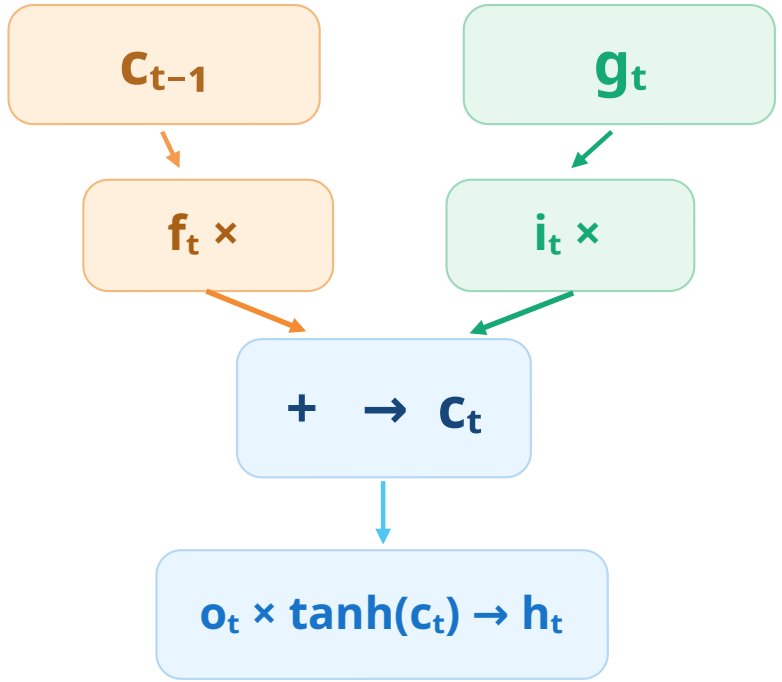
Atualização da memória

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

Estado que a célula expõe

$$h_t = o_t \odot \tanh(c_t)$$

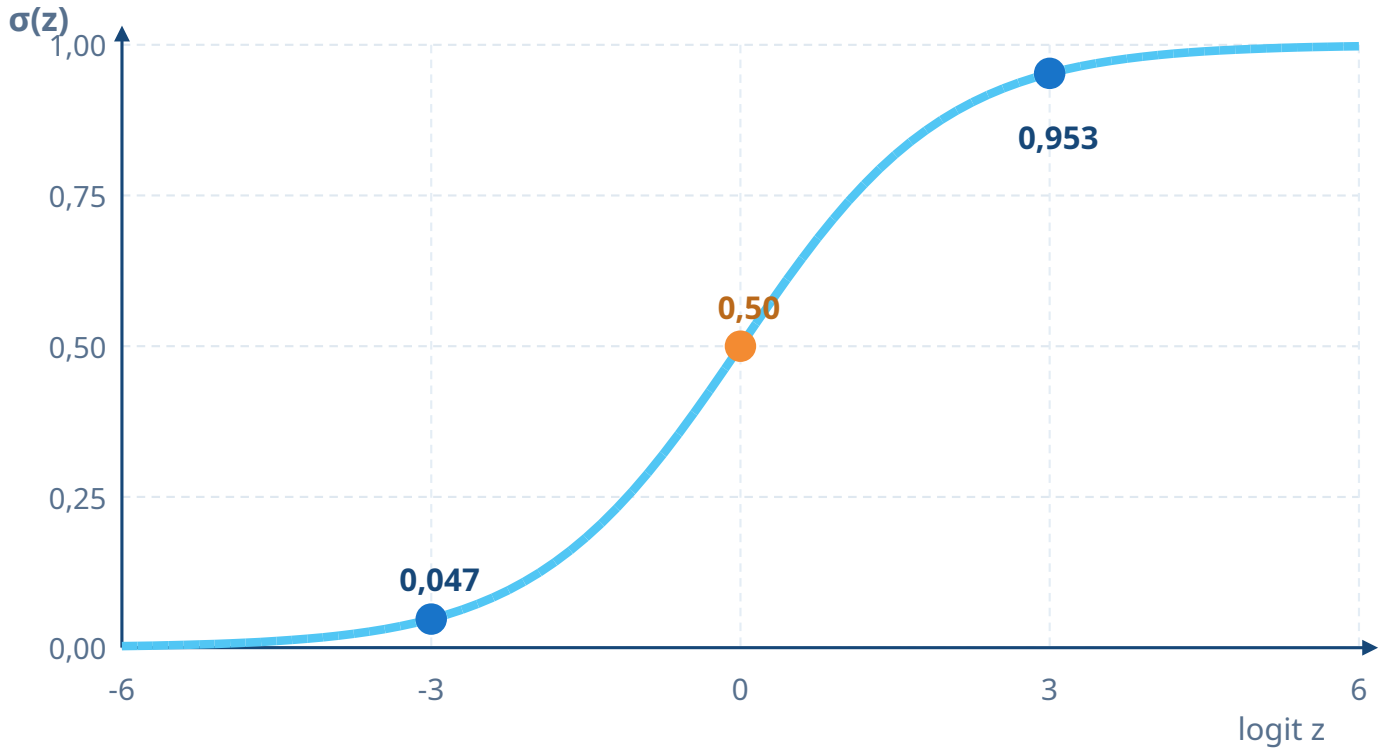
Como o estado é formado



Equações para a versão com porta de esquecimento, sem conexões peephole.

Saída da função sigmoid

$$\sigma(z) = 1 / (1 + e^{-z})$$



Limites próximos de 0 e 1, com transição suave em torno de z = 0.

Modulação de cada componente

Os pesos produzem valores de porta para cada unidade do estado.

Próxima de 0

Passa uma fração muito pequena.

8%

Intermediária

Mantém parte da informação.

52%

Próxima de 1

Permite quase toda a passagem.

95%

Atenção: as portas da LSTM são modulações contínuas, não chaves binárias nem probabilidades.

Célula LSTM

Porta de esquecimento: o que permanece em c

Conteúdo mantido = $f_t \odot c_{t-1}$

Componente	c anterior	f	Conteúdo mantido
1	0,8	0,9	0,72
2	−0,4	0,1	−0,04
3	0,6	0,5	0,30

Valores hipotéticos. A porta modula cada componente do estado da célula.

Célula LSTM

Porta de entrada e candidata a conteúdo

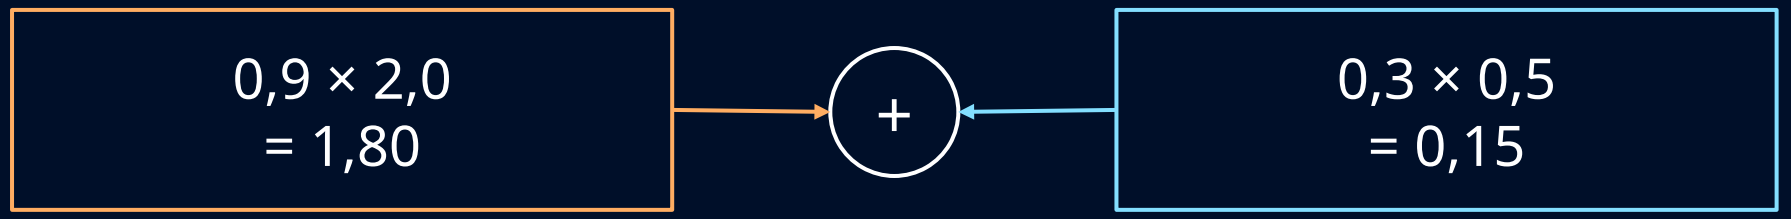
Nova contribuição = $i_t \odot g_t$

Componente	i	g	Nova contribuição
1	0,2	0,5	0,10
2	0,8	−0,5	−0,40
3	0,1	0,8	0,08

g vem da tanh. i vem da sigmoid. A contribuição pode ser positiva ou negativa.

Atualização aditiva do estado da célula

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$



1,80 + 0,15 = 1,95

$c_t = 1,95$

Exemplo escalar. A soma separa o conteúdo mantido da nova contribuição.

Porta de saída: cálculo de h e previsão de Q

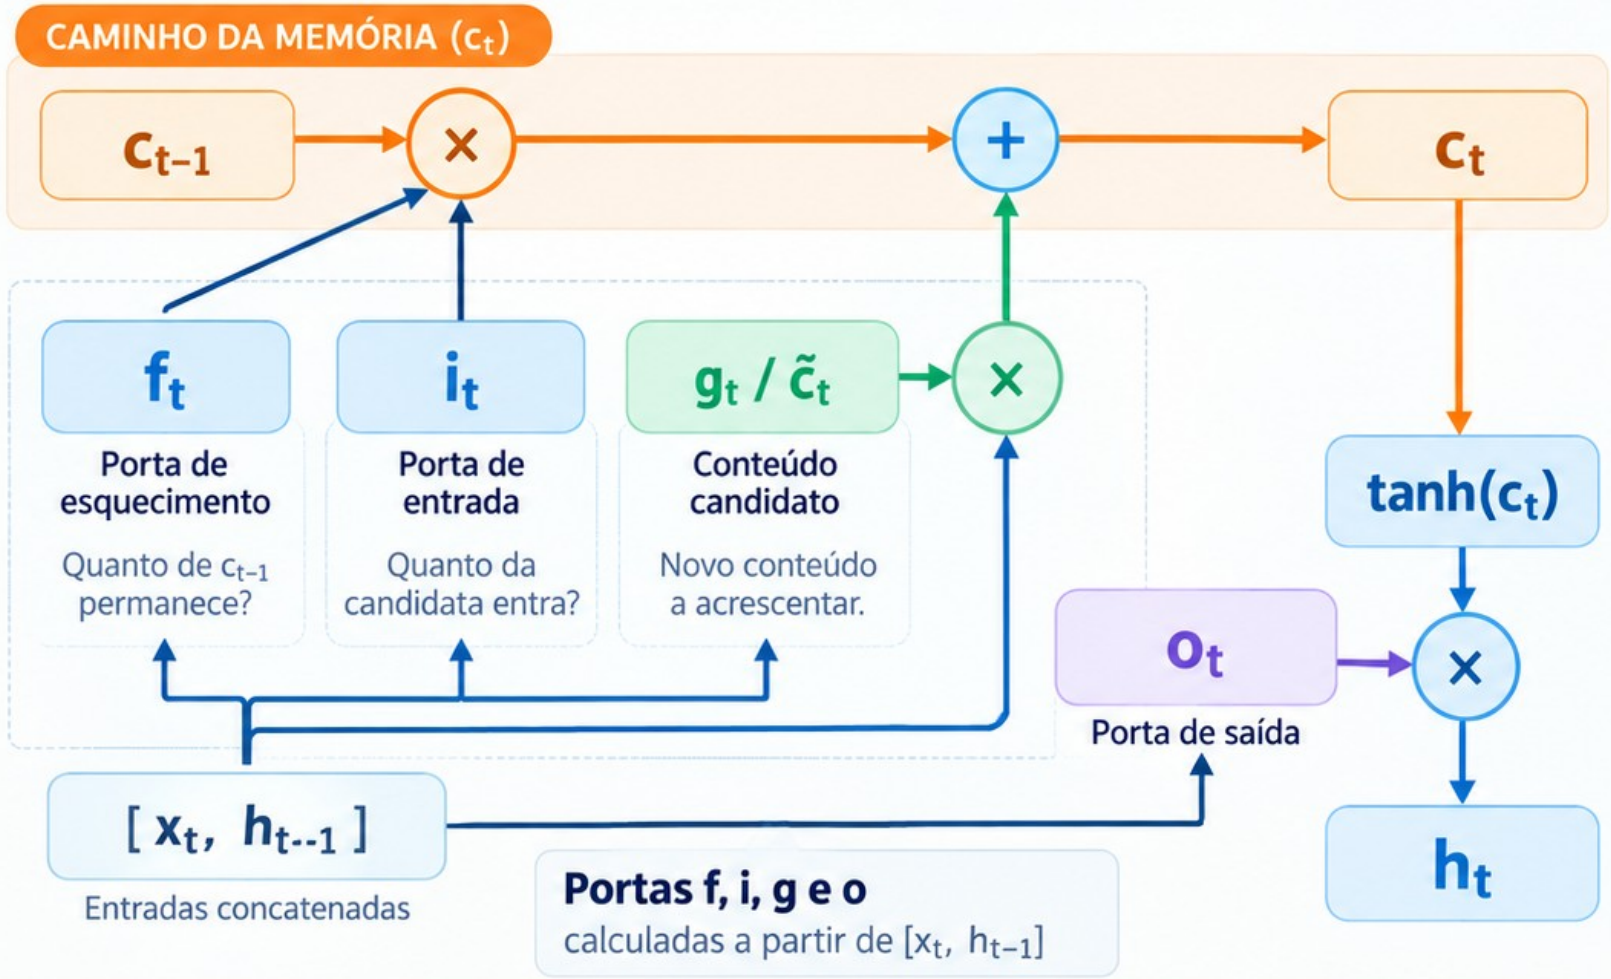
$$h_t = o_t \odot \tanh(c_t)$$

$c_t = 1{,}95$ e $o_t = 0{,}7$
$h_t = 0{,}7 \times \tanh(1{,}95) \approx 0{,}672$



A porta de saída produz h_t. Uma camada adicional transforma h_t no alvo de previsão.

Caminho da memória e portas de controle



Como ler a figura

f_t Esquecer
Quanto de c_{t-1} permanece?

i_t Inserir
Quanto da candidata entra?

g_t Propor
Novo conteúdo a acrescentar.

o_t Expor
Quanto de $\tanh(c_t)$ aparece em h_t?

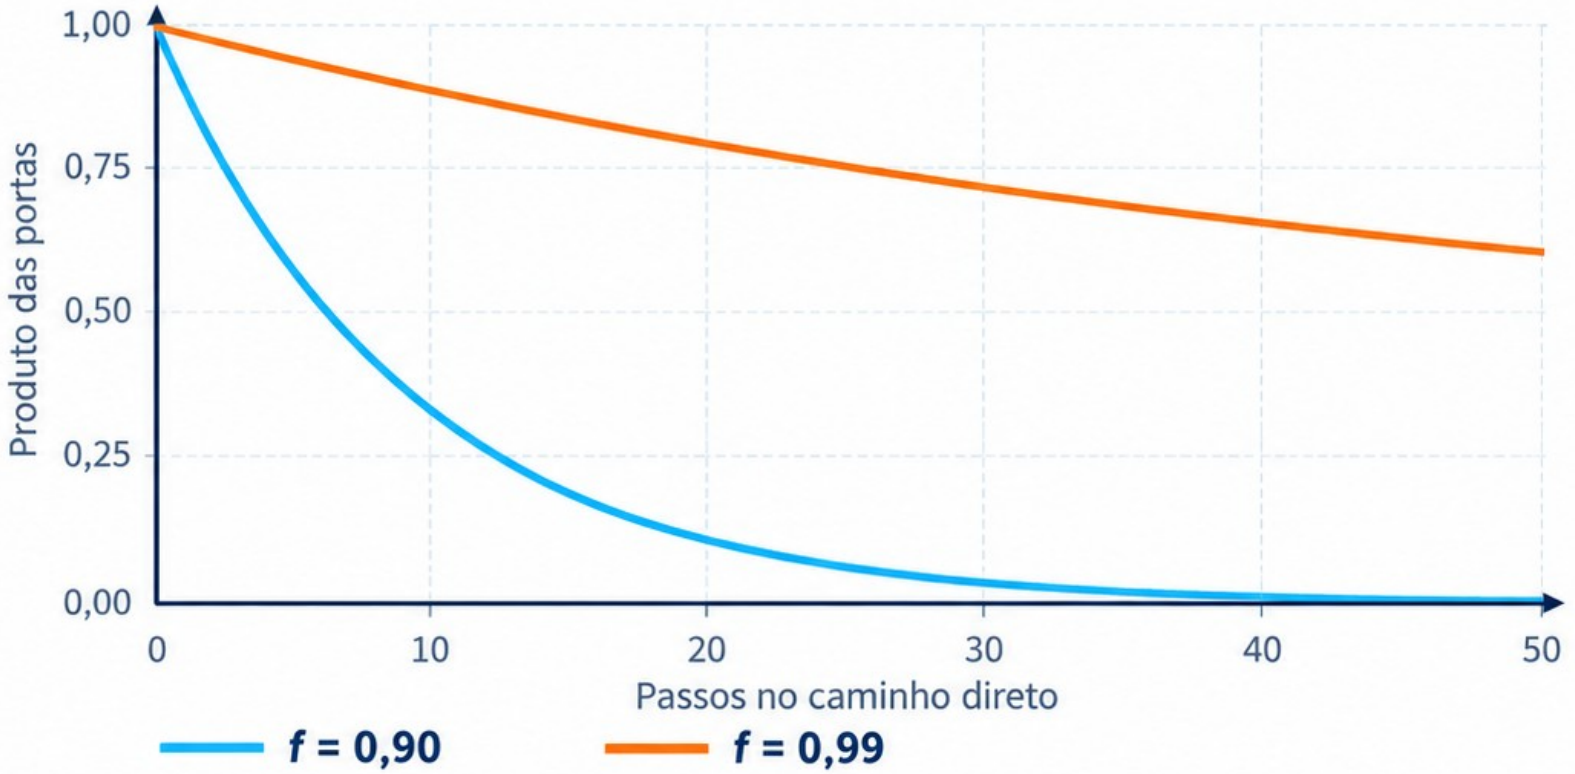
$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

Memória c_t e saída h_t são diferentes: ambas participam da dinâmica recorrente.

A memória também transporta gradientes

Caminho direto: produto das portas de esquecimento

$$\partial c_t / \partial c_{t-1} = \mathrm{diag}(f_t) \quad \text{(portas fixas)}$$



Depois de 50 passos

$0{,}99^{50} \approx 0{,}605$

Caminho com maior retenção

$0{,}90^{50} \approx 0{,}005$

Atenuação muito maior

O que o gráfico mostra

Portas próximas de 1 ajudam a preservar gradientes nesse caminho direto; não eliminam todos os efeitos de vanishing/exploding.

A derivada total inclui caminhos indiretos por h e pelas portas; o gráfico isola o caminho direto.

Um conteúdo novo e dois instantes sem nova escrita

$$c_t = 0{,}9\,c_{t-1} + 0{,}5\,g_t \qquad h_t = 0{,}8\tanh(c_t) \qquad c_0 = 0$$

PASSO 1

$g_1 = 0{,}8$

$c_1 = 0{,}400$

$h_1 = 0{,}304$

→

PASSO 2

$g_2 = 0$

$c_2 = 0{,}360$

$h_2 = 0{,}276$

→

PASSO 3

$g_3 = 0$

$c_3 = 0{,}324$

$h_3 = 0{,}250$

Quantidade retida na memória (c)



Condições do exemplo

f = 0,9
Reter 90% no caminho direto

i = 0,5
Porta de entrada constante

o = 0,8
Porta de saída constante

g = [0,8; 0; 0]
Só o primeiro passo escreve

Mesmo com g = 0, c não zera.

Exemplo escalar sintético: c e h são estados latentes, não volumes de água medidos.

UMA METÁFORA PARA AS PORTAS

“Seu nome está na lista da memória?”

f_t Esquecimento
Que parte do passado fica?

i_t Entrada
Quanto de novo conteúdo entra?

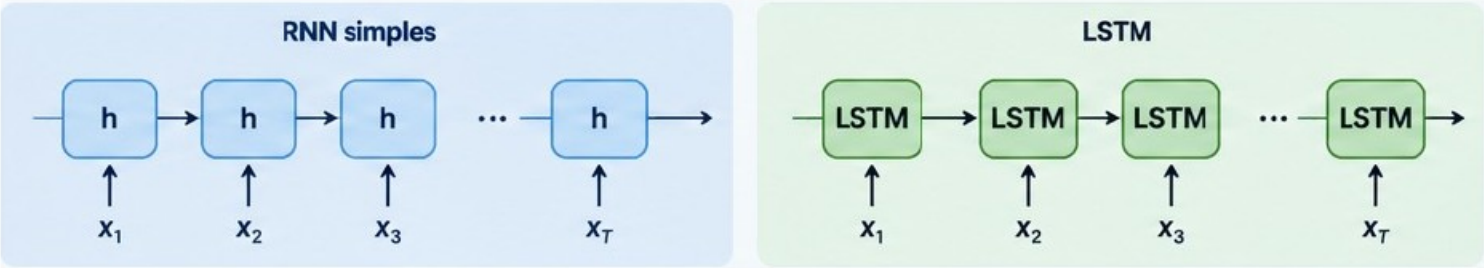
o_t Saída
Quanto da memória aparece em h_t?

Portas são vetores contínuos aprendidos.

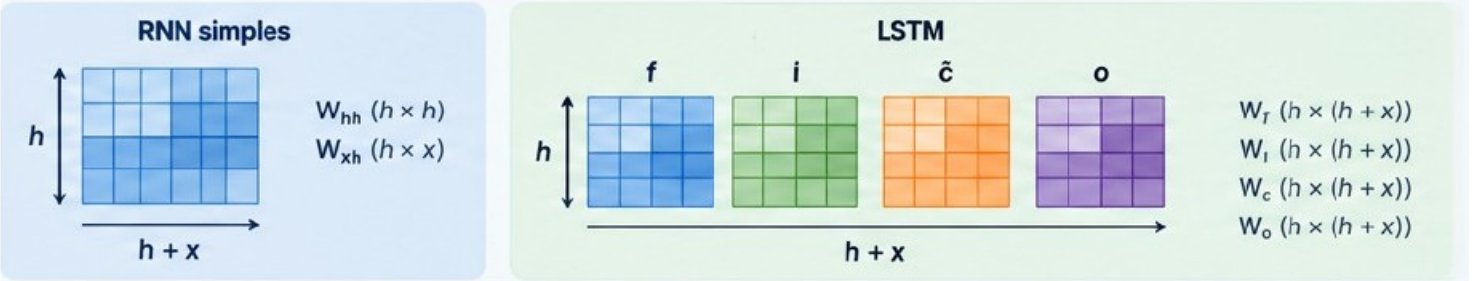


A metáfora ajuda a entender as portas, mas a célula não faz escolhas conscientes.

1 Uma sequência temporal, duas arquiteturas



2 Matrizes de pesos que se repetem no tempo



O que realmente muda?

RNN simples
Um estado oculto: h(t)

LSTM
Quatro portas; estados h(t) e c(t)

RNN simples: 320
H(D + H + 1) = 16(3 + 16 + 1)

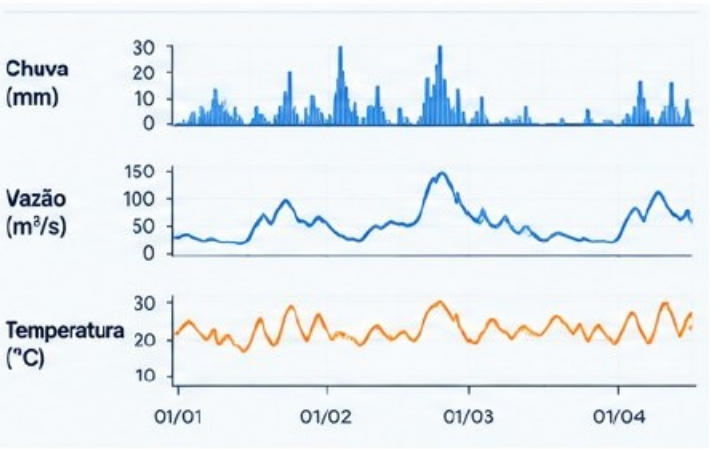
LSTM: 1.280
4H(D + H + 1) = 4 × 320

4× mais parâmetros
D = 3 variáveis; H = 16 estados ocultos

Os pesos são compartilhados entre os passos. Mais parâmetros não garantem melhor previsão.

Previsão operacional de vazão com LSTM

1. Observações até t

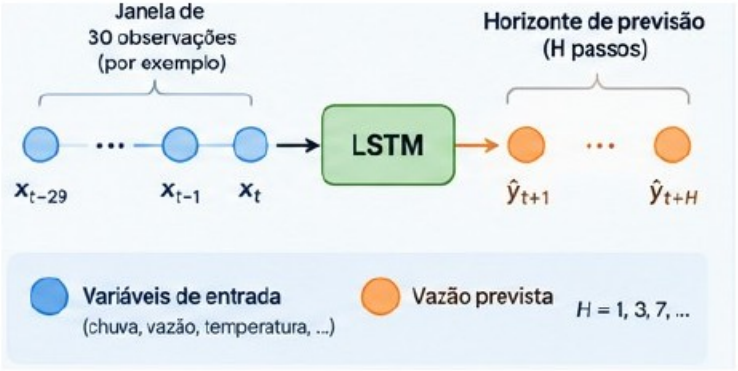


Três séries hidrológicas

Chuva (mm) · Vazão (m^3/s)
Temperatura (°C)

Usar apenas medições já disponíveis.

2. Janela → LSTM



Matriz de entrada

T passos × D variáveis

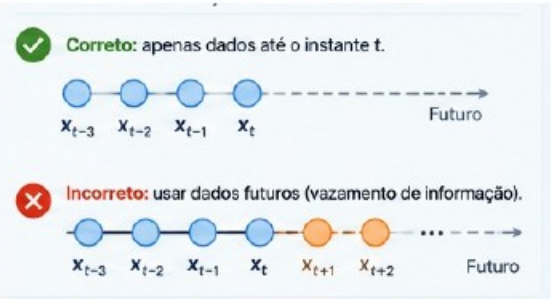
A rede atualiza seus estados (h, c) e entrega a previsão.

3. Vazão futura prevista



Q̂(t + 1) ainda não é medição.

Vazamento de informação



Pergunta operacional: quais dados realmente existiriam quando a previsão fosse emitida?

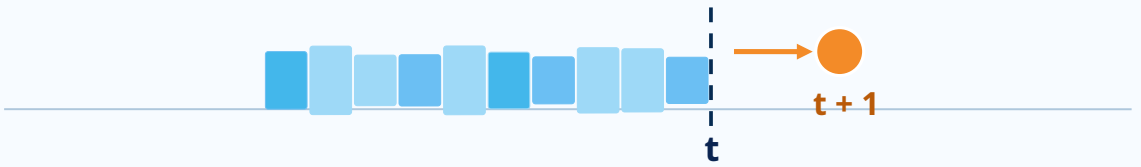
Do histórico observado à vazão futura

T = tamanho da janela | **h = horizonte futuro**

Cada linha representa uma configuração possível do modelo.

T = 30 | h = 1

x(t − 29) … x(t) → Q(t + 1)



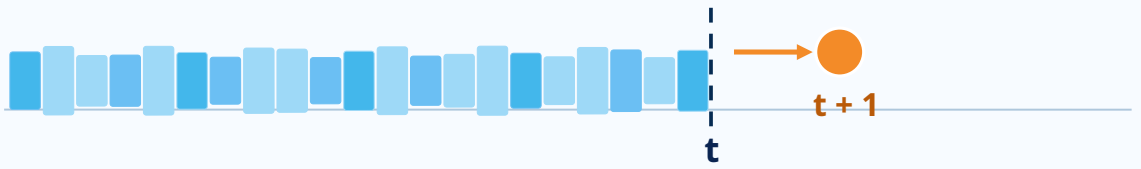
T = 30 | h = 7

x(t − 29) … x(t) → Q(t + 7)



T = 90 | h = 1

x(t − 89) … x(t) → Q(t + 1)



O que muda?

T — quantidade de passado

30 ou 90 observações até t, conforme a resolução temporal dos dados.

h — distância do alvo

h = 1 → Q(t + 1)
h = 7 → Q(t + 7)

Escolha baseada nos dados

Compare T e h com validação temporal. Considere tempo de resposta da bacia, resolução e disponibilidade das variáveis.

Aumentar T amplia o histórico disponível, mas não garante melhor desempenho; mudar h altera o alvo.

Arquitetura mínima em Keras

Código mínimo

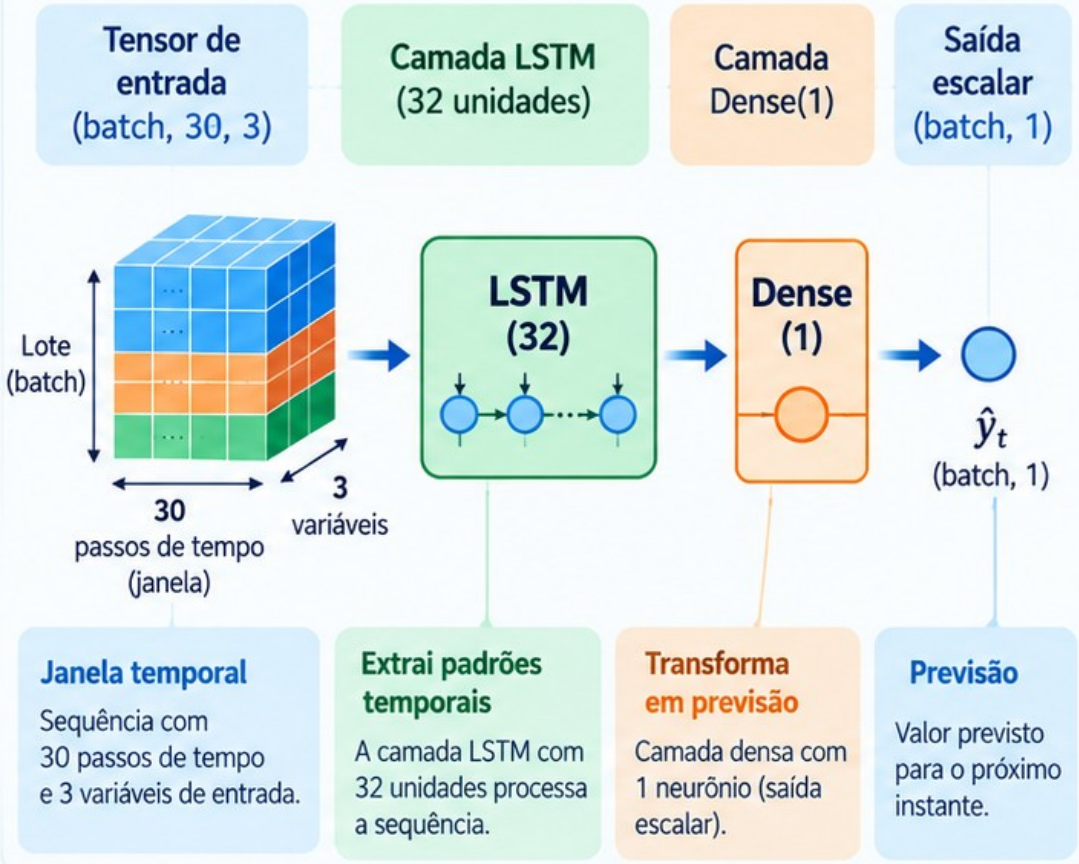
Modelo sequencial com camada LSTM e saída densa para previsão escalar.

```python
import keras
from keras import layers

modelo = keras.Sequential([
  keras.Input(shape=(30, 3)),
  layers.LSTM(32),
  layers.Dense(1)
])
```

Fluxo da arquitetura

Do tensor de entrada à previsão escalar.



Dimensões

Principais tensores ao longo da rede.

Entrada: (lote, 30, 3)
Lote de janelas temporais com 30 passos e 3 variáveis.

Estado final: (lote, 32)
Último estado da camada LSTM com 32 unidades.

Saída: (lote, 1)
Previsão escalar para cada item do lote.

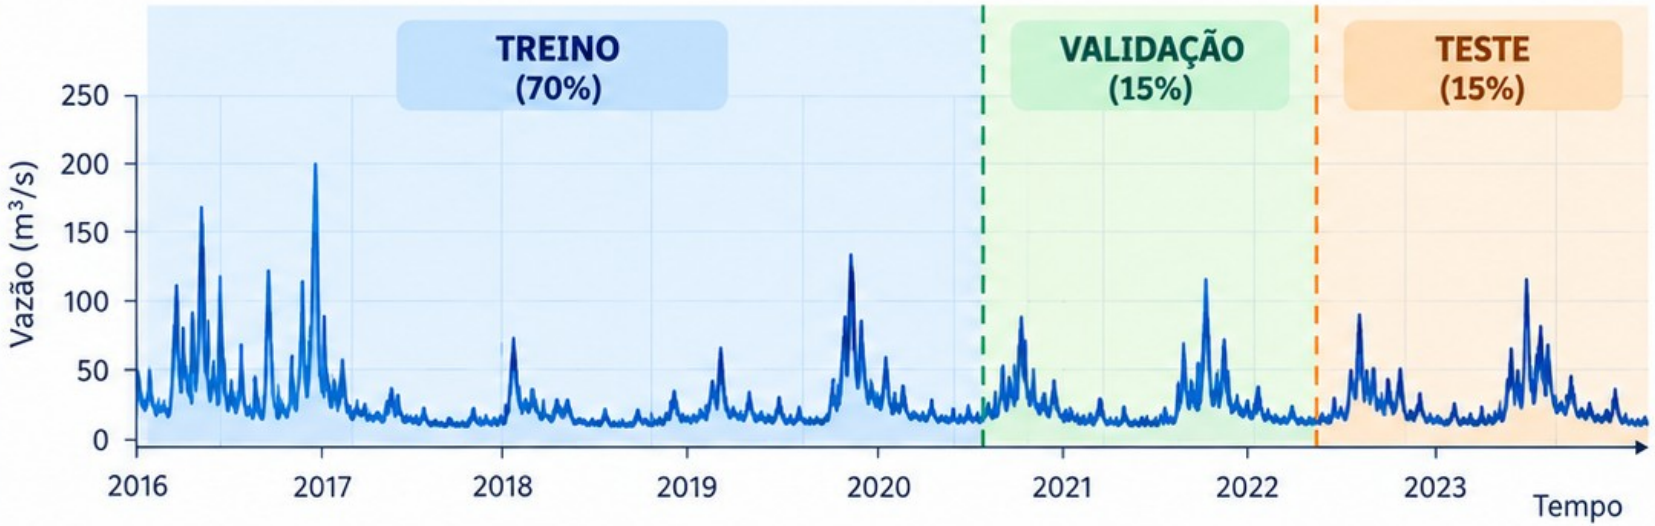
stateful=False
Cada janela inicia com estados zerados por padrão.

Trecho didático de Keras 3. Pressupõe janelas e alvos previamente preparados e um backend configurado.

Separação temporal e preparo dos dados

Três blocos em ordem cronológica

Os intervalos são definidos pelas datas dos alvos previstos, não pelo embaralhamento de amostras.



Ajustar

Pesos, escala e imputação.

Selecionar

Janela / modelo.

Testar

Modelo escolhido.

Fronteira temporal: o histórico anterior pode entrar na janela, mas o alvo futuro nunca pode entrar no treino.

Preparo sem vazamento

1. **Ajuste somente no treino**

   Calcule escalas e regras de imputação usando os dados de treino.

2. **Aplique sem refazer**

   Use os mesmos parâmetros na validação e no teste.

3. **Teste após a escolha**

   Avalie no bloco final o modelo e a janela já selecionados.

Para múltiplos horizontes, verifique cada data-alvo e evite usar informações futuras na preparação.

A falsa previsão perfeita

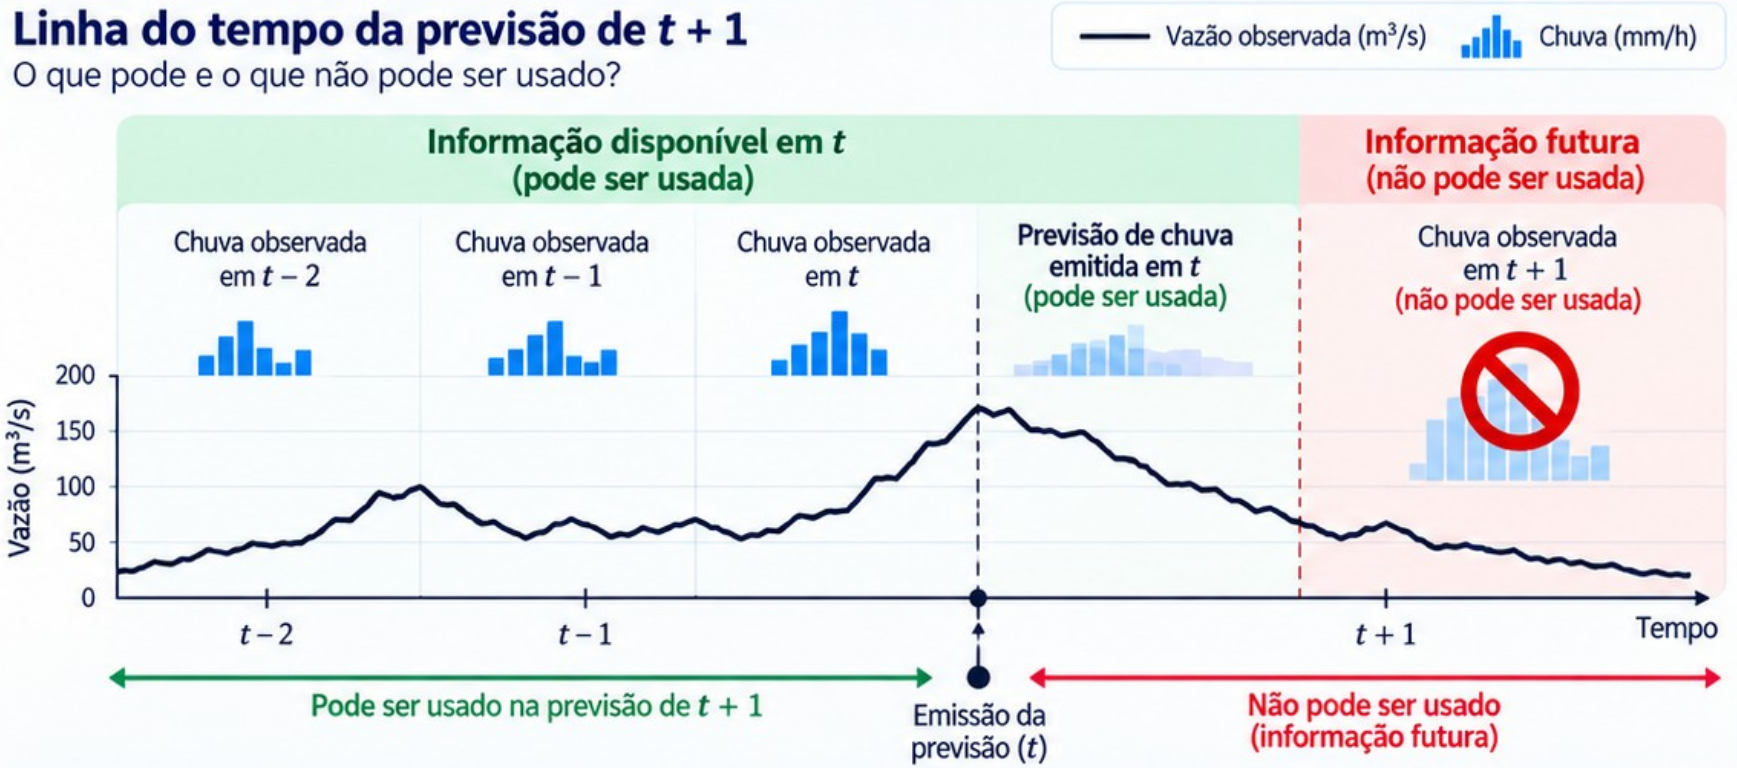
A LSTM:
“Previ perfeitamente a cheia!”

O dataset:
“Eu te passei a chuva de amanhã.”

Se o modelo usa informação do futuro (por exemplo, a chuva observada em $t + 1$), ele parece prever muito bem, mas está “vendo” o futuro. Isso é **vazamento de informação (data leakage)**.

Linha do tempo da previsão de $t + 1$

O que pode e o que não pode ser usado?



Informações e uso na previsão de $t + 1$

Informação em t	Uso na previsão de t + 1
Chuva observada até t	Pode entrar, considerando a latência.
Previsão de chuva emitida em t	Pode entrar como previsão, com erro próprio.
Chuva observada em $t + 1$	Só existe depois do instante de emissão.

Regra prática: na previsão operacional, use apenas o que **existiria no instante de emissão.**

Aplicação hidrológica

Treinamento com clipping e parada antecipada

Por que isso é útil?

Em séries hidrológicas, o treinamento de RNNs pode ser instável. O clipping e a parada antecipada ajudam a tornar o treinamento mais estável e a generalizar melhor.

Estabiliza os gradientes
Evita atualizações muito grandes nos pesos.

Evita explosão de gradientes
Limita a norma conjunta dos gradientes.

Interrompe antes do overfitting
Para o treinamento quando a validação não melhora mais.

Clipping de gradientes

Limita a norma (magnitude) do vetor de gradientes a um valor máximo, evitando atualizações muito grandes nos pesos.

Gradiente muito grande (antes do clipping)

$g =$ → → → → →

$\|g\| = 5.2$ (exemplo)

Gradiente limitado (após o clipping)

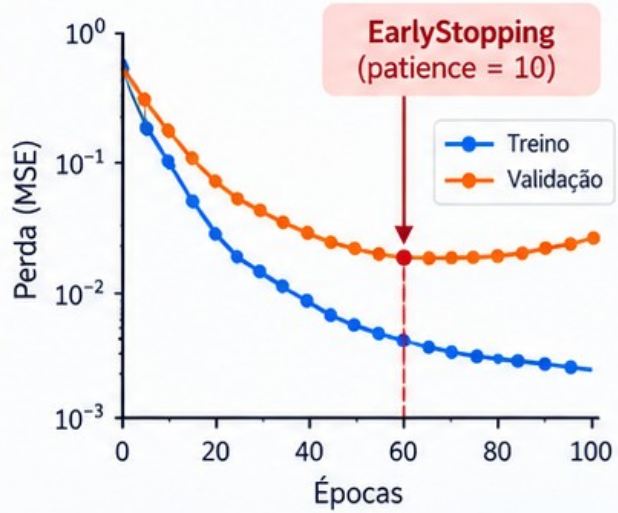
$g_{\text{clipped}} =$ → → → → →

$\|g_{\text{clipped}}\| \leq 1.0$

No Keras, usamos:
`global_clipnorm = 1.0`

Parada antecipada

Monitora a perda de validação e interrompe o treinamento quando não há mais melhora por um número de épocas (patience). Evita overfitting e mantém os melhores pesos.



O treinamento é interrompido e os melhores pesos (menor perda de validação) são restaurados.

Exemplo de código (Keras)

Treinamento com optimizador Adam, clipping de gradientes e parada antecipada.

```
# Compilação do modelo
modelo.compile(
   optimizer=keras.optimizers.Adam(
      learning_rate=1e-3,
      global_clipnorm=1.0   # limita
   ),
   loss="mse"
)

# Parada antecipada
parada = keras.calibacks.EarlyStopping(
   patience=10,
   restore_best_weights=True
)

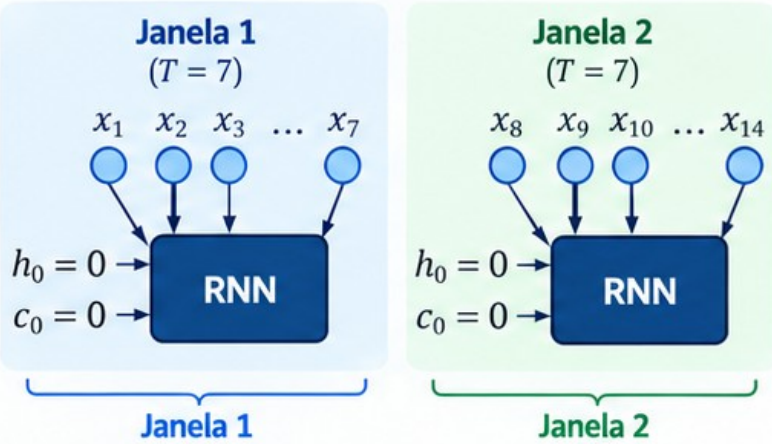
# Treinamento
modelo.fit(
   X_treino, y_treino,
   epochs=100,
   batch_size=32,
   validation_data=(X_val, y_val),
   callbacks=[parada],
   shuffle=False
)
```

global_clipnorm limita a norma conjunta dos gradientes, enquanto a **parada antecipada** reduz overfitting.

Estados entre janelas e BPTT truncado

Janelas independentes

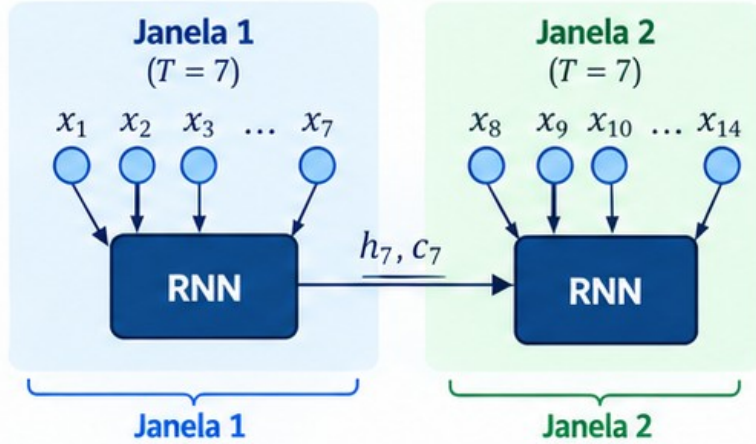
Reinicia h e c em cada janela.



Cada janela é tratada de forma independente, reiniciando h e c em cada janela.

Sequência contínua

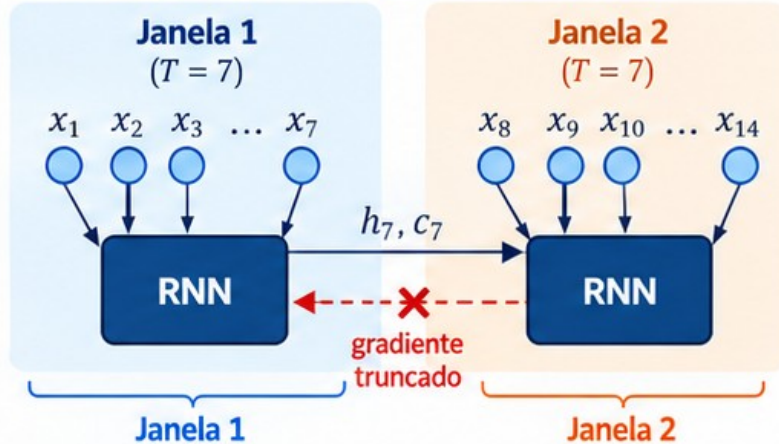
Transporta h e c entre trechos contíguos.



O estado final da primeira janela (h, c) é usado como estado inicial da próxiima.

BPTT truncado

O estado pode seguir, mas o gradiente é truncado na fronteira entre trechos.



O estado pode ser carregado para a próxiima janela, mas o gradiente não atravessa a fronteira.

Cuidados práticos

Exigir ordem temporal
Manter a sequência temporal e a continuidade de cada série.

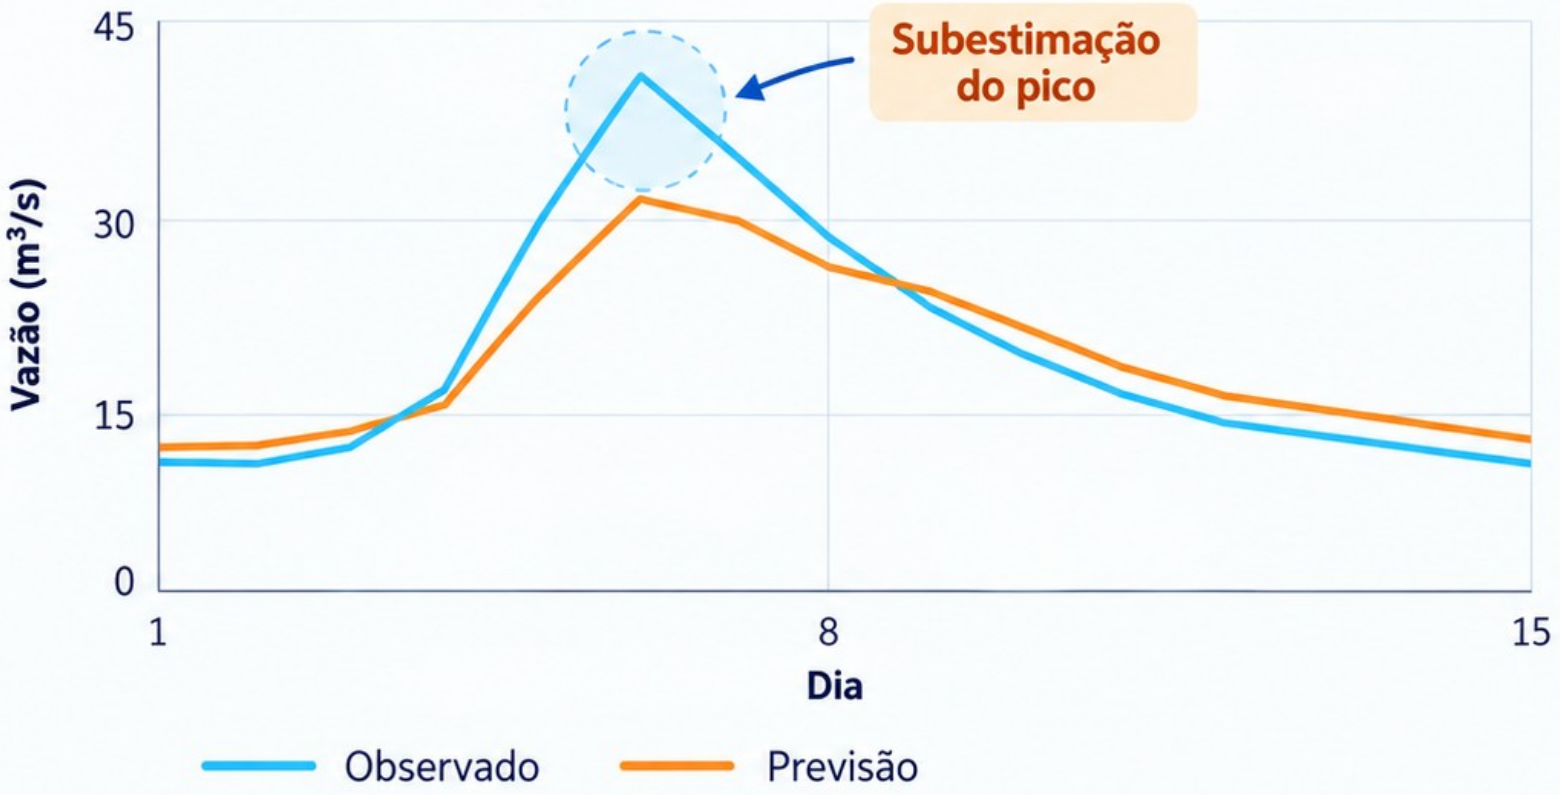
Evitar misturar séries/bacias sem controle do estado
Não misturar séries ou bacias diferentes sem reset ou gestão explícita do estado.

Carregar estado não recupera crédito antes do corte do gradiente
O BPTT truncado limita o alcance do gradiente, mesmo que o estado seja carregado.

Mudança de bacia ou série exige tratamento explícito do estado.

Hidrograma observado e previsto

Comparação entre a vazão observada e a previsão do modelo.



Timing

Verificar deslocamento temporal do pico (adiantado ou atrasado).

Viés

Comparar níveis médios e tendência (superestimação ou subestimação sistemática).

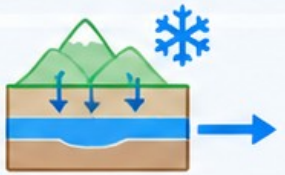
Estiagem e extremos

Avaliar o desempenho em baixas vazões (estiagem) e em eventos intensos (picos de cheia).

O pico apresenta subestimação.

Uma métrica global boa **não substitui a inspeção de hidrogramas e eventos críticos.**

Kratzert et al. (2018)

Dimensão	Desenho do estudo
Dados	241 bacias do CAMELS, nos Estados Unidos. 
Entradas	Forçantes meteorológicas diárias. 
Alvo	Vazão diária. 
Comparação	SAC-SMA acoplado a Snow-17. 
Experimentos	Modelos por bacia, regionalização e transferência. 

O trabalho mostrou **forte potencial de LSTMs** para modelagem chuva–vazão em múltiplas bacias.

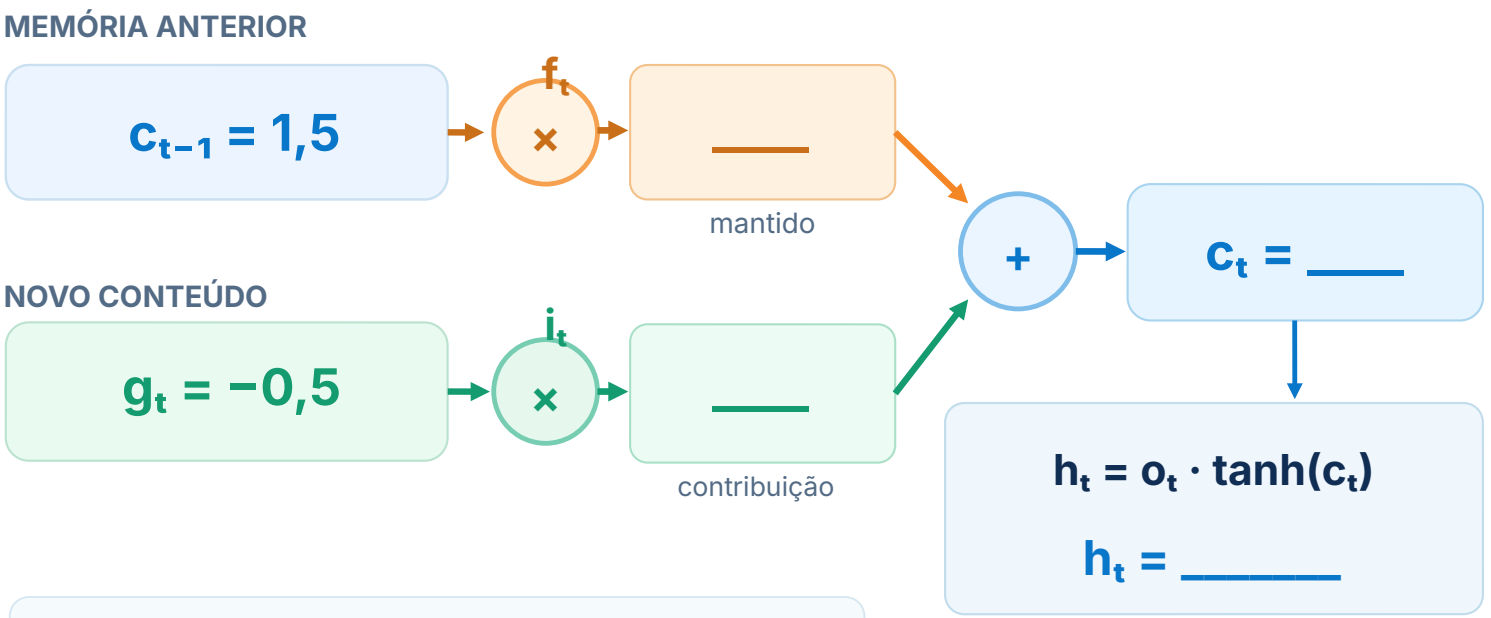
HESS 22, 6005–6022.

Exercício: uma célula LSTM em um passo

Dois caminhos constroem a nova memória

Use as portas para calcular a memória atualizada e o estado oculto.

$c_{t-1} = 1{,}5$ | $f_t = 0{,}8$ | $i_t = 0{,}2$ | $g_t = -0{,}5$ | $o_t = 0{,}75$



Etapa 1 manter + acrescentar

Etapa 2 aplicar a porta de saída

Sua missão

1. **Calcule quanto da memória anterior permanece.**
2. **Calcule a contribuição nova e obtenha c_t.**
3. **Use a porta de saída para determinar h_t.**

E se $f_t = 0{,}2$?

Refaça o cálculo mantendo i, g e o constantes.

0,8 | 0,2

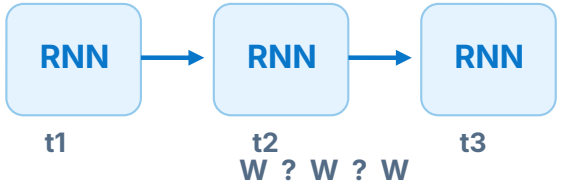
4 minutos em duplas · Valores escalares e adimensionais · Respostas comentadas nas notas do professor

45 Checagem de compreensão

Cinco perguntas para ligar os conceitos às figuras

1 Pesos da RNN

A rede usa pesos diferentes em cada dia?



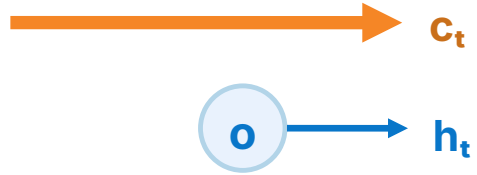
2 Clipping

Ele recupera gradientes que já desapareceram?



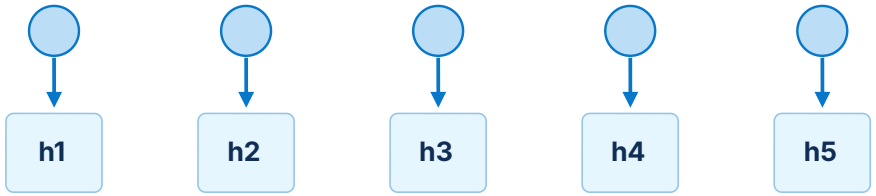
3 Memória e estado

Na LSTM, c_t e h_t representam a mesma coisa?



4 return_sequences=True

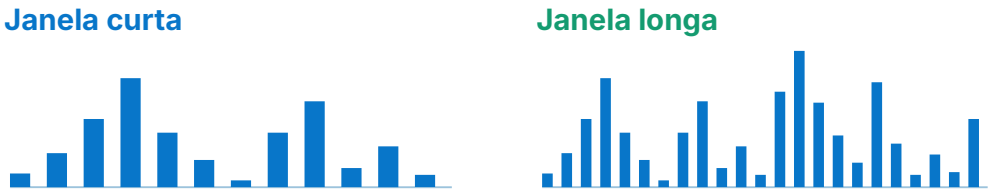
Retornar uma saída por passo significa prever vários dias futuros?



Estados da sequência de entrada

5 Janela temporal

Uma janela maior garante uma previsão melhor?



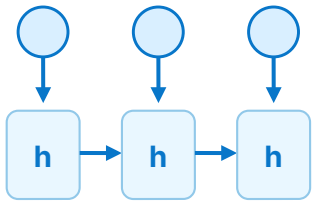
Comparar por validação temporal

3 minutos de discussão · Explique por quê, não apenas “sim” ou “não” · Gabarito nas notas do professor

Síntese: memória, aprendizado e previsão

O caminho da informação — da sequência de entrada à avaliação hidrológica

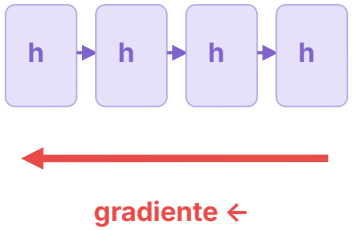
01 RNN



W compartilhado

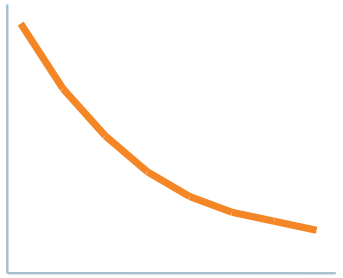
Atualiza o estado a cada passo usando pesos compartilhados.

02 BPTT



Propaga o erro pelo grafo recorrente desenrolado.

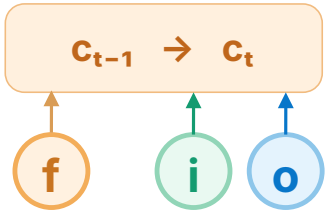
03 Vanishing



gradiente ↓

O produto de Jacobianas enfraquece sinais distantes.

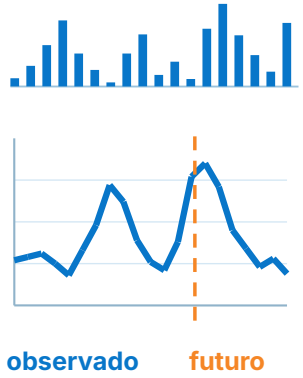
04 LSTM



portas aprendidas

Portas controlam a memória c e a saída h.

05 Aplicação



Usar só dados disponíveis e validar no tempo.

Memória temporal ≠ desempenho preditivo

Incerteza exige um método adicional

i Uma LSTM usual entrega uma previsão pontual; intervalos requerem procedimentos específicos.

Referências e material para consulta

Da teoria das redes recorrentes à prática hidrológica

2013 — **Treinamento de RNNs**



Pascanu, Mikolov e Bengio

ICML • gradientes e otimização

1997 — **LSTM original**



Hochreiter e Schmidhuber

Neural Computation

2000 — **Porta de esquecimento**

f · i · o

Gers, Schmidhuber e Cummins

Neural Computation

2018 — **Chuva–vazão com LSTM**



Kratzert et al.

HESS • 22, 6005–6022

API — **Keras 3**

[LSTM(32)]

SimpleRNN • LSTM • Adam

EarlyStopping e Dense

GUIA — **scikit-learn**

treino → teste

Common pitfalls

Preparo e data leakage

Links completos nas notas · Dados dos gráficos didáticos são sintéticos · Ilustrações de humor são originais